

به نام خدا



مدل های زبانی بزرگ (بهار ۱۴۰۵)

تمرین کامپیوتری پنجم

مهلت ارسال: ۱۴۰۵/۰۴/۰۵

استاد درس: دکتر دوستی

طراحان تمرین:

- محمد امانلو (Mohammad.Amanlou@ut.ac.ir)

- محمد مهراییان (m.mehrabian@ut.ac.ir)

قوانین و ملاحظات

نحوه ارسال تمرین:

- تمامی فایل ها باید در یک فایل فشرده با نام LLM-CA5-StudentID ارسال شوند.
- تمامی کدهای ارسال شده باید امکان اجرای مجدد داشته باشند. اگر تنظیمات خاصی برای اجرا نیاز است، آن را ذکر کنید.
- کدهای ارسال شده باید توسط خودتان اجرا شده باشند و نتایج اجرا در فایل ارسالی مشخص باشد.

رعایت اصول آکادمیک و صداقت علمی:

- این تمرین باید به صورت فردی انجام شود. هرگونه همکاری یا نوشتن تمرین به صورت گروهی ممنوع است.
- در صورت مشاهده تشابه در پاسخ، تمامی افراد درگیر، نمره صفر دریافت خواهند کرد و موضوع به استاد گزارش خواهد شد.

استفاده از ابزارهای هوش مصنوعی:

استفاده از ابزارهایی مانند Copilot، Gemini، ChatGPT و موارد مشابه مجاز است، اما تحت شرایط زیر:

- نحوه استفاده از این ابزارها را در انتهای نوتبوک خود توضیح دهید (ابزارهای استفاده شده، کاربردهای مشخص و موارد مرتبط).

- تمامی پرامپت ها و لینکهای استفاده شده را در انتهای نوتبوک و در یک سلول قرار دهید.
- عدم ارائه این اطلاعات به منزله سرقت علمی محسوب شده و منجر به نمره صفر خواهد شد.

ارتباط با TA ها و پرسیدن سوال:

- دانشجویان میتوانند تمامی سوالات مرتبط به تمرین خود را در گروه درس و یا با ایمیل با TA طراح سوال مطرح کنند.

- در تمامی پرسش ها حتما ایمیل دستیاران ارشد درس باید cc شود.

○ علی رمضانی - ali.ramezani.96@ut.ac.ir

○ علی خرم فر - Khoramfar@ut.ac.ir

مهلت ارسال و جریمه تأخیر:

- امکان ارسال تمرین با تأخیر تا ۲ روز وجود دارد. برای هر روز تأخیر **۱۰ درصد جریمه** اعمال میشود.
- تأخیر به صورت ساعتی محاسبه شده و پس از دو روز تأخیر، تمرین پذیرفته نخواهد شد.
- **مهلت ارسال عادی این تمرین تا پایان روز ۵ تیر و مهلت ارسال با تاخیر تا پایان روز ۷ تیر می باشد.**

تمرین اول: ارزیابی ماژولار و چندزبانه اعتمادپذیری مدل های زبانی بزرگ با دیتاست XQuAD

۱. مقدمه و هدف تمرین

در این تمرین، هدف طراحی و پیاده سازی یک چارچوب ارزیابی برای مدل های زبانی بزرگ است. برخلاف ارزیابی های ساده که فقط دقت پاسخ نهایی را بررسی می کنند، در این تمرین مدل از چند زاویه مختلف ارزیابی می شود؛ از جمله درستی پاسخ، کیفیت توضیح، میزان اتکا به متن داده شده، عملکرد چندزبانه، اختلاف عملکرد بین زبان ها، و اثر استفاده از یک معماری ماژولار شامل تولیدکننده پاسخ، ارزیاب و اصلاح کننده.

در این تمرین باید از دیتاست XQuAD استفاده شود. XQuAD یک دیتاست چندزبانه برای سؤال پاسخ است که نمونه های آن از SQuAD گرفته شده و به چند زبان ترجمه شده اند. ویژگی مهم این دیتاست این است که یک سؤال و متن زمینه ای مشابه در چند زبان مختلف وجود دارد. بنابراین می توان عملکرد مدل را روی زبان های مختلف به شکل نسبتاً کنترل شده مقایسه کرد.

در این تمرین، حداقل از ۴ زبان مختلف استفاده کنید. در صورت امکان می توانید زبان های بیشتری نیز اضافه کنید. همچنین فقط باید از یک مدل HuggingFace استفاده شود. بعنوان مثال می توانید از مدل Qwen/Qwen2.5-0.5B-Instruct استفاده کنید. همین مدل باید برای همه بخش های تمرین استفاده شود. در گزارش نهایی باید توضیح دهید که استفاده از یک مدل واحد برای هم generator و هم verifier چه محدودیت هایی دارد.

۲. معرفی مقالات و منابع مورد نیاز

این تمرین علاوه بر پیاده سازی عملی، بر پایه چند مقاله و منبع پژوهشی مرتبط با ارزیابی و اعتمادپذیری مدل های زبانی بزرگ طراحی شده است. دانشجویان لازم است قبل از شروع تمرین، ایده کلی این منابع را مطالعه کنند و در گزارش نهایی خود توضیح دهند که هرکدام از این منابع چه ارتباطی با بخش های مختلف تمرین دارد.

اولین مقاله پیشنهادی، مقاله HELM: Holistic Evaluation of Language Models است. ایده اصلی این مقاله آن است که ارزیابی مدل های زبانی بزرگ نباید فقط به یک معیار مانند accuracy محدود شود. در عوض، مدل ها باید از چندین جنبه مختلف مانند درستی پاسخ، پایداری، سوگیری، انصاف، ایمنی، کالبراسیون و کارایی بررسی شوند. این مقاله مبنای اصلی نگاه چندمعیاره در این تمرین است؛ زیرا در این تمرین نیز مدل فقط با معیار پاسخ درست ارزیابی نمی شود، بلکه معیارهایی مانند faithfulness، عملکرد چندزبانه، اختلاف عملکرد بین زبان ها و اثر معماری ماژولار نیز بررسی می شوند.

لینک مقاله: <https://arxiv.org/abs/2211.09110>

مقاله دوم، DecodingTrust: A Comprehensive Assessment of Trustworthiness in GPT Models است. این مقاله به بررسی اعتمادپذیری مدل های زبانی از جنبه هایی مانند bias، fairness، ethics، privacy، robustness و safety می پردازد. ارتباط این مقاله با تمرین حاضر در بخش تحلیل bias و ethics است. در این تمرین، تمرکز اصلی روی language-based bias یا اختلاف عملکرد مدل بین زبان های مختلف است. اگر مدل در یک زبان، مثلاً انگلیسی، عملکرد بسیار بهتری نسبت به زبان های دیگر داشته باشد، این مسئله می تواند از نظر انصاف و اخلاق در کاربردهای واقعی مدل های زبانی مهم باشد.

لینک مقاله: <https://arxiv.org/abs/2306.11698>

مقاله سوم، SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative LLMs است. این مقاله ایده بررسی پاسخ های مدل از طریق self-consistency و مقایسه خروجی های مختلف مدل را مطرح می کند. در این تمرین، از این ایده برای طراحی نگاه ماژولار استفاده می شود؛ یعنی پاسخ اولیه مدل بدون بررسی نهایی پذیرفته نمی شود، بلکه یک مرحله verifier برای ارزیابی سازگاری پاسخ با context و یک مرحله reviser برای اصلاح پاسخ در نظر گرفته می شود. بنابراین این مقاله از نظر مفهومی با بخش modular pipeline تمرین مرتبط است.

لینک مقاله: <https://arxiv.org/abs/2303.08896>

همچنین دیتاست XQuAD به عنوان منبع داده اصلی تمرین استفاده می شود. این دیتاست برای ارزیابی cross-lingual question answering طراحی شده و شامل نمونه های سؤال پاسخ در چند زبان مختلف است. استفاده از XQuAD به دانشجویان اجازه می دهد عملکرد مدل را روی زبان های مختلف بررسی کنند و ببینند آیا مدل در زبان های مختلف رفتار یکسان و قابل اعتمادی دارد یا نه.

لینک دیتاست: <https://huggingface.co/datasets/google/xquad>

۳. بخش های اصلی تمرین

در این تمرین باید دو روش را پیاده سازی و مقایسه کنید.

۳.۱ Direct Baseline

در این روش، مدل مستقیماً با دریافت context و question پاسخ می دهد.

۳.۲ Modular Pipeline

در این روش، سیستم به چند ماژول تقسیم می شود. ماژول اول Generator نام دارد. مدل ابتدا یک پاسخ اولیه تولید می کند. سپس Verifier مدل یا همان pipeline بررسی می کند که آیا پاسخ اولیه با context سازگار است یا نه. در نهایت Reviser اگر verifier تشخیص دهد پاسخ اولیه مشکل دارد، پاسخ نهایی اصلاح را میکند. خروجی verifier باید مشخص کند که پاسخ اولیه Supported، Unsupported یا Uncertain است. هدف از سیستم ماژولار این است که بررسی کنیم آیا اضافه کردن verifier و reviser باعث بهتر شدن کیفیت پاسخ و توضیح مدل می شود یا نه.

۳.۳ معیارهای ارزیابی

در این تمرین باید حداقل معیارهای Exact Match (بررسی می کند که آیا پاسخ مدل دقیقاً با پاسخ صحیح دیتاست برابر است یا نه)، Token-level F1 (پاسخ مدل و پاسخ صحیح را در سطح token مقایسه می کند. این معیار نسبت به Exact Match انعطاف پذیرتر است)، Fuzzy Match (برای مقایسه تقریبی رشته ها استفاده می شود، مخصوصاً وقتی پاسخ مدل از نظر نوشتاری کمی با پاسخ صحیح تفاوت دارد)،

Evidence Faithfulness (بررسی می‌کند که آیا evidence ارائه شده توسط مدل واقعاً در context وجود دارد یا نه)، Explanation Faithfulness (بررسی می‌کند که آیا explanation مدل به پاسخ و context مرتبط است یا نه)، Language Fairness / Language Bias Metrics (در این تمرین، bias از زاویه اختلاف عملکرد مدل بین زبان‌ها بررسی می‌شود. اگر مدل در انگلیسی عملکرد بسیار بهتری نسبت به زبان‌های دیگر داشته باشد، این می‌تواند نشانه‌ای از language-based performance disparity باشد)، Cross-lingual Consistency (چون XQuAD شامل نمونه‌های موازی در چند زبان است، باید بررسی کنید که آیا مدل برای یک سؤال مشابه در زبان‌های مختلف رفتار مشابه دارد یا نه).

۳.۴. سوالات تئوری

مقاله HELM چه ارتباطی با این تمرین دارد؟

چرا ارزیابی مدل‌های زبانی فقط با accuracy کافی نیست؟

آیا سیستم modular نسبت به direct baseline بهتر عمل کرد؟

آیا verifier باعث بهتر شدن faithfulness توضیح‌ها شد؟

کدام زبان ضعیف‌ترین عملکرد را داشت؟

آیا مدل در انگلیسی بهتر از زبان‌های غیرانگلیسی عمل کرد؟

آیا اختلاف عملکرد بین زبان‌ها می‌تواند نوعی bias یا مسئله اخلاقی محسوب شود؟

استفاده از یک مدل واحد به عنوان generator و verifier چه محدودیت‌هایی دارد؟

جزئیات کامل پیاده سازی هر بخش و توضیحات مربوط به نحوه انجام دقیق تمرین در دفترچه دانشجویان که به پیوست این فایل قرار دارد توضیح داده شده است. لطفاً تمامی نکات مطرح شده در دفترچه را به صورت کامل انجام و پیگیری کنید.

تمرین دوم: مدل های بینایی-زبانی (VLMs)

۱. مقدمه و هدف تمرین

در این تمرین، هدف آشنایی با معماری، ارزیابی و تنظیم دقیق مدل های زبانی چندوجهی (Vision-Language Models) است. برخلاف مدل های زبانی بزرگ (Large Language Models)، VLM ها قادرند اطلاعات بصری و متنی را به صورت همزمان پردازش کرده و به سؤالات مبتنی بر تصویر پاسخ دهند. در این تمرین، شما استنتاج Zero-shot، تأثیر رزولوشن تصویر بر کارایی مدل، و همچنین روش های تنظیم دقیق کارآمد (PEFT) را بررسی خواهید کرد.

در این تمرین باید از دیتاست ScienceQA استفاده شود. این دیتاست شامل سؤالات چندگزینه ای علمی است که برای پاسخ گویی به آن ها، درک همزمان متن سؤال و تصویر ضمیمه شده الزامی است. این ویژگی باعث می شود ScienceQA بستر مناسبی برای سنجش توانایی استدلال چندوجهی مدل ها باشد.

در این تمرین، از مدل Qwen/Qwen3.5-0.8B استفاده خواهد شد. در تمام طول این تمرین، مدل باید در حالت Non-Thinking Mode (حالت Instruct) قرار گیرد تا خروجی ها بدون مکانیزم استدلال درونی ارزیابی شوند. در گزارش نهایی باید توضیح دهید که تغییر رزولوشن تصاویر چه تأثیری بر سرعت و دقت مدل دارد و استفاده از روش هایی مانند LoRA چه تأثیری بر پاسخگویی مدل می گذارد.

۲. بخش های اصلی

در این تمرین باید یک خط لوله (Pipeline) کامل شامل سه بخش زیر را پیاده سازی و تحلیل کنید:

۲.۱. استنتاج پایه و تحلیل توکن ها

در این بخش، مدل پایه بارگذاری شده و استنتاج Zero-shot روی چند نمونه از داده ها انجام می شود. همچنین باید نحوه ترکیب توکن های تصویری و متنی در ورودی مدل بررسی شده و تعداد آن ها محاسبه شود.

۲.۲. ارزیابی کارایی و نقش رزولوشن

در این بخش، عملکرد مدل روی ۱۰۰ نمونه آزمایشی ارزیابی می‌شود. سپس، با استفاده از محدود کردن پیکسل‌های پردازنده تصویر (max_pixels)، مدل را مجبور می‌کنید تا تصاویر را با رزولوشن پایین‌تر پردازش کند. هدف این بخش مقایسه مستقیم دقت پاسخ‌ها در برابر زمان اجرای استنتاج در دو حالت High-Resolution و Low-Resolution است.

۲.۳. تنظیم دقیق با استفاده از LoRA

در این روش، مدل با استفاده از ۱۰۰۰ نمونه آموزشی و تنظیمات LoRA آموزش داده می‌شود. برای جلوگیری از خطای کمبود حافظه (OOM)، آموزش باید روی رزولوشن پایین و با تنظیم دقیق Gradient accumulation steps و... انجام شود. پس از آموزش، مدل دوباره روی داده‌های آزمایشی ارزیابی شده و با حالت پایه مقایسه می‌شود.

۳. سوالات تئوری

در نوت‌بوک سوالات، مجموعه‌ای از پرسش‌های تحلیلی و تئوری طراحی شده است که به بررسی چالش‌های معماری VLM، اثر رزولوشن بر دقت، مزایای تنظیم دقیق کارآمد و تحلیل رفتار مدل می‌پردازد. لازم است به این سوالات با دقت و براساس نتایج که از اجرای کدهای خود به دست آورده‌اید، پاسخ دهید.

شرح دقیق الزامات پیاده‌سازی و راهنمایی‌های لازم برای کدنویسی، مستقیماً در نوت‌بوک تمرین گنجانده شده است. انتظار می‌رود تمامی مراحل عملی را با دقت اجرا کرده و برپایه خروجی‌های به دست آمده، تحلیل‌های خواسته‌شده را ارائه دهید، برای انجام این تمرین، پاسخ دادن به سوالات کدنویسی و تحلیلی در خود نوت‌بوک به تنهایی کفایت می‌کند.