

گزارش تحلیلی اتصال Spark Apache به ClickHouse و StarRocks

پارامترهای ClickHouse

این بخش، گزینه‌های قابل تنظیم در دو مسیر رایج اتصال Spark-ClickHouse را پوشش می‌دهد: (الف) Connector Native Spark و (ب) Spark ClickHouse JDBC. خود این دو مسیر را به عنوان راه‌های اصلی معرفی کرده و Connector Spark را «مسیر پیشنهادی» دانسته است. [۷]

ClickHouse Spark Connector (DataSource V2)

گزینه‌های اتصال و مشخصات جدول در API TableProvider

جدول زیر از بخش TableProvider «Table و Options» Connection «Table و Options» Creation در مستندات رسمی ClickHouse Spark Connector استخراج شده است. [۸]

array

پارامتر	محدوده	نوع/مقادیر قابل قبول	پیش فرض	محل تنظیم	توضیح کاربرد
spark.clickhouse.ignoreUnsupportedTransform	Read/Write	bool	true	spark.conf/.option	نادیده گرفتن های transform پشتیبانی نشده (هشدار: اثر روی توزیع). [۱۲]
spark.clickhouse.read.compression.codec	Read	none/lz4	lz4	spark.conf/.option	کدک decompression داده هنگام خواندن. [۱۲]
spark.clickhouse.read.distributed.convertLocal	Read	bool	true	spark.conf/.option	خواندن local به جای Distributed. [۱۲]
spark.clickhouse.read.fixedStringAs	Read	binary/string	binary	spark.conf/.option	نگاشت FixedString به نوع Spark. [۱۲]
spark.clickhouse.read.format	Read	json/binary	json	spark.conf/.option	فرمت serialization برای Read. [۱۲]
spark.clickhouse.read.runtimeFilter.enabled	Read	bool	false	spark.conf/.option	فعال سازی filter. runtime [۱۲]
spark.clickhouse.read.splitByPartitionId	Read	bool	true	spark.conf/.option	ساخت فیلتر بر اساس __partition_id [۱۲]
spark.clickhouse.useNullableQuerySchema	عمدتاً Write	bool	false	spark.conf	همهٔ فیلدها nullable در CTAS/RTAS (وابسته به نسخه Spark). [۱۲]
spark.clickhouse.write.batchSize	Write	int	10000	spark.conf/.option	تعداد رکورد در هر batch نوشتن. [۱۲]
spark.clickhouse.write.compression.codec	Write	none/lz4	lz4	spark.conf/.option	کدک compression در نوشتن. [۱۲]
spark.clickhouse.write.distributed.convertLocal	Write	bool	false	spark.conf	نوشتن به local (مسئولیت sharding به Spark منتقل می شود). [۱۲]
spark.clickhouse.write.distributed.convertLocal.allowUnsupportedSharding	Write (ریسکی)	bool	false	spark.conf	اجازه sharding پشتیبانی نشده (خطر corrupt شدن داده). [۱۲]

پارامتر	محدوده	نوع/مقادیر قابل قبول	پیش فرض	محل تنظیم	توضیح کاربرد
spark.clickhouse.write.distributed.useClusterNodes	Write	bool	true	spark.conf	نوشتن به همه های node کلاستر. [۱۲]
spark.clickhouse.write.format	Write	json/arrow	arrow	spark.conf/.option	فرمت serialization در نوشتن. [۱۲]
spark.clickhouse.write.localSortByKey	Write	bool	true	spark.conf	sort محلی روی sort های key قبل از Write. [۱۲]
spark.clickhouse.write.localSortByPartition	Write	bool	وابسته	spark.conf	sort محلی به تفکیک partition (وابسته به تنظیم repartition) [۱۲]
spark.clickhouse.write.maxRetry	Write	int	3	spark.conf	سقف retry برای های batch خطا دار. [۱۲]
spark.clickhouse.write.retryInterval	Write	duration	10s	spark.conf	فاصله زمانی بین های retry. [۱۲]
spark.clickhouse.write.retryableErrorCodes	Write	list/int	241	spark.conf	کد (های) خطای ClickHouse که retry می شوند. [۱۲]
spark.clickhouse.write.repartitionByPartition	Write	bool	true	spark.conf	بازپارتیشن بندی مطابق partition های ClickHouse. [۱۲]
spark.clickhouse.write.repartitionNum	Write	int	0	spark.conf	تعداد پارتیشن هدف؛ مقدار <1 یعنی «الزامی نیست». [۱۲]
spark.clickhouse.write.repartitionStrictly	Write	bool	false	spark.conf	enforce سختگیرانه توزیع رکوردها بین پارتیشن ها. [۱۲]

پارامترهای Catalog API (پیکربندی سراسری Spark)

برای استفاده از Catalog، API نمونه پیکربندی در spark-defaults.conf یا SparkConf ارائه شده است (کلاس Catalog و host/protocol/port/user/db و همچنین option.ssl) [۱۳]

نمونه کلیدها (خلاصه):

- spark.sql.catalog.<name>=com.clickhouse.spark.ClickHouseCatalog
- spark.sql.catalog.<name>.host ، spark.sql.catalog.<name>.protocol ، spark.sql.catalog.<name>.http_port ، spark.sql.catalog.<name>.user ، spark.sql.catalog.<name>.password ، spark.sql.catalog.<name>.database

- spark.sql.catalog.<name>.option.ssl (و سایر option.<key> برای settings پاس دادنی) [۱۴]

JDBC Spark با ClickHouse

در حالت Spark، JDBC دو لایه تنظیم دارید:

۱. گزینه‌های استاندارد JDBC Spark (برای Read/Write). [۶]
۲. پارامترهای JDBC URL/Properties مخصوص ClickHouse JDBC Driver و Client. Java [۱۵]

گزینه‌های استاندارد JDBC DataSource در Spark

این جدول از مستندات رسمی Spark (صفحهٔ JDBC DataSource Options) استخراج شده است. [۱۶]

پارامتر	محدوده	نوع/مقادیر قابل قبول	پیش فرض	توضیح کاربرد
url	Read/Write	JDBC URL	ندارد	آدرس اتصال JDBC (می‌تواند شامل properties connection باشد). [۱۷]
dbtable	Read/Write	نام جدول یا subquery	ندارد	جدول هدف (یا؛ subquery همزمان با query مجاز نیست). [۱۷]
query	Read	SQL query	ندارد	خواندن بر اساس query با dbtable و partitionColumn همزمان مجاز نیست. [۱۸]
prepareQuery	Read	SQL prefix	ندارد	پیشوندی که قبل از query اجرا می‌شود. [۱۹]
driver	Read/Write	کلاس Driver	ندارد	مثلاً com.clickhouse.jdbc.ClickHouseDriver. [۲۰]
partitionColumn+lowerBound+upperBound	Read	عدد/تاریخ/زمان	ندارد	پارتیشن‌بندی خواندن موازی (هر سه با هم و همراه numPartitions). [۲۱]
numPartitions	Read/Write	int	ندارد	سقف parallelism و تعداد های connection. JDBC. [۲۲]
queryTimeout	Read/Write	int ثانیه	0	timeout اجرای statement؛ یعنی نامحدود. [۲۳]
fetchsize	Read	int	0	تعداد ردیف در هر trip round برای fetch. [۲۴]
batchsize	Write	int	1000	تعداد ردیف در هر batch JDBC insert. [۲۴]

پارامتر	محدوده	نوع/مقادیر قابل قبول	پیش فرض	توضیح کاربرد
isolationLevel	Write	enum	UNCOMMITTED	سطح ایزولاسیون تراکنش JDBC (وابسته به DB) [۲۵]
sessionInitStatement	Read	SQL/PLSQL	ندارد	اجرای statement هنگام شروع session برای init. [۲۶]
truncate	Write	bool	false	در Overwrite به جای drop/create از truncate استفاده کند. [۲۷]
cascadeTruncate	Write	bool	وابسته به DB	truncate با CASCADE در های DB پشتیبان؛ بررسی. [۲۷]
createTableOptions	Write	string	خالی	ضمایم DB-specific هنگام CREATE TABLE. [۲۸]
createTableColumnTypes	Write	string	ندارد	override نوع ستون ها هنگام CREATE TABLE. [۲۹]
customSchema	Read	string	ندارد	override نوع ستون ها در schema خواندن. [۳۰]
pushDownPredicate	Read	bool	true	فعال/غیرفعال predicate. pushdown. [۳۱]
pushDownAggregate	Read	bool	true	pushdown aggregate (V2). [۳۲]
pushDownLimit	Read	bool	true	pushdown LIMIT/TopN (V2). [۳۳]
pushDownOffset	Read	bool	true	pushdown OFFSET (V2). [۳۴]
pushDownTableSample	Read	bool	true	pushdown TABLESAMPLE (V2). [۳۵]
keytab	Read/Write	مسیر فایل	ندارد	اگر keytab و principal ست شوند، Spark تلاش به Kerberos می کند. [۳۶]
principal	Read/Write	principal Kerberos	ندارد	همراه keytab. [۳۶]
refreshKrb5Config	Read/Write	bool	false	refresh تنظیمات Kerberos قبل از اتصال جدید (هشدار. race-condition). [۳۷]
connectionProvider	Read/Write	نام provider	ندارد	انتخاب provider اتصال. JDBC. [۳۸]
preferTimestampNTZ	Read	bool	false	نحوه تفسیر TIMESTAMP WITHOUT TIME ZONE. [۳۷]
hint	Read	/*+ ... */	ندارد	hint برای خواندن (برای برخی. (ها dialect. [۳۷]

پارامترهای اختصاصی Client Java و Driver JDBC ClickHouse

نحو URL و Class Driver در مستندات رسمی Driver JDBC ClickHouse آمده است (از جمله شکل jdbc:(ch|clickhouse)[:<protocol>]://endpoint... [۳۹]).
Driver properties اختصاصی (خارج از Java Client) طبق docs:

- disable_frameworks_detection (پیش فرض true)
- jdbc_ignore_unsupported_values (پیش فرض false)
- clickhouse.jdbc.v1 (پیش فرض false)
- default_query_settings (پیش فرض null)
- jdbc_resultset_auto_close (پیش فرض true)
- beta.row_binary_for_simple_insert (پیش فرض false)
- jdbc_use_max_result_rows (پیش فرض false)
- jdbc_sql_parser (پیش فرض JAVACC و گزینه‌های دیگر) [۳۹]

پارامترهای SSL/TLS در Driver JDBC (طبق بخش Connect «): with ClickHouse to SSL»:

- ssl (پیش فرض false)
- sslmode (پیش فرض strict و مقادیر strict/none)
- key_store_password، trust_store، key_store_type، sslkey، sslcert، sslrootcert [۴۰]

(JDBC Driver) Timeouts: مستندات رسمی تصریح می‌کند که مقادیر پیش فرض برای socket timeout و connection timeout برابر ۳۰ ثانیه است. همچنین نمونه‌ای از استفاده از socket_timeout در URL اتصال نیز ارائه شده است. [۴۱]

کلیدهای مهم Java Client: طبق مستندات ClickHouse، پارامترهای اصلی در Java Client تعریف می‌شوند و باید به JDBC Driver ارسال شوند. [۴۲] در ادامه، نمونه‌هایی از این کلیدها و مقادیر پیش فرض آنها آورده شده است:

- pool/endpoint: Connection ،connection_pool_enabled=true ،max_open_connections=10 ،connection_ttl=-1 و ... [۴۳]
- Auth: user (پیش فرض default) ،password ،access_token و تنظیمات auth.basic/bearer [۴۴]
- Timeouts: retry: ،connection_timeout ،connection_request_timeout=10000 ،socket_timeout=0 ،max_execution_time=0 ،retry=3 و ... [۴۵]
- Socket: options: ،socket_rcvbuf=8196 ،socket_sndbuf=8196 ،socket_keepalive ،socket_tcp_nodelay ،socket_linger [۴۶]
- Compression: ،compress=true ،decompress=false ،compression.lz4.uncompressed_buffer_size=65536 و ... [۴۷]
- SSL/Security: ،trust_store ،sslrootcert ،sslcert ،ssl_key ،ssl_socket_sni و ... [۴۸]
- Server pass-through settings و HTTP headers از طریق serverSetting(...) یا کلیدهای .دارprefix [۴۹]

نکته ثانویه (غیر): Reference) در یک پست رسمی وبلاگ ClickHouse دربارهٔ Glue نمونه‌ای از استفاده از های option batchsize ،socket_timeout ،connection_t imeout در مسیر writeTo(...) ارائه شده است. چون این نام‌ها در صفحهٔ reference کانکتور Spark به صورت صریح در جدول options لیست نشده‌اند، بهتر است آنها را «قابل استفاده طبق مثال رسمی وبلاگ» در نظر بگیرید، نه «گزینه‌های لیست شدهٔ رسمی کانکتور». [۵۰]

پارامترهای StarRocks

StarRocks دو سند رسمی جداگانه برای Read و Write از طریق Connector Spark دارد. [۵۱] در Write، اصولاً داده در حافظه جمع می‌شود و سپس با LOAD STREAM به StarRocks بارگذاری می‌گردد و کانکتور بر پایه DataSource ۷۲ معرفی شده است. [۵۲]

Read برای Connector Spark StarRocks

جدول زیر از بخش «Parameters» در سند رسمی Read استخراج شده است. [۵۳]

پارامتر	محدوده	نوع/مقادیر قابل قبول	پیش فرض	توضیح کاربرد
starrocks.fenodes	Read	host:port یا لیست با ،	ندارد	آدرس HTTP FE برای خواندن؛ چند FE قابل تعریف. [۵۴]
starrocks.fe.http.url	Read	مانند بالا	ندارد	معادل جدید starrocks.fenodes در ۰۰.۱۰.۱+ (پیشنهادی). [۵۵]
starrocks.fe.jdbc.url	Read	jdbc:mysql://<fe_host>:<fe_query_port>	ندارد	اتصال JDBC به MySQL روی FE برای متادیتا؛ از ۰۰.۱۰.۱+ «اجباری» ذکر شده است. [۵۵]
starrocks.table.identifier	Read	<db>.<table>	ندارد	جدول مبدأ برای خواندن. [۵۴]
user/starrocks.user	Read	string	ندارد	نام کاربری (دو نام قدیم/جدید؛ جدید توصیه شده). [۵۵]
password/starrocks.password	Read	string	ندارد	رمز عبور (دو نام قدیم/جدید؛ جدید توصیه شده). [۵۵]
starrocks.request.retries	Read	int	3	حداکثر retry برای های request خواندن. [۵۴]
starrocks.request.connect.timeout.ms	Read	ms	30000	timeout برقراری اتصال. [۵۴]
starrocks.request.read.timeout.ms	Read	ms	30000	timeout خواندن پاسخ. [۵۴]
starrocks.request.query.timeout.s	Read	ثانیه یا -1	3600	timeout اجرای query؛ -1 یعنی بدون محدودیت. [۵۴]
starrocks.request.tablet.size	Read	int	tablets per MAX_VALUE در هر پارتیشن RDD؛ کوچکتر parallelism بیشتر	ولی فشار بیشتر روی StarRocks. [۵۴]
starrocks.batch.size	Read	int	4096	rows max در هر fetch از BE. [۵۶]
starrocks.exec.mem.limit	Read	بایت	2147483648	محدودیت RAM برای هر query. [۵۶]
starrocks.deserialize.arrow.async	Read	bool	false	تبدیل ArrowRowBatch به صورت async. [۵۶]
starrocks.deserialize.queue.size	Read	int	64	سایز صف داخلی برای deserialize. async. [۵۶]
starrocks.filter.query	Read	شرط SQL	ندارد	فیلتر سمت StarRocks قبل از ورود به Spark. [۵۶]
starrocks.filter.query.in.max.count	Read	int	100	حد بیشینه مقادیر IN برای pushdown. [۵۵]
starrocks.timezone	Read	TZ/offset	JVM timezone	تبدیل DATETIME به TimestampType در Spark (از ۱۰.۱۰.۱). [۵۶]
starrocks.request.auth.user	Read (RDD)	string	ندارد	auth برای مسیر RDD. [۵۵]

پارامتر	محدوده	نوع/مقادیر قابل قبول	پیش فرض	توضیح کاربرد
starrocks.request.auth.password	Read (RDD)	string	ندارد	auth برای مسیر RDD. [۵۵]
starrocks.read.field	Read (RDD)	لیست ستون‌ها با ،	ندارد	تعیین ستون (های) خواندنی در مسیر RDD. [۵۵]

Write برای Connector Spark StarRocks

جدول زیر از بخش «Parameters» در سند رسمی Write استخراج شده است. [۵۷]

پارامتر	محدوده	نوع/مقادیر قابل قبول	پیش فرض	توضیح کاربرد
starrocks.fe.http.url	Write	<fe_host>: <fe_http_port> (چندتایی با ،)	ندارد	FE URL HTTP (برای Stream). Load/کنترل [۵۸]
starrocks.fe.jdbc.url	Write	jdbc:mysql://<fe_host>:<fe_query_port> <db>.<table>	ندارد	JDBC برای متادیتا/کنترل؛ Required. [۵۹]
starrocks.table.identifier	Write	string	ندارد	جدول مقصد. [۵۸]
starrocks.user	Write	string	ندارد	نام کاربری (نیازمند SELECT و INSERT). [۵۹]
starrocks.password	Write	string	ندارد	رمز عبور. [۵۹]
starrocks.write.label.prefix	Write	string	spark-	پیشوند label برای Load Stream (ردگیری/idempotency). [۵۹]
starrocks.write.enable.transaction-stream-load	Write	bool	TRUE	استفاده از load stream transaction (نیازمند StarRocks +۵)؛ ۷۲۰ از ۱۰۱۰۱ فقط وقتی starrocks.write.max.retries<=0 اثر دارد. [۶۰]
starrocks.write.buffer.size	Write	بایت	104857600	سقف حجم buffer قبل از ارسال هر batch. [۵۹]
starrocks.write.buffer.rows	Write	int	Integer.MAX_VALUE	تعداد ردیف در buffer قبل از flush (از ۱۰۱۰۱). [۵۹]
starrocks.write.flush.interval.ms	Write	ms	300000	interval ارسال داده (کنترل). (latency) [۵۹]

پارامتر	محدوده	نوع/مقادیر قابل قبول	پیش فرض	توضیح کاربرد
starrocks.write.max.retries	Write	int	3	تعداد retry برای Load Stream یک batch اگر مثبت باشد
starrocks.write.retry.interval.ms	Write	ms	10000	transaction-stream-load نادیده گرفته می شود. [۶۱] فاصله retry برای همان batch. [۶۱]
starrocks.columns	Write	لیست ستون ها با ،	ندارد	ستون های مقصدی که داده باید در آنها load شود. [۶۱]
starrocks.column.types	Write	string schema	ندارد	override نوع ستون ها (مثل BITMAP/HLL (از ۱۰۱۰۱). [۶۲]
starrocks.write.properties.*	Write	وابسته به headers	ندارد	پاس دادن مستقیم پارامترهای Load Stream (مثل format/timeout/...). [۶۳]
starrocks.write.properties.format	Write	CSV/JSON	CSV	فرمت سریال سازی batch قبل از ارسال. [۶۲]
starrocks.write.properties.row_delimiter	Write	string	\n	جداکننده سطر برای CSV. [۶۲]
starrocks.write.properties.column_separator	Write	string	\t	جداکننده ستون برای CSV. [۶۴]
starrocks.write.properties.partial_update	Write	TRUE/FALSE	FALSE	فعال سازی update. partial [۶۵]
starrocks.write.properties.partial_update_mode	Write	row/column	row	حالت update. partial [۶۵]
starrocks.write.num.partitions	Write	int	default Spark	تعداد پارتیشن های Spark برای نوشتن موازی. [۶۶]
starrocks.write.partition.columns	Write	لیست ستون ها	ندارد	ستون های partitioning در Spark فقط وقتی num.partitions ست شود اثر دارد. [۶۷]
starrocks.timezone	Write	TZ/offset	JVM timezone	تبدیل Spark TimestampType به DATETIME در StarRocks (از ۱۰۱۰۱). [۶۷]

پارامترهای Load Stream که از طریق starrocks.write.properties.* قابل پاس دادن هستند

از آنجا که کانکتور صراحتاً می گوید starrocks.write.properties.* برای کنترل رفتار Load Stream است و به سند LOAD STREAM ارجاع می دهد، برای «فهرست کاملی پارامترهای مهم Stream Load» باید به همان سند رجوع کرد. [۶۳] در ادامه، پارامترهایی که در LOAD STREAM به عنوان /merge-committopt_propertiesheader/ معرفی شده اند آورده می شود (اینها را معمولاً به شکل starrocks.write.properties.<name>=... به کانکتور می دهید).

پارامترهای format و data-desc (مهم برای CSV/JSON)

LOAD STREAM پارامترهایی مانند format، column_separator، row_delimiter، columns، partitions، jsonpaths، strip_outer_array، json_root، compression، ignore_json_size را به عنوان های data_desc header لیست می کند. [۶۸]

پارامتر Load Stream	نوع/مقادیر	پیش فرض	توضیح کاربرد
format	CSV/JSON	CSV	فرمت داده ورودی Load. Stream [۶۹]
column_separator	string	\t	جداکننده ستون در CSV. [۶۹]
row_delimiter	string	\n	جداکننده سطر در CSV. [۷۰]
columns	string	ندارد	نگاشت/تبدیل ستون ها (می تواند mapping/expression داشته باشد). [۶۹]
partitions	فهرست پارتیشن ها	ندارد	بارگذاری فقط به پارتیشن های مشخص. [۶۹]
temporary_partitions	فهرست temporary partitions	ندارد	بارگذاری به temporary. partition ها [۶۹]
jsonpaths	آرایه مسیرهای JSON	ندارد	تعیین مسیرهای JSON برای استخراج. [۷۰]
strip_outer_array	true/false	ندارد	برای JSON، array حذف array. outer [۷۰]
json_root	string	ندارد	ریشه JSON برای parsing. [۷۰]
ignore_json_size	true/false	ندارد	کنترل رفتار نسبت به محدودیت های size در JSON. [۷۰]
compression/Content-Encoding	الگوریتم های فشرده سازی	ندارد	فشرده سازی داده ارسالی (طبق docs). [۷۰]

پارامترهای opt_properties (کنترل رفتار کل job)

LOAD، STREAM لیست opt_properties را شامل label، where، max_filter_ratio، timeout، strict_mode، timezone، load_mem_limit، merge_condition، partial_update_mode، partial_update معرفی می‌کند. [۷۱]

پارامتر	نوع/مقادیر	پیش فرض	توضیح کاربرد
label	string	auto-generated	برچسب یگنا برای جلوگیری از بارگذاری تکراری/ردگیری. [۷۲]
where	شرط SQL	ندارد	فیلتر داده پس از pre-process و قبل از load. [۷۲]
max_filter_ratio	num	(طبق docs)	تحمل خطا/نسبت ردیف‌های فیلترشده. [۷۳]
timeout	1..259200 ثانیه	600	job timeout (برای load). [۷۴]
strict_mode	true/false	false	mode strict برای خطاهای تبدیل داده. [۷۴]
timezone	TZ/offset	ندارد	timezone برای parsing/conversion زمان. [۷۵]
load_mem_limit	عدد	ندارد	محدودیت حافظه برای job. load [۷۶]
partial_update	true/false	ندارد	فعال سازی partial. update. [۷۶]
partial_update_mode	row/column	ندارد	تعیین partial mode. update. [۷۶]
merge_condition	نام ستون	ندارد	شرط merge در سناریوهای خاص. [۷۶]

Merge Commit (تراکنش تجمعی برای چند Load Stream همزمان)

LOAD STREAM از ۳۰۰۰۴ مفهوم Merge Commit را معرفی می‌کند که چند درخواست همزمان را در یک «تراکنش واحد» merge می‌کند و پارامترهایی مانند enable_merge_commit، _merge_commit، merge_commit_async، merge_commit_interval_ms، merge_commit_parallel دارد. [۷۷]

پارامتر	نوع/مقادیر	پیش فرض	توضیح کاربرد
enable_merge_commit	true/false	false	فعال سازی Merge Commit برای ادغام چند Load Stream در یک تراکنش. [۷۸]
merge_commit_async	true/false	false	async سریع تر اما بدون تضمین موفقیت در لحظه پاسخ؛ sync هدفش commit و قابل مشاهده شدن است. [۷۸]

پارامتر	نوع/مقادیر	پیش فرض	توضیح کاربرد
merge_commit_interval_ms	int ms	required	پنجره زمانی ادغام؛ بزرگتر از ادغام بهتر اما latency بیشتر. [۷۸]
merge_commit_parallel	int	required	درجه parallelism برای plan هر پنجره (با تعداد BE محدود می شود). [۷۸]

امنیت و TLS در StarRocks (مرتبط با اتصال کانکتورها)

StarRocks مستند می کند که از ۳۰۱۰۴ به بعد «SSL encrypted» connections را پشتیبانی می کند. [۷۹] در پیکربندی FE نیز پارامترهای enable_https (پیش فرض false) و https_port (پیش فرض 8443) از ۷۴۰۰ معرفی شده اند. [۸۰]

در سند Spark Connector، پارامترهای اتصال FE با عنوان «HTTP» URL شرح داده شده اند و نمونه صریحی برای https:// در همان صفحه نداریم؛ بنابراین برای استفاده از HTTPS باید به تنظیمات سطح کلاستر/FE و سازگاری ابزارها تکیه شود (بدون فرض قطعی در این متن). [۸۱]

جداول مقایسه ای پارامترهای متناظر StarRocks و ClickHouse

در این بخش، پارامترهای متناظر را «دسته بندی شده» کنار هم می بینید. هر جدول بر اساس مستندات رسمی دو سیستم ساخته شده است. [۸۲]

اتصال و احراز هویت

نیاز/مفهوم	ClickHouse (Spark Connector)	StarRocks (Spark Connector)	نکته
FE/Host اصلی	host+http_port+protocol [۸]	starrocks.fe.http.url [۵۸]	StarRocks می تواند چند FE را
دیتابیس/جدول	database, table [۸]	starrocks.table.identifier [۵۸]	comma-separated بگیرد. [۵۸] db StarRocks و table را در یک کلید می دهد.

نیاز/مفهوم	ClickHouse (Spark Connector)	StarRocks (Spark Connector)	نکته
کاربر/رمز	user,password [۸]	starrocks.user,starrocks.password [۵۹]	در StarRocks، Read نام‌های قدیم user/password هم alias هستند. [۵۵]
متادیتا با JDBC	در connector، تنظیمات ClickHouse settings (جداست) [۸۳]	starrocks.fe.jdbc.url (اجباری از ۰۰۱۰۱+) [۸۴]	StarRocks برای متادیتا به MySQL JDBC نیاز دارد و driver باید اضافه شود (محدودیت GPL ذکر شده). [۸۵]

عملکرد، موازی‌سازی و بافر/Batch

مفهوم	ClickHouse	StarRocks	توضیح
Batch size نوشتن	spark.clickhouse.write.batchSize [۱۲]	starrocks.write.buffer.size و starrocks.write.buffer.rows + flush.interval.ms [۵۹]	ClickHouse batch را بر حسب «تعداد رکورد» تعریف می‌کند؛ StarRocks هم حجم/هم تعداد/هم interval دارد. تفاوت در semantics/format مهم است.
فرمت انتقال	spark.clickhouse.write.format (arrow/json) [۱۲]	starrocks.write.properties.format (CSV/JSON) [۶۲]	
موازی‌سازی write	spark.clickhouse.write.repartitionBy Partition و repartitionNum [۱۲]	starrocks.write.num.partitions و starrocks.write.partition.columns [۶۷]	هر دو روی «همزمانی» write اثر دارند (مکانیزم متفاوت).
خواندن batch	spark.clickhouse.read.format و codec [۱۲]	starrocks.batch.size [۵۶]	StarRocks صریحاً rows-per-fetch از BE را تنظیم می‌کند.

Consistency / Retry / Timeout

مفهوم	ClickHouse	StarRocks	نکته
Retry در write	spark.clickhouse.write.maxRetry retryableErrorsCodes، retryInterval [۱۲]	starrocks.write.max.retries starrocks.write.retry.interval.ms [۶۱]	در StarRocks اگر retry مثبت باشد، کانکتور از transaction-stream-load استفاده نمی کند. [۶۱]
تراکنش/Exactly-once	ClickHouse بیشتر روی retry و routing distributed تمرکز دارد [۱۲]	starrocks.write.enable.transaction-stream-load Transaction Interface + eam-load (2PC) [۶۰]	StarRocks semantics دقیق تر را هدف می گیرد. [۸۶]
Timeouts سطح client	در client: JDBC/Java socket_timeout و connection_timeout ... [۸۷]	Read: starrocks.request.*timeout* و در Load: Stream timeout header [۸۸]	StarRocks هم read-timeout در connector دارد و هم write-timeout در Load. Stream

امنیت (TLS/Kerberos)

مفهوم	ClickHouse	StarRocks	نکته
TLS در کانکتور	ssl، ssl_mode، protocol=https [۹]	سطح کلاستر: enable_https، https_port و SSL Authentication [۸۹]	کانکتور StarRocks صریحاً مثال https:// را کم تر نشان داده، ولی خود سیستم SSL/HTTPS را پوشش می دهد. [۸۱]
TLS در JDBC	JDBC: ClickHouse sslmode، sslrootcert ... [۹۰]	(بسته به driver، MySQL/... از فرض جزئیات driver اختصاصی خودداری شده) همان (اگر driver مقصد پشتیبانی کند)	—
Kerberos	JDBC: Spark principal، keytab refreshKrb5Config [۹۱]		در اسناد Spark Connector این دو، Kerberos به عنوان option کانکتور لیست نشده؛ عمدتاً سطح JDBC Spark است. [۹۲]

[1] [4] [7] Integrating Apache Spark with ClickHouse | ClickHouse Docs
<https://clickhouse.com/docs/integrations/apache-spark>

[2] [3] [5] [51] [53] [54] [55] [56] [84] [85] [88] [100] [101] Read data from StarRocks using Spark connector | StarRocks
https://docs.starrocks.io/docs/unloading/Spark_connector/

[6] [16] [17] [18] [19] [20] [21] [22] [23] [24] [25] [26] [27] [28] [29] [30] [31] [32] [33] [34] [35] [36] [37] [38] [91] [92]
<https://spark.apache.org/docs/latest/sql-data-sources-jdbc.html>

[8] [9] [10] [11] [12] [13] [14] [82] [83] [93] [95] [96] Spark Connector | ClickHouse Docs
<https://clickhouse.com/docs/integrations/apache-spark/spark-native-connector>

[15] [39] [40] [41] [42] [90] JDBC Driver | ClickHouse Docs
<https://clickhouse.com/docs/integrations/language-clients/java/jdbc>

[43] [44] [45] [46] [47] [48] [49] [87] Java Client | ClickHouse Docs
<https://clickhouse.com/docs/integrations/language-clients/java/client>

[50] Announcing the ClickHouse Connector for AWS Glue
https://clickhouse.com/blog/clickhouse-connector-aws-glue?utm_source=chatgpt.com

[52] [57] [58] [59] [60] [61] [62] [63] [64] [65] [66] [67] [81] [94] [98] [99]
<https://docs.starrocks.io/docs/loading/Spark-connector-starrocks/>

[68] [69] [70] [71] [72] [73] [74] [75] [76] [77] [78]
https://docs.starrocks.io/docs/sql-reference/sql-statements/loading_unloading/STREAM_LOAD/

[79]
https://docs.starrocks.io/docs/administration/user_privs/ssl_authentication/

[80] [89]
https://docs.starrocks.io/docs/administration/management/FE_configuration/

[86]
https://docs.starrocks.io/docs/loading/Stream_Load_transaction_interface/

[97] Spark JDBC | ClickHouse Docs

<https://clickhouse.com/docs/integrations/apache-spark/spark-jdbc>