




دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی برق و کامپیوتر
گروه مهندسی کامپیوتر



حقیقت‌سنجی ادعاهای جدید در مدل‌های زبانی بزرگ با کمک سوگیری‌های شناختی

پروژه کارشناسی مهندسی کامپیوتر گرایش نرم‌افزار


محمد امانلو

استاد راهنما

دکتر محمدرضا ابوالقاسمی دهاقانی

شهریور ۱۴۰۵





دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی برق و کامپیوتر
گروه مهندسی کامپیوتر



حقیقت‌سنجی ادعاهای جدید در مدل‌های زبانی بزرگ با کمک سوگیری‌های شناختی

پروژه کارشناسی مهندسی کامپیوتر گرایش نرم‌افزار

محمد امانلو

استاد راهنما

دکتر محمدرضا ابوالقاسمی دهاقانی

شهریور ۱۴۰۵

تعهدنامه اصالت اثر

باسمه تعالی

اینجانب محمد امانلو تأیید می‌کنم که مطالب مندرج در این پروژه حاصل کار پژوهشی اینجانب است و به دستاوردهای پژوهشی دیگران که در این نوشته از آن‌ها استفاده شده است مطابق مقررات ارجاع گردیده است. این پروژه قبلاً برای احراز هیچ مدرک هم‌سطح یا بالاتری ارائه نشده است.

نام و نام خانوادگی دانشجو: محمد امانلو

تاریخ و امضای دانشجو:

کلیه حقوق مادی و معنوی این اثر
متعلق به دانشگاه تهران است.

چکیده

مدل‌های زبانی بزرگ پاسخ‌هایی روان و متقاعدکننده تولید می‌کنند، اما این توانایی لزوماً به قضاوت مبتنی بر واقعیت، به‌ویژه درباره‌ی ادعاهای جدید، منجر نمی‌شود. این پایان‌نامه حقیقت‌سنجی بسته‌ی ادعاها را از منظر تعمیم زمانی بررسی می‌کند و عملکرد مدل‌ها را در دو رژیم عملیاتی *seen* و *unseen* می‌سنجد. این دو اصطلاح فقط به قرارگرفتن ادعا در دو سوی مرز زمانی ثبت‌شده‌ی هر اجرا اشاره دارند و ادعایی قطعی درباره‌ی حضور یا نبود نمونه در داده‌های پیش‌آموزش نیستند. محور دوم پژوهش، سنجش اثر افزودن نشانه‌های متنی سوگیری شناختی به پرامپت حقیقت‌سنج است. برای تولید این نشانه‌ها، یک آشکارساز ۷۲ کلاسه‌ی مبتنی بر DeBERTa-v3 روی MindScope تنظیم دقیق شد و در آزمون به دقت ۲۰/۹۸ درصد و Macro-F1 برابر ۱۵/۹۸ درصد رسید. سپس سه راهبرد Naive، Strong، Bias-aware روی پنج پیکره و چند خانواده‌ی مدل مقایسه شدند. تحلیل اصلی زمانی بر ۱۱ مطالعه‌ی کامل مدل-پیکره و تحلیل مستقیم مداخله بر ۴۲۰۱۰ زوج *unseen* استوار بود. دقت، Macro-F1، شکاف زمانی، آزمون مکنمار، بوت‌استرپ زوجی، تصحیح Holm، گذارهای Fixed/Broke، اثر تک‌سوگیری و تغییر توزیع برچسب به‌طور هم‌زمان بررسی شدند. در میانگین ۱۱ مطالعه، دقت Strong در *seen/unseen* به ترتیب ۲۸/۵۰ و ۸۹/۵۴ درصد بود و از دو راهبرد دیگر سطح عملکرد بالاتری داشت. Bias-aware دقت‌های ۳۱/۴۹ و ۷۴/۴۹ درصد را ثبت کرد و قدر مطلق شکاف زمانی را از ۶۱/۴ واحد درصد در Strong به ۴۳/۰ واحد درصد رساند، اما این برابری با افزایش توان روی ادعاهای جدید همراه نبود. در هسته‌ی زوجی، دقت Strong و Bias-aware به ترتیب ۶۰/۸ و ۵۸/۰ بود؛ مداخله ۴۰۹ خطا را اصلاح و ۶۸۴ پاسخ درست را خراب کرد و آزمون مکنمار این عدم‌تقارن را معنادار نشان داد $p < ۰/۰۰۱$. پس از تصحیح چندآزمونی، فقط Bias Blind Spot و Curse of Knowledge اثر معنادار داشتند و هر دو منفی بودند. یافته‌ی محوری این است که رفع سوگیری پرامپتی می‌تواند خود یک سوگیری تصمیم تازه ایجاد کند: مداخله، بدون بهبود دقت کلی، مدل‌ها را به‌طور نظام‌مند به سوی پذیرش بیشتر ادعاها سوق داد. این الگوی رفتاری در این پژوهش Permissive Decision Shift و در سطح کلی‌تر «پارادوکس شناختی رفع سوگیری» نامیده می‌شود. با این حال، سقف Oracle با دقت ۶۴۷/۰ حدود ۹/۳ واحد درصد ظرفیت مکمل بودن دوروش را نشان داد. برآیند نتایج چهار دستاورد مفهومی را تثبیت می‌کند: تازگی زمانی با دشواری یکسان نیست؛ ناوردایی زمانی معادل صلاحیت زمانی نیست؛ رفع سوگیری پرامپتی می‌تواند یک سوگیری تصمیم تازه ایجاد کند؛ و دقت آشکارساز سوگیری، سود مداخله را تضمین نمی‌کند. بنابراین Strong مسیر پیش‌فرض مناسب‌تری است

و استفاده از اطلاعات شناختی باید به صورت انتخابی و بر پایه‌ی سود مورد انتظار همان ادعا انجام شود. این استنتاج‌ها رفتاری‌اند؛ اختلاف مرزهای عملیاتی با بعضی cutoff‌های مستند، تغییر ترکیب داده و نبود دسترسی یکنواخت به لاجیت و حالت‌های پنهان، تفسیر علی یا مکانیزمی مستقیم را محدود می‌کنند.

واژگان کلیدی حقیقت‌سنجی خودکار، مدل‌های زبانی بزرگ، تعمیم زمانی، ادعاهای جدید، سوگیری‌های شناختی، مداخله‌ی پرامپتی

فهرست مطالب

ت فهرست تصاویر

ج فهرست جداول

۱ فهرست اختصارات

۲ فصل ۱: مقدمه و بیان مسئله

۲ ۱-۱ مقدمه

۴ ۲-۱ تاریخچه و زمینه

۵ ۳-۱ شرح مسئله

۶ ۴-۱ تعریف موضوع

۷ ۵-۱ اهداف و پرسش‌ها

۸ ۶-۱ روش تحقیق

۹ ۷-۱ ساختار پایان‌نامه

۱۰ فصل ۲: مفاهیم اولیه و پیش‌زمینه

۱۰ ۱-۲ مقدمه

۱۱ ۲-۲ حقیقت‌سنجی خودکار و مدل‌های زبانی بزرگ

۱۳ ۳-۲ تعمیم زمانی، دانش پارامتری و تغییر توزیع

۱۶ ۴-۲ سوگیری‌های شناختی و نشانه‌های متنی

۱۷ ۵-۲ مداخله‌ی پرامپتی و اثر آن بر تصمیم LLM

۶-۲	معیارهای ارزیابی و استنباط آماری	۱۹
۷-۲	شکاف پژوهشی و چارچوب نظری پایان‌نامه	۲۰
۸-۲	جمع‌بندی	۲۲
فصل ۳: مدل‌سازی و طراحی چارچوب پژوهش		
۱-۳	مقدمه و صورت‌بندی مسئله	۲۳
۲-۳	طراحی کلی آزمایش و معماری دو فاز	۲۵
۳-۳	فاز نخست: آموزش و استفاده از آشکارساز سوگیری	۲۷
۴-۳	فاز دوم: پیکره‌های حقیقت‌سنجی، استانداردسازی و تفکیک زمانی	۲۹
۵-۳	طراحی سه راهبرد پرامپتی و مدل‌های مورد ارزیابی	۳۲
۶-۳	پروتکل اجرا، اعتبارسنجی خروجی و بازتولیدپذیری	۳۴
۷-۳	معیارهای ارزیابی و طرح تحلیل آماری	۳۶
۸-۳	جمع‌بندی	۴۱
فصل ۴: پیاده‌سازی، تحلیل اکتشافی و تحلیل عمیق نتایج		
۱-۴	داده، ممیزی و ساختار زمانی	۴۲
۲-۴	تحلیل اکتشافی و ارزیابی آشکارساز	۴۵
۳-۴	نتایج اصلی تعمیم زمانی	۴۶
۴-۴	مقایسه‌ی Naive، Strong و Bias-aware	۴۹
۵-۴	تحلیل آماری زوجی	۵۲
۶-۴	تحلیل تک‌سوگیری و تغییر جهت تصمیم	۵۳
۷-۴	مسیریابی و Oracle	۵۶
۸-۴	بحث: ناهمگنی و حدود تفسیر	۵۷
۹-۴	خلاصه	۵۸
فصل ۵: جمع‌بندی، نتیجه‌گیری و پیشنهادها		
۱-۵	جمع‌بندی و پاسخ نهایی به پرسش‌ها	۶۰

۶۲		۲-۵	دستاوردها و نوآوری‌ها
۶۳		۳-۵	محدودیت‌ها
۶۴		۴-۵	پیشنهادها برای ادامه‌ی پژوهش
۶۶		۵-۵	نتیجه‌گیری نهایی

۶۷			کتاب‌نامه
----	--	--	-----------

فهرست تصاویر

- ۱-۱ نمای مفهومی چارچوب پژوهش برای ارزیابی تعمیم زمانی و مداخله‌ی شناختی در حقیقت‌سنجی
مدل‌های زبانی بزرگ. ۷
- ۱-۲ اثر پرامپت بر مسیر تصمیم مدل زبانی با ثابت نگه‌داشتن متن ادعا. ۱۳
- ۲-۲ تفاوت مفهومی میان ناوردایی زمانی و صلاحیت زمانی؛ شکاف کوچک به‌تنهایی نشانه‌ی
توان بالای حقیقت‌سنجی نیست. ۱۵
- ۳-۲ اثر مداخله‌ی سوگیری بر بازنمایی و تصمیم مدل؛ تغییر نهایی می‌تواند ترکیبی از اثر وابسته
به ادعا و پیشین ناشی از پرامپت باشد. ۱۸
- ۱-۳ معماری انتهابه‌انتهای چارچوب برای تولید سیگنال سوگیری و ارزیابی حقیقت‌سنجی در
انتقال زمانی. ۲۶
- ۲-۳ تفکیک مدل محور seen/unseen و فاصله‌ی هر ادعا از مرز عملیاتی. ۳۱
- ۳-۳ چارچوب دوبعدی ارزیابی صلاحیت و پایداری زمانی. ۳۷
- ۱-۴ حجم نمونه‌ی قابل مقایسه‌ی seen و unseen در ۱۱ مطالعه‌ی کامل مدل-پیکره. ۴۴
- ۲-۴ پوشش و میانگین confidence آشکارساز سوگیری در پنج پیکره‌ی حقیقت‌سنجی. ۴۶
- ۳-۴ میانگین Accuracy سه راهبرد پرامپتی در seen و unseen در ۱۱ مطالعه‌ی کامل. ۴۷
- ۴-۴ شکاف تعمیم زمانی به تفکیک مدل-پیکره و روش؛ مقدار منفی یعنی Accuracy بخش
unseen بیشتر است. ۴۸
- ۵-۴ اثر مرز زمانی عملیاتی بر دقت در سطح سلول؛ مقدار مثبت به معنای دقت بیشتر در unseen
است و خطوط، فاصله‌ی اطمینان ۹۵ درصد بوت‌استرپ را نشان می‌دهند. ۵۰

۶-۴	موازنه‌ی Accuracy و پایداری زمانی؛ شکاف کوچک‌تر الزاماً به معنای competence	۵۱
۷-۴	اثر Bias-aware نسبت به Strong در هر مطالعه و رژیم زمانی؛ مقدار مثبت به نفع مداخله	۵۲
۸-۴	تضاد برهم‌کنش اثر Bias-aware نسبت به Strong میان unseen و seen؛ مقدار مثبت	۵۳
۹-۴	اثر زوجی Bias-aware نسبت به Strong به تفکیک سوگیری در ادعاهای unseen همتاشده؛	۵۴
۱۰-۴	تغییر توزیع برچسب به تفکیک سوگیری در ادعاهای unseen همتاشده؛ مقدار مثبت یعنی	۵۵
	انتخاب بیشتر آن برچسب توسط Bias-aware	

فهرست جداول

۱-۱	نگاشت پرسش‌های پژوهش به مقایسه و شواهد اصلی.	۸
۱-۲	جمع‌بندی ادبیات مرتبط و جایگاه پژوهش حاضر.	۲۱
۱-۳	نمادهای اصلی مورد استفاده در طراحی پژوهش.	۲۴
۲-۳	داده، معماری و فرایارامترهای آموزش آشکارساز سوگیری.	۲۸
۳-۳	پیکره‌های حقیقت‌سنجی و ویژگی نسخه‌های پردازش شده.	۲۹
۴-۳	مدل‌های زبانی مورد استفاده و نقش آن‌ها در طراحی چندمدلی.	۳۳
۵-۳	پروتکل استنتاج، اعتبارسنجی و ثبت خروجی.	۳۵
۱-۴	ممیزی فشرده‌ی پیکره‌ها و پوشش سیگنال‌شناختی	۴۳
۲-۴	عملکرد آشکارساز ۷۲ کلاسه‌ی سوگیری شناختی روی آزمون MindScope	۴۵
۳-۴	میانگین عملکرد ۱۱ مطالعه‌ی کامل در دو رژیم زمانی	۴۷
۴-۴	شواهد آماری اصلی در هسته‌ی زوجی unseen	۵۳
۵-۴	سیاست‌های انتخاب روش روی هسته‌ی زوجی unseen	۵۶
۶-۴	تحلیل‌های حساسیت و تشخیصی مکمل	۵۸
۱-۵	جمع‌بندی فرضیه‌های اصلی پژوهش	۶۲
۲-۵	پنج محور اولویت‌دار برای ادامه‌ی پژوهش	۶۵

فهرست اختصارات

Automated Fact-Checking	AFC
Artificial Intelligence	AI
Application Programming Interface	API
Chain-of-Thought	CoT
Exploratory Data Analysis	EDA
Expected Calibration Error	ECE
F ₁ Score	F ₁
Large Language Model	LLM
Machine Learning	ML
Not Enough Information	NEI
Natural Language Processing	NLP
Retrieval-Augmented Generation	RAG
Replaced Token Detection	RTD
Total Variation Distance	TVD

فصل ۱

مقدمه و بیان مسئله

این فصل مسئله‌ی حقیقت‌سنجی ادعاهای جدید با مدل‌های زبانی بزرگ را معرفی می‌کند. ابتدا ضرورت مطالعه‌ی تعمیم زمانی و نقش نحوه‌ی بیان ادعا توضیح داده می‌شود؛ سپس تعریف عملیاتی ادعاهای seen و unseen، مسئله‌ی مداخله‌ی آگاه از سوگیری شناختی، اهداف و پرسش‌های پژوهش و نمای کلی روش ارائه می‌شود. مبانی نظری تفصیلی در فصل دوم، جزئیات روش و تنظیمات اجرا در فصل سوم و نتایج و تفسیرهای آماری در فصل چهارم آمده‌اند.

۱-۱- مقدمه

مدل‌های زبانی بزرگ^۱ در سال‌های اخیر به ابزارهایی اثرگذار برای تولید، خلاصه‌سازی و تحلیل متن تبدیل شده‌اند. توانایی آن‌ها در تولید پاسخ‌های روان و ظاهراً مستدل، فرصت مهمی برای خودکارسازی تحلیل اطلاعات فراهم می‌کند؛ با این حال، روانی و انسجام پاسخ لزوماً به معنای صحت آن نیست. مدل ممکن است اطلاعات نادرست تولید کند، میان شواهد و نتیجه رابطه‌ای نامعتبر بسازد یا با اطمینان بالا حکمی صادر کند که پشتوانه‌ی کافی ندارد [۷، ۱۵]. از این رو، ارزیابی اعتمادپذیری این مدل‌ها، به‌ویژه در وظایف حساس به صحت اطلاعات، ضرورتی اساسی است.

¹Large Language Models (LLMs)

یکی از مهم‌ترین این وظایف، **حقیقت‌سنجی خودکار**^۲ است؛ یعنی تعیین میزان سازگاری یک ادعا با واقعیت. حقیقت‌سنجی صرفاً یک طبقه‌بندی سطحی متن نیست، زیرا حکم نهایی ممکن است به هویت موجودیت‌ها، زمان وقوع رویداد، عدد و واحد، نفی، مقایسه، جهت علیت و زمینه‌ی سیاسی یا علمی وابسته باشد. پیکره‌هایی مانند LIAR، FEVER و AVeriTeC این مسئله را به‌ترتیب در قالب برچسب‌گذاری ادعاهای واقعی، استنتاج مبتنی بر شواهد و راستی‌آزمایی ادعاهای وب صورت‌بندی کرده‌اند [۲۹، ۲۴، ۱۹].

کاربرد مدل‌های زبانی در این حوزه یک ابهام مهم ایجاد می‌کند. پاسخ صحیح مدل به یک ادعای قدیمی ممکن است حاصل استدلال باشد، اما می‌تواند از آشنایی قبلی با همان رویداد، موجودیت یا گزاره در داده‌های پیش‌آموزش نیز ناشی شود. بنابراین عملکرد مطلوب روی ادعاهای موجود الزاماً نشان نمی‌دهد که مدل در برابر ادعاهای جدید نیز حقیقت‌سنج قابل‌اعتمادی است. وابستگی دانش factual مدل به بازه‌ی زمانی داده‌های آموزشی و دشواری به‌روزرسانی حقایق متغیر، این مسئله را تشدید می‌کند [۶، ۳۲].

این پایان‌نامه مسئله را از منظر **تعمیم زمانی**^۳ مطالعه می‌کند. ادعاها بر اساس تاریخ و یک مرز زمانی به دو رژیم تقسیم می‌شوند: ادعاهای پیش از مرز، *seen*، و ادعاهای پس از آن، *unseen*. این نام‌گذاری عملیاتی است: *seen* اثبات نمی‌کند که نمونه واقعاً در داده‌ی پیش‌آموزش مدل وجود داشته و *unseen* نیز نبود همه‌ی اطلاعات مشابه را تضمین نمی‌کند، زیرا داده‌های آموزشی کامل بسیاری از مدل‌ها منتشر نشده‌اند. این تفکیک تنها شرایطی کنترل‌شده برای مقایسه‌ی رفتار مدل در دو سوی زمان فراهم می‌سازد و با ارزیابی تحت تغییر توزیع زمانی هم‌راستا است [۲۰، ۱، ۲۲].

اگر دقت مدل در دو بخش به‌ترتیب با Acc_{seen} و Acc_{unseen} نشان داده شود، شکاف تعمیم زمانی به‌صورت زیر تعریف می‌شود:

$$G = Acc_{seen} - Acc_{unseen}. \quad (1.1)$$

با این حال، اندازه یا علامت G به‌تنهایی برای داوری درباره‌ی توان مدل کافی نیست. تازگی زمانی با دشواری مترادف نیست و دو بخش ممکن است از نظر موضوع، طول ادعا یا توزیع برچسب متفاوت باشند. افزون بر این، شکاف کوچک می‌تواند هم از عملکرد مطلوب در هر دو بخش و هم از عملکرد ضعیف اما مشابه حاصل شود.

^۲Automated Fact-Checking

^۳Temporal Generalization

از این رو، در این پژوهش پایداری رفتار در طول زمان از توان واقعی حقیقت‌سنجی ادعاهای جدید متمایز می‌شود؛ جزئیات این تمایز و عوامل مداخله‌گر در فصل دوم و نحوه‌ی سنجش آن در فصل سوم ارائه می‌شود.

محور دوم پژوهش، **نحوه‌ی بیان ادعا** است. متن یک ادعا ممکن است حاوی قاب‌بندی جانبدارانه، لنگرگذاری، توسل به مرجع، برجسته‌سازی انتخابی یا سایر نشانه‌های مرتبط با سوگیری‌های شناختی باشد [۲۶، ۲۷، ۸]. این نشانه‌ها ممکن است سبب شوند قضاوت مدل، افزون بر محتوای *factual*، از صورت‌بندی ادعا نیز اثر بپذیرد. با این حال، وجود چنین نشانه‌ای با نادرست‌بودن ادعا برابر نیست: یک ادعای صحیح می‌تواند جانبدارانه بیان شود و یک ادعای نادرست می‌تواند زبانی خنثی داشته باشد. بنابراین در این پایان‌نامه، سوگیری شناختی نه برچسب حقیقت و نه شاهد کذب، بلکه سیگنالی کمکی برای هدایت توجه مدل به امکان اثرگذاری صورت‌بندی ادعاست. برای سنجش اثر این سیگنال، سه راهبرد پرامپتی مقایسه می‌شوند: پرامپت ساده‌ی *Naive*، خط‌پایه‌ی دقیق‌تر *Strong* و نسخه‌ی *Bias-aware* که همان خط‌پایه‌ی قوی را همراه با اطلاعات سوگیری دریافت می‌کند. این طراحی اجازه می‌دهد اثر اطلاعات سوگیری نسبت به یک خط‌پایه‌ی کنترل‌شده سنجیده شود. پرسش اصلی آن است که آیا این مداخله دقت و تعمیم زمانی را بهبود می‌دهد یا صرفاً سیاست تصمیم مدل را تغییر می‌دهد. به همین دلیل، ارزیابی فقط به دقت کلی محدود نیست و رفتار زوجی روش‌ها، تغییرات سطح کلاس و ناهمگنی اثر نیز در فصل چهارم بررسی می‌شوند.

در مجموع، پژوهش حاضر در تقاطع حقیقت‌سنجی با مدل‌های زبانی بزرگ، تعمیم زمانی و مداخله‌ی شناختی قرار دارد. هدف آن اثبات پیشینی سودمندی یک پرامپت نیست، بلکه اندازه‌گیری نظام‌مند این موضوع است که مدل‌ها در مواجهه با ادعاهای جدید چگونه رفتار می‌کنند و اطلاعات سوگیری در چه شرایطی می‌تواند سودمند یا زیان‌بار باشد.

۱-۲- تاریخچه و زمینه

حقیقت‌سنجی خودکار ابتدا عمدتاً بر ویژگی‌های واژگانی، سبک متن، مشخصات ناشر و الگوریتم‌های طبقه‌بندی متکی بود. با گسترش یادگیری عمیق، بازنمایی‌های توزیعی و مدل‌های مبتنی بر ترنسفورمر جای بخش بزرگی از مهندسی دستی ویژگی را گرفتند. مجموعه داده‌ی *LIAR* برچسب‌گذاری چندسطحی ادعاهای سیاسی واقعی را تثبیت کرد؛ *FEVER* بازیابی شواهد و استنتاج میان ادعا و شاهد را به مرکز مسئله آورد؛ و *AVeriTeC*

ارزیابی ادعاهای واقعی با شواهد وب را به شرایط کاربردی نزدیک‌تر کرد [۲۹، ۲۴، ۱۹].

ظهور مدل‌های زبانی بزرگ امکان تجزیه‌ی ادعا، تولید پرسش کمکی، مقایسه‌ی دلایل و صدور حکم را در یک چارچوب مولد فراهم کرد. روش‌های استدلال مرحله‌به‌مرحله و پرامپت‌های ساختاریافته نیز برای بهبود این فرایند پیشنهاد شدند [۳۰، ۱۴، ۳۳]. با این حال، توضیح تولیدشده الزاماً بازتاب وفادار سازوکار تصمیم نیست [۲۵] و ارزیابی تصادفی نیز ممکن است افت ناشی از تغییر زمان را پنهان کند [۲۰، ۱]. در خطی موازی، پژوهش‌های روان‌شناسی شناختی اثر قاب‌بندی و میان‌برهای ذهنی بر قضاوت را نشان داده‌اند و مطالعات جدیدتر، از جمله MindScope، الگوهای رفتاری مرتبط را در مدل‌های زبانی بررسی کرده‌اند [۲۶، ۲۷، ۳۱]. پژوهش حاضر این سه مسیر را در یک طراحی تجربی مشترک به هم پیوند می‌دهد. مرور منظم و تفصیلی ادبیات و شکاف پژوهشی در فصل دوم ارائه می‌شود.

۱-۳- شرح مسئله

مسئله‌ی نخست این است که دقت بالا روی داده‌های قدیمی یا تجمیع‌شده، شاهد کافی برای توان حقیقت‌سنجی ادعاهای جدید نیست. برای هر ادعای x_i با برجسب حقیقت y_i و تاریخ t_i ، و با مرز زمانی τ ، تعریف عملیاتی دو بخش پژوهش چنین است:

$$\begin{aligned} D_{\text{seen}} &= \{(x_i, y_i) : t_i \leq \tau\}, \\ D_{\text{unseen}} &= \{(x_i, y_i) : t_i > \tau\}. \end{aligned} \quad (۲.۱)$$

این تفکیک امکان مقایسه‌ی عملکرد گذشته‌محور و آینده‌محور را فراهم می‌کند، اما تفسیر آن باید محتاطانه باشد. تفاوت دو بخش می‌تواند علاوه بر میزان مواجهه‌ی احتمالی مدل، از تغییر دامنه، موضوع، دشواری یا توزیع کلاس‌ها ناشی شود. بنابراین این پژوهش هم سطح عملکرد unseen و هم تغییر آن نسبت به seen را می‌سنجد و نتیجه‌گیری درباره‌ی تعمیم زمانی را بر مجموعه‌ای از سنجه‌ها و تحلیل‌های کنترل‌شده استوار می‌کند.

مسئله‌ی دوم این است که قضاوت مدل ممکن است از صورت‌بندی اقناعی ادعا اثرپذیرد. مجموعه داده‌های رایج حقیقت‌سنجی برجسب مستقیم سوگیری شناختی ندارند؛ از این رو، برای هر ادعا ابتدا نشانه‌های مرتبط با

سوگیری به صورت خودکار استخراج می‌شود و سپس این اطلاعات تنها در راهبرد Bias-aware در اختیار مدل قرار می‌گیرد. قید مفهومی اساسی آن است که مدل نباید از «وجود سوگیری» میان‌بری برای پیش‌بینی «نادرست» بسازد.

مسئله‌ی سوم به تفاوت میان تشخیص سوگیری و سود مداخله مربوط است. حتی اگر آشکارساز، نوع سوگیری را درست شناسایی کند، افزودن این اطلاعات ممکن است پاسخ نادرست را اصلاح کند، پاسخ صحیح را خراب کند یا بدون تغییر صحت، توزیع انتخاب برچسب‌ها را جابه‌جا سازد. در نتیجه، کیفیت مستقل آشکارساز تضمین‌کننده‌ی بهبود حقیقت‌سنجی انتهابه‌انتها نیست. این پژوهش با مقایسه‌ی زوجی Strong و Bias-aware بررسی می‌کند که اثر خالص مداخله چیست، در کدام نمونه‌ها رخ می‌دهد و آیا میان مدل‌ها، پیکره‌ها، کلاس‌ها و رژیم‌های زمانی ناهمگون است.


بنابراین صورت اصلی مسئله چنین است: آیا ارائه‌ی اطلاعات صریح درباره‌ی نشانه‌های سوگیری شناختی، توان مدل زبانی در حقیقت‌سنجی ادعاهای زماناً جدید را بهبود می‌دهد، یا فقط ثبات و سیاست تصمیم آن را تغییر می‌دهد؟ پاسخ معتبر به این پرسش مستلزم جداسازی سه مفهوم است: تازگی از دشواری، پایداری زمانی از عملکرد مطلوب، و دقت آشکارسازی از سود مداخله. صورت‌بندی نظری کامل این تمایزها در فصل دوم و طرح اندازه‌گیری آن‌ها در فصل سوم ارائه می‌شود.

۱-۴- تعریف موضوع

موضوع پایان‌نامه «حقیقت‌سنجی ادعاهای جدید در مدل‌های زبانی بزرگ با کمک سوگیری‌های شناختی» است و سه مؤلفه دارد. نخست، چند مدل زبانی بزرگ در نقش طبقه‌بند حقیقت، برچسبی از فضای مجاز هر پیکره انتخاب می‌کنند. دوم، جدیدبودن ادعا با تاریخ و مرز زمانی همان آزمایش عملیاتی و به دو بخش seen و unseen تبدیل می‌شود. سوم، چون پیکره‌های حقیقت‌سنجی فاقد برچسب سوگیری‌اند، یک آشکارساز مبتنی بر DeBERTa-v3-base با استفاده از داده‌های MindScope آموزش می‌بیند تا سیگنال کمکی مورد نیاز پرامپت آگاه از سوگیری را تولید کند [۳۱، ۱۱].

در این چارچوب، Naive حداقل دستور لازم، Strong تعریف دقیق وظیفه و قواعد بررسی ادعا، و Bias-aware همان Strong به‌علاوه‌ی سیگنال سوگیری را دریافت می‌کند. بدین ترتیب، مقایسه‌ی دو روش اخیر اثر

مداخله‌ی شناختی را تا حد ممکن جدا می‌سازد. شکل ۱-۱ نمای مفهومی فرایند را نشان می‌دهد؛ جزئیات اجزای آن در فصل سوم تشریح می‌شود.



شکل (۱-۱) نمای مفهومی چارچوب پژوهش برای ارزیابی تعمیم زمانی و مداخله‌ی شناختی در حقیقت‌سنجی مدل‌های زبانی بزرگ.

۱-۵- اهداف و پرسش‌ها

هدف کلی، طراحی و ارزیابی چارچوبی تجربی برای سنجش حقیقت‌سنجی ادعاهای جدید و اثر مداخله‌ی شناختی بر عملکرد و رفتار مدل‌های زبانی بزرگ است. اهداف اختصاصی عبارت‌اند از: سنجش جداگانه‌ی عملکرد در دو بخش زمانی؛ بررسی اینکه تازگی الزاماً با دشواری بیشتر همراه است یا نه؛ تولید خودکار سیگنال سوگیری برای ادعاهای فاقد برچسب شناختی؛ مقایسه‌ی کنترل‌شده‌ی سه راهبرد پرامپتی؛ تمایز پایداری زمانی از صلاحیت واقعی؛ و شناسایی ناهمگنی سود یا زیان مداخله در سطح نمونه، کلاس، مدل و پیکره.

بر این اساس، پرسش‌های اصلی پژوهش عبارت‌اند از:

۱. عملکرد مدل‌های زبانی در حقیقت‌سنجی ادعاهای seen و unseen چه تفاوتی دارد و این تفاوت تا چه حد با تازگی یا ویژگی‌های توزیع داده مرتبط است؟

۲. آیا پرامپت Strong در مقایسه با Naive عملکرد کلی و تعمیم زمانی بهتری فراهم می‌کند؟

۳. افزودن اطلاعات سوگیری به Strong چه اثری بر دقت، عملکرد سطح کلاس و شکاف زمانی دارد؟

۴. آیا کوچک شدن شکاف seen/unseen با حفظ یا افزایش عملکرد در بخش unseen همراه است؟
۵. آیا مداخله‌ی آگاه از سوگیری، الگوی انتخاب برچسب‌ها را به صورت جهت‌دار تغییر می‌دهد و اثر آن میان شرایط آزمایشی ناهمگون است؟
۶. آیا شواهد موجود از لزوم مداخله‌ی انتخابی، به جای افزودن همیشگی اطلاعات سوگیری، پشتیبانی می‌کنند؟
- برای حفظ ارتباط روشن میان پرسش‌ها و ارزیابی، جدول ۱-۱ نداشت فشرده‌ی آن‌ها را ارائه می‌کند.
- جدول (۱-۱) نداشت پرسش‌های پژوهش به مقایسه و شواهد اصلی.

محور پرسش	مقایسه‌ی اصلی	شواهد ارزیابی
تعمیم زمانی و تازگی	Unseen / Seen	عملکرد کلی و سطح کلاس، شکاف زمانی و ویژگی‌های توزیع داده
کیفیت راهبرد پرامپتی	Strong / Naive	اختلاف عملکرد در مدل‌ها و پیکره‌ها
سود مداخله‌ی شناختی	Bias-aware / Strong	تغییر عملکرد و شواهد زوجی
پایداری در برابر صلاحیت	شکاف زمانی / عملکرد Unseen	تحلیل هم‌زمان ثبات و سطح عملکرد
تغییر رفتار و ناهمگنی	خروجی‌های زوجی و زیرگروه‌ها	تغییر برچسب و اثر برحسب مدل، داده و نوع سوگیری
مداخله‌ی انتخابی	انتخاب میان دو راهبرد	برآورد ظرفیت بالقوه و محدودیت‌های انتخاب

برآیند این طراحی در چهار دستاورد مفهومی صورت‌بندی می‌شود: تمایز تازگی زمانی از دشواری؛ تمایز ناوردایی زمانی از صلاحیت زمانی؛ نشان‌دادن اینکه دقت آشکارساز، سود مداخله را تضمین نمی‌کند؛ و معرفی پارادوکس شناختی رفع سوگیری^۴. مورد چهارم بیان می‌کند که مداخله‌ی پرامپتی با هدف کاهش سوگیری می‌تواند خود یک سوگیری تصمیم تازه ایجاد کند و بدون افزایش دقت، مدل را به سوی پذیرش بیشتر ادعاها سوق دهد. این ادعا در این پایان‌نامه در سطح رفتار خروجی و با الگوی Permissive Decision Shift سنجیده می‌شود، نه به عنوان ادعایی درباره‌ی سازوکار روان‌شناختی یا حالت‌های پنهان مدل.

۱-۶- روش تحقیق

پژوهش حاضر تجربی، کمی و مقایسه‌ای و دارای معماری دوفازی است. در فاز نخست، یک طبقه‌بند مبتنی بر DeBERTa-v3-base با داده‌های MindScope برای تشخیص ۷۲ نوع سوگیری شناختی تنظیم دقیق می‌شود

⁴Cognitive Debiasing Paradox

و خروجی آن به ادعاهای پیکره‌های حقیقت‌سنجی افزوده می‌گردد. در فاز دوم، پیکره‌ها از نظر ستون‌ها، تاریخ و فضای برچسب استاندارد می‌شوند و با مرز زمانی متناسب هر آزمایش به دو بخش seen و unseen تقسیم می‌شوند.

برای هر ادعا، سه پرامپت Naive، Strong و Bias-aware ساخته و با تنظیمات استنتاج ثابت روی مدل‌های زبانی مورد ارزیابی اجرا می‌شوند. خروجی‌ها در برابر فضای برچسب مجاز اعتبارسنجی و موارد نامعتبر ثبت می‌شوند. ارزیابی، عملکرد کلی و سطح کلاس، شکاف زمانی و مقایسه‌های زوجی را در بر می‌گیرد؛ تحلیل‌های آماری برای سنجش عدم قطعیت و معنی‌داری اختلاف‌ها و تحلیل‌های زیرگروهی برای بررسی ناهمگنی اثر به کار می‌روند. همچنین تغییر الگوی برچسب و ظرفیت بالقوه‌ی انتخاب میان Strong و Bias-aware بررسی می‌شود. معماری دقیق، داده‌ها، تنظیمات، معیارها و آزمون‌ها در فصل سوم و نتایج آن‌ها در فصل چهارم ارائه شده‌اند.

۱-۷- ساختار پایان‌نامه

این پایان‌نامه در پنج فصل سازمان یافته است. فصل اول مسئله، اهداف، پرسش‌ها و نمای کلی روش را معرفی می‌کند. فصل دوم مبانی حقیقت‌سنجی، مدل‌های زبانی بزرگ، تعمیم زمانی، سوگیری‌های شناختی و پیشینه‌ی مرتبط را مرور و شکاف پژوهشی را مشخص می‌کند. فصل سوم معماری دو فاز، داده‌ها، تفکیک زمانی، راهبردهای پرامپتی، پروتکل اجرا و طرح ارزیابی را شرح می‌دهد. فصل چهارم تحلیل اکتشافی داده‌ها و نتایج تجربی را گزارش و تفسیر می‌کند. سرانجام، فصل پنجم پاسخ نهایی به پرسش‌ها، دستاوردها، محدودیت‌ها و مسیرهای ادامه‌ی پژوهش را جمع‌بندی می‌کند.

فصل ۲

مفاهیم اولیه و پیش زمینه

۲-۱- مقدمه

فصل نخست مسئله‌ی حقیقت‌سنجی ادعاهای جدید و ارزیابی اثر مداخله‌ی آگاه از سوگیری را معرفی کرد. برای تفسیر درست طراحی و نتایج پژوهش، باید چهار زمینه‌ی نظری به یکدیگر متصل شوند: حقیقت‌سنجی خودکار، دانش و رفتار مدل‌های زبانی بزرگ، تعمیم زمانی و سوگیری‌های شناختی. هدف این فصل ارائه‌ی همین مبانی به‌اندازه‌ی لازم برای فهم روش است؛ جزئیات پیاده‌سازی در فصل سوم و شواهد تجربی در فصل چهارم ارائه می‌شوند.

نخست، تفاوت حقیقت‌سنجی بسته و حقیقت‌سنجی مبتنی بر شواهد توضیح داده می‌شود و روشن می‌گردد که پاسخ صحیح یک مدل الزاماً حاصل راستی‌آزمایی نیست. سپس نقش دانش پارامتری، مرز زمانی دانش و تغییر توزیع در ارزیابی ادعاهای جدید بررسی می‌شود. در ادامه، میان حالت شناختی انسان، نشانه‌ی متنی سوگیری و برچسب حقیقت تمایز گذاشته می‌شود. سرانجام، افزودن اطلاعات سوگیری به پرامپت به‌عنوان مداخله‌ای بر تصمیم مدل صورت‌بندی و معیارهای لازم برای سنجش اثر آن معرفی می‌شوند.

۲-۲- حقیقت‌سنجی خودکار و مدل‌های زبانی بزرگ

حقیقت‌سنجی خودکار فرایند ارزیابی یک ادعای قابل بررسی و انتساب حکم مناسب به آن است. این وظیفه می‌تواند شامل تشخیص ادعای قابل راستی‌آزمایی، تجزیه‌ی آن به زیرادعاها، بازیابی شواهد، سنجش رابطه‌ی شاهد و ادعا و صدور حکم باشد. فضای حکم نیز الزاماً دودویی نیست؛ برچسب‌هایی مانند «گمراه‌کننده»، «نیمه‌درست» یا «اطلاعات ناکافی» نشان می‌دهند که حذف زمینه، ابهام یا ناکافی بودن شاهد می‌تواند مرز میان کلاس‌ها را تعیین کند.

ادبیات این حوزه از طبقه‌بندی ادعا به سمت راستی‌آزمایی مبتنی بر شاهد حرکت کرده است. LIAR ادعاهای سیاسی واقعی را در فضایی چندسطحی از صحت صورت‌بندی کرد [۲۹]. FEVER حکم را به شواهد پشتیبان یا ناقض متصل ساخت [۲۴] و AVeriTeC مسئله را به ادعاهای واقعی و شواهد چندمنبعی وب نزدیک کرد [۱۹]. این تحول میان دو رژیم اساسی تمایز ایجاد می‌کند:

$$\hat{y}_{\text{closed}} = f_{\theta}(x), \quad \hat{y}_{\text{grounded}} = f_{\theta}(x, R(x)), \quad (1.2)$$

که در آن $R(x)$ شواهد بازیابی‌شده برای ادعاست. در حالت بسته^۱ مدل تنها به متن ادعا، دستور و دانش درونی خود متکی است؛ در حالت مبتنی بر شواهد^۲ حکم با اسناد خارجی پشتیبانی می‌شود. آزمایش اصلی این پایان‌نامه از نوع بسته است تا رفتار دانش پارامتری و اثر خالص مداخله‌ی پرامپتی مطالعه شود؛ بنابراین نتیجه‌ها نباید با توان یک سامانه‌ی کامل بازیابی و راستی‌آزمایی یکسان تلقی شوند.

مدل‌های زبانی بزرگ، برخلاف طبقه‌بندهای سنتی، می‌توانند ادعا را بازنویسی کنند، زیرمسئله بسازند، استدلال متنی تولید کنند و تحت دستورهای مختلف پاسخ‌های متفاوت بدهند. روش‌های استدلال زنجیره‌ای (CoT) نشان داده‌اند که ساختاردهی مراحل میانی در برخی وظایف، توانایی‌های نهفته‌ی مدل را بهتر فعال می‌کند [۳۰، ۱۴]. در حقیقت‌سنجی نیز HiSS با تجزیه‌ی سلسله‌مراتبی ادعا و زنجیره‌ی بازبینی (CoVe) با ارزیابی مرحله‌ای پاسخ، نمونه‌هایی از این رویکردها [۳۳، ۷].

با این حال، توضیح تولیدشده را نمی‌توان مستقیماً فرایند واقعی تصمیم مدل دانست. پژوهش درباره‌ی وفاداری

¹Closed-Book

²Evidence-Grounded

استدلال زنجیره‌ای نشان داده است که نشانه‌های جانبی می‌توانند پاسخ را تغییر دهند، بی‌آنکه اثر آن‌ها در توضیح مدل آشکار شود [۲۵]. به همین ترتیب، وزن‌های توجه نیز بدون آزمون‌های مکمل، توضیح علیّ تصمیم محسوب نمی‌شوند [۱۲]. از این رو، پژوهش حاضر به جای استنتاج سازوکار داخلی از متن توضیح، بر تغییرات قابل مشاهده‌ی حکم، عملکرد و توزیع برچسب تمرکز دارد.


معماری بیشتر مدل‌های مورد بحث بر ترنسفورمر استوار است [۲۸]. تنها رابطه‌ی لازم برای بحث حاضر، توجه مقیاس شده است:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V. \quad (2.2)$$

توجه چندسری همین محاسبه را در چند زیرفضای بازنمایی انجام می‌دهد. پیام مرتبط با این پایان‌نامه آن است که توکن‌های افزوده‌شده به پرامپت می‌توانند با متن ادعا برهم‌کنش کنند و بازنمایی و احتمال خروجی را تغییر دهند؛ بنابراین بلوک سوگیری یک الحاق خنثی نیست. جزئیات آموزشی معماری، softmax و مدل‌سازی خودرگرسیو برای صورت مسئله‌ی این پایان‌نامه ضروری نیستند.

مدل ممکن است متنی روان اما نادرست تولید کند؛ پدیده‌ای که معمولاً ذیل مفهوم توهم بررسی می‌شود. روش‌هایی مانند SelfCheckGPT از ناسازگاری میان چند پاسخ برای شناسایی خطا استفاده می‌کنند، هرچند سازگاری نیز تضمین‌کننده‌ی حقیقت نیست [۱۵]. در نتیجه، توان زبانی، اعتماد ظاهری و صحت اطلاعاتی سه مفهوم متمایزند و حکم مدل باید با معیارهای مستقل ارزیابی شود.

شکل ۲-۱ رابطه‌ی میان ادعا، پرامپت و تصمیم را نمایش می‌دهد. ثابت بودن ادعا برای ثابت بودن خروجی کافی نیست؛ زیرا پرامپت بخشی از شرط محاسباتی مدل است. سه راهبرد Naive، Strong و Bias-aware بر اساس همین اصل کنترلی در فصل سوم مقایسه می‌شوند.



شکل (۱-۲) اثر پرامپت بر مسیر تصمیم مدل زبانی با ثابت نگه‌داشتن متن ادعا.

۳-۲- تعمیم زمانی، دانش پارامتری و تغییر توزیع

مدل‌های زبانی در پیش‌آموزش، الگوها و واقعیت‌های فراوانی را در وزن‌های خود جذب می‌کنند؛ این اطلاعات دانش پارامتری^۳ نامیده می‌شود. در حقیقت‌سنجی بسته، پاسخ تا حد زیادی به همین دانش و نحوه‌ی بازایی آن از طریق پرامپت وابسته است. بنابراین پاسخ صحیح به ادعایی قدیمی می‌تواند حاصل استدلال، حفظ اطلاعات یا ترکیبی از هر دو باشد و دقت بالا به‌تنهایی این عوامل را از هم جدا نمی‌کند.

دانش پارامتری از نظر زمانی محدود است. مرزدانش^۴ به آخرین بازه‌ای اشاره دارد که داده‌های آن می‌توانسته‌اند در آموزش مدل حضور داشته باشند؛ با این حال، در عمل این مرز همیشه دقیق و یکنواخت نیست و جزئیات داده‌های آموزش اغلب منتشر نمی‌شود. حقایق نیز ممکن است با زمان تغییر کنند؛ برای نمونه، سمت یک فرد، جمعیت یک کشور یا نتیجه‌ی یک انتخابات در تاریخ‌های مختلف احکام متفاوتی دارد. پژوهش در باره‌ی مدل‌های زمان‌آگاه و ناهم‌ترازی زمانی نشان داده است که مدل‌های مبتنی بر تصویری ثابت از جهان، در برابر حقایق آینده یا منسوخ آسیب‌پذیرند [۶، ۳۲].

به همین دلیل، تقسیم تصادفی همیشه برآورد واقع‌بینانه‌ای از کاربرد آینده ارائه نمی‌کند. نمونه‌های بسیار مشابه یا ادعاهای مربوط به یک رویداد ممکن است در دو سوی تقسیم قرار گیرند و اثر آشنایی را با تعمیم اشتباه بگیرند. تقسیم زمانی، داده را در جهت طبیعی استقرار، یعنی گذشته به آینده، مرتب می‌کند و خطر این خوش‌بینی را کاهش

³Parametric Knowledge

⁴Knowledge Cutoff

می‌دهد [۲۰، ۲۲، ۲]. با این حال، برش زمانی نیز اثبات نمی‌کند که هر ادعای پس از مرز واقعاً از پیش آموزش غایب بوده است؛ از این رو، تعریف عملیاتی seen/unseen همان تعریف فصل نخست در رابطه‌ی (۲.۱) است و به عنوان تقریب مواجهه‌ی زمانی تفسیر می‌شود.

انتقال زمانی معمولاً چند نوع تغییر را هم‌زمان در بر می‌گیرد. تغییر هم‌متغیر به تفاوت در موضوعات، موجودیت‌ها یا سبک بیان؛ تغییر برچسب به تفاوت فراوانی کلاس‌ها؛ و تغییر مفهوم به تفاوت رابطه‌ی ورودی و حکم اشاره دارد. این سه حالت را می‌توان فشرده چنین نمایش داد:

$$\begin{aligned} \text{Covariate shift: } & P_s(X) \neq P_u(X), \\ \text{Label shift: } & P_s(Y) \neq P_u(Y), \\ \text{Concept shift: } & P_s(Y | X) \neq P_u(Y | X). \end{aligned} \quad (۳.۲)$$

در حقیقت‌سنجی، موضوع و موجودیت جدید می‌تواند دشواری را تغییر دهد؛ تفاوت سهم کلاس‌ها می‌تواند دقت کلی را بالا یا پایین ببرد؛ و تغییر یک حقیقت با زمان می‌تواند دانش قدیمی را مستقیماً گمراه‌کننده سازد. بنابراین هر اختلاف میان seen و unseen را نمی‌توان فقط به مرز دانش نسبت داد. مطالعات تعمیم زمانی نیز تأکید کرده‌اند که افت یا بهبود با گذر زمان به وظیفه، دامنه و ترکیب داده وابسته است [۱]. این نکته به تمایز نخست چارچوب نظری می‌انجامد:

$$\text{Temporal Novelty} \neq \text{Difficulty}. \quad (۴.۲)$$


برای روشن شدن منشأ شکاف زمانی، دقت هر رژیم را می‌توان حاصل سهم کلاس‌ها و عملکرد شرطی روی آن‌ها دانست. اگر $\pi_{k,z} = P(Y = k | z)$ و $a_{k,z} = P(\hat{Y} = Y | Y = k, z)$ باشند، شکاف رابطه‌ی (۱.۱) به صورت زیر تجزیه می‌شود:

$$G = \sum_k (\pi_{k,s} - \pi_{k,u}) a_{k,s} + \sum_k \pi_{k,u} (a_{k,s} - a_{k,u}). \quad (۵.۲)$$

جمله‌ی نخست اثر تغییر ترکیب کلاس و جمله‌ی دوم تغییر عملکرد شرطی مدل را بازنمایی می‌کند. در نتیجه، حتی بهتر شدن دقت unseen می‌تواند ناشی از ساده‌تر شدن ترکیب داده باشد. این تجزیه دلیل استفاده‌ی هم‌زمان از دقت، Macro-F1 و تحلیل سطح کلاس در فصل چهارم است. تمایز دوم میان ناوردایی زمانی^۵ و صلاحیت زمانی^۶ است:

$$\text{Temporal Invariance} \neq \text{Temporal Competence.} \quad (۶.۲)$$

ناوردایی به مشابه‌بودن عملکرد در دو سوی زمان اشاره دارد، در حالی که صلاحیت به سطح واقعی عملکرد در بخش unseen مربوط است. مدلی با عملکرد ضعیف اما برابر در هر دو بخش، شکاف کوچکی دارد ولی حقیقت‌سنج توانمندی نیست. از این رو، کوچک شدن $|G|$ تنها زمانی مطلوب است که سطح عملکرد، به‌ویژه روی ادعاهای جدید، حفظ یا بهتر شود. شکل ۲-۲ این تفاوت را به‌صورت مفهومی نشان می‌دهد.



شکل (۲-۲) تفاوت مفهومی میان ناوردایی زمانی و صلاحیت زمانی؛ شکاف کوچک به‌تنهایی نشانه‌ی توان بالای حقیقت‌سنجی نیست.

⁵Temporal Invariance

⁶Temporal Competence

۲-۴- سوگیری‌های شناختی و نشانه‌های متنی

سوگیری‌های شناختی به الگوهای نظام‌مند انحراف قضاوت از یک معیار هنجاری اشاره دارند. پژوهش‌های کلاسیک نشان داده‌اند که میان‌برهایی مانند دسترس‌پذیری، بازنمایی و لنگرگذاری می‌توانند تصمیم انسان را به شیوه‌ای قابل پیش‌بینی تغییر دهند [۲۶]. همچنین، اثر قاب‌بندی نشان می‌دهد که دو بیان متفاوت از اطلاعات بنیادی مشابه می‌توانند ترجیحات متفاوتی ایجاد کنند [۲۷]. در حوزه‌ی اطلاعات نادرست نیز تکرار، آشنایی، پردازش تحلیلی و زمینه‌ی اجتماعی بر پذیرش یا رد محتوا اثر می‌گذارند [۸، ۱۷].

این مفاهیم هنگام انتقال به متن و مدل زبانی به احتیاط سازه‌ای نیاز دارند. اگر یک طبقه‌بند در جمله‌ای نشانه‌ی لنگرگذاری یا توسل به مرجع تشخیص دهد، نمی‌توان نتیجه گرفت نویسنده الزاماً همان حالت روان‌شناختی را تجربه کرده است. خروجی مدل تنها نشانه‌ی متنی سازگار با یک طبقه‌ی سوگیری است، نه مشاهده‌ی ذهن نویسنده. افزون بر این، شباهت رفتاری یک مدل زبانی به الگوی انسانی، هویت سازوکارهای آن‌ها را اثبات نمی‌کند. در این پایان‌نامه اصطلاح «آشکارسازی سوگیری» همواره در همین معنای عملیاتی به کار می‌رود.

تمایز مهم‌تر آن است که نشانه‌ی سوگیری، برچسب حقیقت نیست:

$$B_{\text{textual}} \neq Y_{\text{truth}}. \quad (۷.۲)$$

یک ادعای صحیح می‌تواند با زبان هیجانی یا قاب‌بندی جانبدارانه بیان شود و یک ادعای نادرست می‌تواند کاملاً خنثی باشد. بنابراین استفاده از سوگیری به عنوان میان‌بری برای پیش‌بینی «نادرست» از نظر مفهومی نامعتبر است. نقش مطلوب این سیگنال، هشدار درباره‌ی صورت‌بندی و برانگیختن بررسی دقیق‌تر ادعاست.

برای تولید این سیگنال از MindScope استفاده می‌شود که دامنه‌ی گسترده‌ای از الگوهای مرتبط با سوگیری را برای مطالعه‌ی رفتار مدل‌های زبانی پوشش می‌دهد [۳۱]. آشکارساز پروژه بر پایه‌ی DeBERTa-v3-base است. خانواده‌ی DeBERTa محتوا و موقعیت را به صورت تفکیک‌شده بازنمایی می‌کند و نسخه‌ی سوم از هدف پیش‌آموزش تشخیص توکن جایگزین‌شده^۷ و اشتراک‌گذاری کنترل‌شده‌ی بازنمایی‌ها بهره می‌برد [۱۱]. همین توضیح برای فهم انتخاب مدل کافی است؛ معماری طبقه‌بندی، آماده‌سازی داده و تنظیمات آموزش در فصل سوم

⁷Replaced Token Detection (RTD)

آمده‌اند.

۲-۵- مداخله‌ی پرامپتی و اثر آن بر تصمیم LLM

در مدل زبانی، پرامپت بخشی از شرط مسئله است. برای ادعای ثابت x ، تغییر پرامپت از p_1 به p_2 می‌تواند توزیع پیش‌بینی را تغییر دهد:

$$P_{\theta}(Y \mid x, p_1) \neq P_{\theta}(Y \mid x, p_2). \quad (۸.۲)$$

حساسیت به ترتیب گزینه‌ها، واژه‌بندی و قالب دستور در مطالعات مختلف گزارش شده است [۴، ۱۸]. بنابراین پرامپت در یک آزمایش علمی باید مانند متغیر مستقل کنترل شود. در طراحی این پژوهش، Bias-aware همان محتوای Strong را حفظ می‌کند و فقط بلوک اطلاعات سوگیری را می‌افزاید؛ به این ترتیب، مقایسه‌ی آن‌ها تا حد ممکن به اثر همان مداخله نزدیک می‌شود.


بااین‌حال، اثر مشاهده‌شده هنوز دو منشأ بالقوه دارد: معنای سیگنال سوگیری و تغییر ساختار زمینه. افزودن یک بلوک جدید ممکن است توجه مدل را به جنبه‌ی مفیدی از ادعا هدایت کند، اما همچنین می‌تواند یک پیش‌فرض عمومی درباره‌ی کلاس‌ها ایجاد کند. در سطح مفهومی، جابه‌جایی تصمیم را می‌توان چنین تجزیه کرد:

$$\delta_B = \delta_{\text{claim-specific}} + \delta_{\text{prompt-prior}}. \quad (۹.۲)$$

جزء نخست اثر وابسته به ادعاست: اطلاعات سوگیری مدل را در همان نمونه از خطای استدلالی دور می‌کند. جزء دوم پیشین القاشده توسط پرامپت^۸ است: مداخله احتمال بعضی برچسب‌ها را به‌طور جهت‌دار تغییر می‌دهد، حتی زمانی که چنین تغییری به صحت کمک نمی‌کند. اگر جزء دوم غالب شود، تغییر دقت با جابه‌جایی

^۸Prompt-Induced Prior

سیاست تصمیم^۹ همراه خواهد بود. شکل ۳-۲ این مسیر را از تغییر زمینه تا تغییر بازنمایی و خروجی نشان می‌دهد.



شکل (۳-۲) اثر مداخله‌ی سوگیری بر بازنمایی و تصمیم مدل؛ تغییر نهایی می‌تواند ترکیبی از اثر وابسته به ادعا و پیشین ناشی از پرامپت باشد.

این صورت‌بندی، امکان پارادوکس شناختی رفع سوگیری^{۱۰} را مطرح می‌کند: مداخله‌ای که با هدف کاهش اثر صورت‌بندی جانبدارانه طراحی شده است، ممکن است خود جهت‌گیری تازه‌ای در خروجی ایجاد کند. این مفهوم در این فصل یک فرضیه‌ی رفتاری است، نه نتیجه‌ی اثبات‌شده یا ادعایی درباره‌ی سازوکار درونی؛ شواهد تجربی آن در فصل چهارم بررسی می‌شوند.

تمایز کلیدی دیگر میان کیفیت آشکارساز و سود پایین‌دستی است:

$$\text{Detector Accuracy} \neq \text{Downstream Utility}. \quad (۱۰.۲)$$

آشکارساز ممکن است برجسب سوگیری را با اطمینان و دقت بالا تولید کند، اما اطلاع از آن برجسب الزاماً حکم حقیقت را بهتر نمی‌کند. اطمینان آشکارساز پاسخ می‌دهد «این نشانه با چه احتمالی وجود دارد؟»، در حالی که متغیر مورد نیاز برای مداخله پاسخ می‌دهد «افزودن این نشانه با چه احتمالی تصمیم نهایی را بهبود می‌دهد؟». این دو کمیت فقط در صورت وجود رابطه‌ی تجربی کافی هم‌راستا خواهند بود.

^۹Decision Shift

^{۱۰}Cognitive Debiasing Paradox

در نتیجه، رویکرد همیشه‌فعال ممکن است بخشی از نمونه‌ها را اصلاح و بخشی دیگر را خراب کند. مسیر طبیعی، **مداخله‌ی انتخابی**^{۱۱} است: سامانه فقط وقتی از Bias-aware استفاده کند که سود مورد انتظار آن از Strong بیشتر باشد. این ایده در پژوهش حاضر از طریق تحلیل ظرفیت بالقوه ارزیابی می‌شود و ساخت یک مسیر یاب آموخته‌شده در محدوده‌ی کار آینده قرار دارد؛ جزئیات روش و نتایج آن به ترتیب در فصل‌های سوم تا پنجم بیان می‌شوند.

۲-۶- معیارهای ارزیابی و استنباط آماری

ارزیابی باید میان سطح عملکرد، تعادل میان کلاس‌ها، پایداری زمانی و اثر زوجی مداخله تمایز بگذارد. دقت و Macro-F1 دو معیار اصلی‌اند:

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N [\hat{y}_i = y_i], \quad (11.2)$$

$$\text{MacroF} = \frac{1}{K} \sum_{k=1}^K F1_k. \quad (12.2)$$

دقت، سهم کل پیش‌بینی‌های صحیح را نشان می‌دهد؛ در مقابل، Macro-F1 به هر کلاس وزن برابر می‌دهد و در حضور عدم‌توازن برچسب‌ها مانع پنهان‌شدن عملکرد ضعیف کلاس‌های کم‌فراوان می‌شود. تعریف آموزشی جداگانه‌ی دقت، بازیابی و F1 برای هر کلاس در این فصل لازم نیست. شکاف زمانی نیز مطابق رابطه‌ی (۱.۱) محاسبه می‌شود، اما تنها در کنار عملکرد unseen و معیارهای سطح کلاس تفسیر خواهد شد.

چون Strong و Bias-aware روی همان ادعاها اجرا می‌شوند، مقایسه باید زوجی باشد. اگر n_0 تعداد نمونه‌هایی باشد که مداخله خطای Strong را اصلاح کرده و n_1 تعداد نمونه‌هایی که پاسخ صحیح آن را خراب کرده است، اختلاف دقت برابر است با

¹¹Selective Intervention

$$\Delta Acc = \frac{n_{01} - n_{10}}{N}. \quad (13.2)$$

این نمایش مستقیماً نشان می‌دهد اثر خالص از توازن اصلاح و تخریب پاسخ‌ها حاصل می‌شود. آزمون مکنمار عدم‌تقارن همین دو سلول را تحت فرض صفر $n_{01} = n_{10}$ می‌سنجد [۱۶]. برای تعداد کم موارد ناهم‌خوان، نسخه‌ی دقیق دو جمله‌ای و در غیر این صورت نسخه‌ی مناسب تقریبی به کار می‌رود؛ جزئیات اجرایی در فصل سوم مشخص می‌شود.

فاصله‌ی اطمینان اختلاف معیارها با بوت‌استرپ زوجی^{۱۲} برآورد می‌شود؛ یعنی شناسه‌ی نمونه همراه با هر دو پیش‌بینی بازنمونه‌گیری می‌گردد تا ساختار جفت‌ها حفظ شود [۹]. صدک‌های توزیع بازنمونه‌گیری، عدم قطعیت اثر را نشان می‌دهند و مانع تفسیر قطعی اختلاف‌های کوچک می‌شوند. در تحلیل انواع سوگیری نیز اندازه‌ی نمونه‌ی هر گروه همراه با فاصله‌ی اطمینان گزارش می‌شود.

انجام آزمون جداگانه برای چندین مدل، پیکره یا نوع سوگیری خطر مثبت کاذب را افزایش می‌دهد. روش Holm با مرتب‌سازی مقادیر احتمال و اعمال آستانه‌های مرحله‌ای، خطای خانواده‌ای را کنترل می‌کند. بنابراین نتیجه‌های اسمی از یافته‌هایی که پس از تصحیح چندآزمونی باقی می‌مانند جدا گزارش می‌شوند. کالیبراسیون اطمینان نیز در تفسیر آشکارساز اهمیت دارد، زیرا اطمینان بالا لزوماً با احتمال تجربی صحت یا سود پایین‌دستی برابر نیست [۱۰].

۷-۲ - شکاف پژوهشی و چارچوب نظری پایان‌نامه

مرور ادبیات چند خط نزدیک اما عمدتاً جدا از هم را نشان می‌دهد. حقیقت‌سنجی مبتنی بر ادعا و شاهد بر صحت حکم و کیفیت شواهد تمرکز دارد؛ مهندسی پرامپت به فعال‌سازی استدلال و بازبینی پاسخ می‌پردازد؛ پژوهش زمانی افت عملکرد و منسوخ‌شدن دانش را مطالعه می‌کند؛ و ادبیات سوگیری شناختی اثر صورت‌بندی و میان‌برهای قضاوت را بررسی می‌نماید. جدول ۱-۲ این جریان‌ها و ارتباطشان با مسئله‌ی حاضر را در یک نمای واحد خلاصه می‌کند.

¹²Paired Bootstrap

جدول (۱-۲) جمع‌بندی ادبیات مرتبط و جایگاه پژوهش حاضر.

خط پژوهشی	تمرکز و نمونه‌های شاخص	شکاف نسبت به مسئله‌ی حاضر
حقیقت‌سنجی ادعا	طبقه‌بندی چندکلاسه در LIAR و اتصال حکم به شاهد در FEVER [۲۹، ۲۴]	تعمیم زمانی و مداخله‌ی شناختی را هم‌زمان نمی‌سنجد
حقیقت‌سنجی وب	بازیابی و ارزیابی شواهد چندمنبعی در AVeriTeC [۱۹]	رفتار بسته و اثر پرامپت بر دانش پارامتری محور اصلی نیست
استدلال و بازیابی LLM	CoT، HiSS و CoVe [۳۰، ۳۳، ۷]	انتقال زمانی و نشانه‌های سوگیری را یکپارچه نمی‌کند
ارزیابی زمانی	دانش زمان‌آگاه، تغییر دامنه و تقسیم زمانی [۳۲، ۲۰، ۲۲، ۱، ۶]	اثر مداخله‌ی شناختی بر تصمیم حقیقت‌سنج را بررسی نمی‌کند
سوگیری و اطلاعات نادرست	قاب‌بندی، میان‌برهای شناختی و پذیرش اطلاعات [۲۶، ۲۷، ۸، ۱۷]	میان نشانه‌ی متنی و سود آن برای حقیقت‌سنجی تمایز تجربی نمی‌گذارد
آزمون سوگیری در LLM	پوشش گسترده‌ی الگوهای شناختی در MindScope [۳۱]	از سیگنال آشکارشده برای ارزیابی تعمیم زمانی حقیقت‌سنجی استفاده نمی‌کند
پژوهش حاضر	آشکارساز سوگیری، سه پرامپت و مقایسه‌ی seen/unseen	اتصال تعمیم زمانی، مداخله و جابه‌جایی تصمیم

شکاف اصلی این است که اثر افزودن نشانه‌های سوگیری استخراج‌شده توسط یک مدل مستقل بر حقیقت‌سنجی بسته‌ی ادعاهای جدید، به‌ویژه با تفکیک اثر بر دقت، شکاف زمانی و سیاست تصمیم، کمتر به‌صورت یکپارچه مطالعه شده است. این مسئله صرفاً مقایسه‌ی دو متن پرامپت نیست؛ زنجیره‌ای دومارحله‌ای دارد که در آن خطا یا عدم‌سودمندی سیگنال بالادستی می‌تواند به تصمیم پایین‌دستی منتقل شود.

چارچوب نظری پایان‌نامه پنج متغیر را به هم متصل می‌کند: ادعا X ، سیگنال پیش‌بینی‌شده‌ی سوگیری $\hat{B}$ ، راهبرد پرامپت P ، رژیم زمانی Z و حکم مدل $\hat{Y}$. صورت فشرده‌ی آن چنین است:

$$\hat{B} = g_{\phi}(X), \quad \hat{Y} = f_{\theta}(X, P, \hat{B}, Z). \quad (۱۴.۲)$$

این چارچوب سه پرسش تحلیلی می‌سازد: آیا سطح عملکرد با انتقال از seen به unseen تغییر می‌کند؛ آیا افزودن $\hat{B}$ نسبت به Strong سود خالص ایجاد می‌کند؛ و آیا مداخله، مستقل از سود، نرخ انتخاب کلاس‌ها را جابه‌جا می‌سازد. پاسخ به پرسش نخست باید با توجه به Difficulty $\neq$ Novelty و پاسخ به دو پرسش بعدی با توجه به Downstream Utility $\neq$ Detector Accuracy و پیشین‌القاشده توسط پرامپت تفسیر شود.

بر این اساس، سهم مفهومی پژوهش نه ادعای کلی مفیدبودن سوگیری، بلکه طراحی آزمونی برای تفکیک

سه پیامد «بهبود صلاحیت»، «هموارشدن ظاهری شکاف زمانی» و «تغییر جهت‌دار تصمیم» است. فصل سوم نحوه‌ی عملیاتی کردن این چارچوب و فصل چهارم شواهد مربوط به هر پیامد را ارائه می‌کنند.

۲-۸- جمع‌بندی

این فصل مبانی لازم برای فهم پژوهش را در ساختاری منسجم ارائه کرد. حقیقت‌سنجی بسته از راستی‌آزمایی مبتنی بر شواهد متمایز شد و نقش دانش پارامتری و مرز زمانی آن توضیح داده شد. سپس نشان داده شد که انتقال زمانی علاوه بر مواجهه‌ی احتمالی، تحت تأثیر تغییر موضوع، برچسب، مفهوم و دشواری قرار دارد؛ از این رو، تازگی با دشواری و ناوردایی با صلاحیت یکسان نیست.

در محور شناختی، خروجی آشکارساز به عنوان نشانه‌ی متنی و نه حالت ذهنی یا برچسب حقیقت تعریف شد. افزودن این نشانه به پرامپت نیز مداخله‌ای دانسته شد که می‌تواند هم اثر وابسته به ادعا و هم پیشین عمومی ایجاد کند؛ بنابراین دقت آشکارساز تضمین‌کننده‌ی سود پایین دستی نیست. در پایان، معیارهای عملکرد، مقایسه‌ی زوجی و اصول استنباط آماری معرفی و شکاف پژوهشی در اتصال تعمیم زمانی، مداخله‌ی شناختی و جابه‌جایی تصمیم مشخص شد. فصل بعد این مفاهیم را به طراحی اجرایی، داده‌ها، مدل‌ها و پروتکل ارزیابی تبدیل می‌کند.

فصل ۳

مدل سازی و طراحی چارچوب پژوهش

۳-۱- مقدمه و صورت بندی مسئله

این فصل چارچوب نظری فصل دوم را به یک طراحی تجربی قابل اجرا تبدیل می کند. هدف، سنجش رفتار مدل های زبانی بزرگ در حقیقت سنجی ادعاهای قدیمی تر و جدیدتر و اندازه گیری اثر افزودن نشانه های سوگیری شناختی به پرامپت است. فصل حاضر فقط مشخص می کند داده ها چگونه آماده شده اند، مدل ها و مداخلات چگونه اجرا می شوند و تحلیل ها با چه قواعدی محاسبه خواهند شد؛ نتیجه ها و تفسیر آن ها منحصرراً در فصل چهارم ارائه می شوند.

مجموعه ی ورودی به صورت

$$\mathcal{D} = \{(x_i, t_i, y_i, d_i)\}_{i=1}^N \quad (1.3)$$

تعریف می شود که در آن x_i متن ادعا، t_i تاریخ آن، y_i برچسب مرجع و d_i شناسه ی پیکره است. برای هر ادعا، آشکارساز بالادستی g_ϕ مجموعه ی سیگنال های سوگیری B_i را تولید می کند و مدل زبانی M_m با راهبرد پرامپتی P_p حکم $\hat{y}_{i,m,p}$ را می سازد. در مقایسه ی اصلی، ادعا، تاریخ، مدل، فضای برچسب و قواعد حقیقت سنجی ثابت اند و تنها وجود بلوک اطلاعات سوگیری تغییر می کند؛ از این رو، اثر Strong و Bias-aware در سطح همان

نمونه قابل مقایسه است.

پرسش های روش شناختی پژوهش در پنج محور خلاصه می شوند: نخست، عملکرد مدل ها در دور ژیم seen و unseen چه تفاوتی دارد؛ دوم، آیا Strong نسبت به Naive سودمند است؛ سوم، افزودن سیگنال سوگیری به Strong چه اثر خالصی دارد؛ چهارم، آیا این اثر میان دور ژیم زمانی، مدل ها، پیکره ها یا انواع سوگیری متفاوت است؛ و پنجم، آیا تغییر مداخله فقط صحت پاسخ را عوض می کند یا الگوی انتخاب برچسب را نیز جابه جا می سازد. تحلیل انتخاب میان دو راهبرد نیز به عنوان ارزیابی ظرفیت بالقوه تعریف می شود و ساخت یک مسیریاب قابل استقرار جزو نتایج انجام شده ی پژوهش نیست.

برای صورت بندی تضادهای اصلی، اگر $A_{p,z}$ عملکرد روش p در رژیم زمانی z باشد، سه کمیت زیر پیش از مشاهده ی نتیجه تعریف می شوند:

(۲.۳)

$$\Delta_{S-N} = A_S - A_N, \quad \Delta_{B-S} = A_B - A_S, \quad I_T = (A_{B,u} - A_{S,u}) - (A_{B,s} - A_{S,s}).$$

Δ_{S-N} اثر ساختاردهی عمومی پرامپت، Δ_{B-S} اثر خالص مداخله ی آگاه از سوگیری و I_T تعامل زمان و مداخله را نشان می دهد. برای مقایسه ی اصلی، فرض صفر $\Delta_{B-S} = 0$ است؛ جهت و اندازه ی اثر از داده تعیین می شود. فرض زمانی نیز به صورت آزمون تفاوت دو رژیم تعریف می شود و بدون کنترل ترکیب پیکره، به رابطه ی علی میان تازگی و دشواری تعبیر نخواهد شد.

نمادهای اصلی در جدول ۳-۱ آمده اند. تعریف دقت، Macro-F1، شکاف زمانی و تمایزهای مفهومی آنها در فصل های اول و دوم ارائه شده است و در این فصل دوباره مشتق نمی شوند.

جدول (۳-۱) نمادهای اصلی مورد استفاده در طراحی پژوهش.

نماد	تعریف	نماد	تعریف
x_i	متن ادعای i	t_i	تاریخ ادعا
y_i	برچسب مرجع	$\hat{y}_i$	برچسب پیش بینی شده
d_i	پیکره ی مبدأ	m	مدل زبانی
p	راهبرد پرامپتی	z_i	وضعیت seen/unseen
B_i	سیگنال های سوگیری	q_{ik}	اطمینان کلاس سوگیری k
C_i	درستی حکم در سطح نمونه	G	شکاف عملکرد زمانی

۳-۲- طراحی کلی آزمایش و معماری دو فازی

پژوهش یک طراحی چندعاملی دارد. عامل مداخله سه سطح Naive، Strong و Bias-aware؛ عامل زمان دو سطح seen و unseen؛ و عوامل ناهمگنی شامل مدل زبانی و پیکره هستند. هر سلول آزمایشی با چهارگانه‌ی (m, d, p, z) مشخص می‌شود. این ساختار امکان می‌دهد مقایسه‌های اصلی درون مدل و پیکره انجام شوند و سپس میزان پایداری الگوها میان خانواده‌های مختلف بررسی شود.


معماری اجرا دو فاز متوالی دارد. در فاز نخست، متن‌های MindScope برای تنظیم دقیق آشکارساز سوگیری استفاده می‌شوند. آشکارساز پس از آموزش، روی ادعاهای حقیقت‌سنجی اجرا و برای هر ادعا مجموعه‌ای از نام سوگیری‌ها و نمره‌های اطمینان تولید می‌کند. در فاز دوم، هر پیکره به ساختار مشترک نگاشت، برچسب‌ها استاندارد و ادعاها بر اساس مرز زمانی عملیاتی تفکیک می‌شوند. سپس سه پرامپت برای هر نمونه ساخته و مدل‌های زبانی در شرایط استنتاج ثابت فراخوانی می‌شوند. خروجی‌های معتبر در سطح نمونه ذخیره و برای تحلیل‌های زمانی، زوجی و زیرگروهی استفاده می‌گردند.

نمای فشرده‌ی زنجیره چنین است:

$$\begin{aligned} x_i &\xrightarrow{g_\phi} B_i, \\ (x_i, t_i, B_i, P_p) &\xrightarrow{M_m} \hat{y}_{i,m,p}, \\ (y_i, \hat{y}_i, z_i, B_i, m, d, p) &\xrightarrow{A} \text{شاخص‌های تحلیل}. \end{aligned} \quad (3.3)$$

در این رابطه A مجموعه‌ی قواعد تحلیل است، نه یک مدل آموخته‌شده. جدایی فازها اهمیت روش‌شناختی دارد: دقت طبقه‌بندی سوگیری کیفیت مؤلفه‌ی بالادستی را می‌سنجد، در حالی که تغییر حکم حقیقت، سود پایین‌دستی همان سیگنال را اندازه می‌گیرد. این دو ارزیابی مستقل گزارش می‌شوند.

شکل ۳-۱ جریان داده را از آموزش آشکارساز تا تولید حکم و تحلیل نشان می‌دهد. سیگنال سوگیری فقط در مسیر Bias-aware وارد مدل حقیقت‌سنج می‌شود؛ بنابراین Naive و Strong همان ادعاها را بدون این سیگنال دریافت می‌کنند. مقایسه‌ی Strong و Bias-aware تضاد اصلی برای سنجش مداخله است و مقایسه‌ی Naive و Strong نقش کنترل کیفیت عمومی پرامپت را دارد.



شکل (۳-۱) معماری انتها به انتهای چارچوب برای تولید سیگنال سوگیری و ارزیابی حقیقت‌سنجی در انتقال زمانی.

برای کاهش اختلاط عوامل، در هر تضاد زوجی شناسه‌ی ادعا، تاریخ، مدل، فضای برچسب، پارامترهای استنتاج و نسخه‌ی داده ثابت نگه داشته می‌شوند. تفاوت پیکره‌ها یا مدل‌ها ابتدا در سلول‌های جداگانه تحلیل و تنها سپس با قواعد ازپیش‌تعریف‌شده تجمیع می‌شود. تحلیل‌های اصلی شامل تعمیم زمانی و مقایسه‌ی زوجی دو راهبرد نهایی‌اند؛ تحلیل نوع سوگیری، موضوع، گوینده، اطمینان و انتخاب مداخله ماهیت اکتشافی دارند و با اندازه‌ی نمونه و فاصله‌ی اطمینان گزارش می‌شوند.

۳-۳- فاز نخست: آموزش و استفاده از

آشکارساز سوگیری

پیکره‌های حقیقت‌سنجی برچسب مستقیم سوگیری شناختی ندارند؛ ازاین‌رو، فاز نخست تابعی می‌سازد که متن ادعا را به یک یا چند نشانه‌ی قابل استفاده در پرامپت نگاشت کند. منبع آموزش، نسخه‌ی مورد استفاده‌ی MindScope با ۵۱۷۰ نمونه و ۷۲ کلاس است [۳۱]. هر نمونه شامل نام سوگیری، توصیف، سناریو و معیار است؛ متن سناریو ورودی مدل و نام سوگیری هدف تک‌برچسبی آموزش قرار می‌گیرد. در نسخه‌ی پردازش‌شده مقدار گمشده وجود نداشت.

نام‌های سوگیری با دو نگاشت ثابت label2id و id2label به شناسه‌های صفر تا ۷۱ تبدیل شدند. ثابت‌بودن این نگاشت‌ها در آموزش، ارزیابی و استنتاج مانع جابه‌جایی معنای شناسه‌های کلاس میان اجراها می‌شود. داده به‌صورت لایه‌ای و با دانه‌ی تصادفی ۴۲ به نسبت ۱۵/۱۵/۷۰ تقسیم شد؛ در نتیجه ۳۶۱۹ نمونه برای آموزش، ۷۷۵ نمونه برای اعتبارسنجی و ۷۷۶ نمونه برای آزمون به دست آمد. لایه‌بندی برای حفظ تقریبی توزیع ۷۲ کلاس در هر سه قسمت استفاده شد.

مدل پایه microsoft/deberta-v3-base است. دلیل انتخاب آن، توان مناسب خانواده‌ی DeBERTa در بازنمایی متن و کارایی هدف پیش‌آموزش نسخه‌ی سوم برای طبقه‌بندی است [۱۱]. مبانی معماری و تشخیص توکن جایگزین‌شده در فصل دوم توضیح داده شد. در این فاز، یک سر طبقه‌بندی ۷۲ کلاسه روی بازنمایی نهایی قرار گرفت و مدل با آنتروپی متقاطع تنظیم دقیق شد. متن با توکن‌ساز متناظر مدل پردازش می‌شود؛ طول ورودی حداکثر ۵۱۲ توکن است، ورودی‌های بلند برش می‌خورند و پرکردن ورودی‌های کوتاه در سطح دسته انجام می‌شود.

تمام فرآیندهای اجرای نهایی در جدول ۲-۳ گردآوری شده اند. بهترین ایست با Weighted-F1 روی اعتبارسنجی انتخاب می شود، اما گزارش علمی آشکارساز علاوه بر آن شامل دقت و Macro-F1 است. این جدول مرجع واحد تنظیمات است و مقادیر آن در متن تکرار نمی شوند.

جدول (۲-۳) داده، معماری و فرآیندهای آموزش آشکارساز سوگیری.

مؤلفه	مقدار	مؤلفه	مقدار
مدل پایه	/deberta-v3 base	تعداد کلاس	۷۲
نمونه های آموزش / اعتبارسنجی / آزمون	۷۷۶/۷۷۵/۳۶۱۹	نوع تقسیم	لایه ای
حداکثر طول	۵۱۲ توکن	دانه ی تصادفی	۴۲
نرخ یادگیری	2×10^{-5}	کاهش وزن	۰/۰۱
اندازه ی دسته ی آموزش	۱۶	اندازه ی دسته ی ارزیابی	۴
تعداد دوره	۱۰	گام های گرم سازی	۵۰۰
دقت نیمه ممیز شناور	FP16 فعال	فاصله ی ثبت لاگ	۱۰۰ گام
ارزیابی و ذخیره	پایان هر دوره	سقف نقاط واریسی	۲
معیار انتخاب بهترین مدل	Weighted-F1	سخت افزار	/Tesla P100 16GB
تابع هدف	آنتروپی متقاطع	چارچوب اجرا	/PyTorch Hugging Face

پس از آموزش، آشکارساز روی متن ادعاهای حقیقت سنجی اجرا می شود و برای هر ادعا بردار احتمال q_i را می سازد. اگرچه آموزش تک برچسبی است، در استفاده ی پایین دستی تنها کلاس با بیشترین احتمال نگهداری نمی شود. تمام کلاس هایی که از آستانه ی عملیاتی $\gamma = 0.30$ عبور کنند به همراه نمره ی خود ذخیره می شوند:

$$B_i = \{(b_k, q_{ik}) : q_{ik} > 0.30\}. \quad (4.3)$$

این تبدیل امکان می دهد چند نشانه ی نسبتاً محتمل در پرامپت قرار گیرند و عدم قطعیت آشکارساز نیز از بین نرود. نام کلاس، تعریف ثبت شده و نمره ی اطمینان اجزای قابل استفاده برای ساخت بلوک سوگیری اند. اگر هیچ کلاس از آستانه عبور نکند، این وضعیت به صورت صریح ثبت می شود تا با خطای اجرای آشکارساز اشتباه نشود. نمره ی q_{ik} فقط اطمینان مدل نسبت به انطباق متن با کلاس b_k است و کالیبراسیون یا سود مداخله را تضمین

نمی‌کند. مطابق تمایز فصل دوم، دقت آشکارساز با سود آن برای حقیقت‌سنجی برابر نیست. در نتیجه، آستانه‌ی ۳۰٪ یک قاعده‌ی تولید سیگنال است و نباید به‌عنوان آستانه‌ی اثبات‌شده‌ی انتخاب مداخله تفسیر شود. اثر اطمینان در تحلیل‌های اکتشافی سنجیده می‌شود، بی‌آنکه نتیجه‌ی آن در این فصل پیش‌فرض گرفته شود. برای جلوگیری از نشت اطلاعات، برچسب حقیقت پیکره‌های پایین‌دستی در تولید B_i دخالت ندارد. خروجی آشکارساز با شناسه‌ی ادعا پیوند می‌خورد و نسخه‌ی مدل، نگاشت کلاس‌ها و آستانه همراه فایل خروجی ثبت می‌شوند. بدین ترتیب می‌توان مرحله‌ی تولید سیگنال را مستقل از فراخوانی مدل‌های زبانی بازاجرا و ممیزی کرد.

۳-۴- فاز دوم: پیکره‌های حقیقت‌سنجی،

استانداردسازی و تفکیک زمانی

فاز دوم برای کاهش وابستگی نتیجه به یک دامنه‌ی خاص از پنج پیکره با موضوع و فضای برچسب متفاوت استفاده می‌کند. اندازه‌ها در جدول ۳-۳ مربوط به نسخه‌های پردازش‌شده‌ی پروژه‌اند و ممکن است با نسخه‌ی خام منابع تفاوت داشته باشند. تنوع پیکره‌ها امکان مقایسه‌ی ادعاهای عمومی، سیاسی، علمی، عددی و زمان‌مند را فراهم می‌کند؛ بااین‌حال، هر پیکره ابتدا جدا تحلیل می‌شود تا اندازه‌ی بزرگ‌تر یک منبع بر میانگین کل غالب نشود.

جدول (۳-۳) پیکره‌های حقیقت‌سنجی و ویژگی نسخه‌های پردازش‌شده.

پیکره	تعداد	ماهیت اصلی	مدیریت برچسب
/ClaimReview2024+ CRP	۳۰۰	ادعاهای واقعی و جدیدتر [۳]	فضای برچسب نسخه‌ی پردازش‌شده
FACT5	۱۵۰	ادعاهای پیچیده و حقیقت چندسطحی [۵]	حفظ برچسب‌های چندسطحی
Matter-of-Fact	۸۳۶۰	ادعاهای علمی مواد و ارزیابی زمان‌محور [۱۳]	فضای اصلی پیکره
/TRACeR PolitiFact-Hidden	۱۴۹۹۴	ادعاهای سیاسی و نیمه‌حقیقت [۲۳]	حفظ Half-True در استنتاج
TSVer	۳۰۴	استدلال زمانی و عددی با سری زمانی [۲۱]	فضای اصلی پیکره

فایل‌های مبدأ طرح‌واره‌ی یکسانی ندارند. لایه‌ی استانداردسازی برای هر سطر پنج فیلد پایه‌ی شناسه، متن ادعا، تاریخ، برچسب و سوگیری‌های آشکارشده را می‌سازد. فراداده‌هایی مانند منبع، گوینده، موضوع یا شواهد،

در صورت وجود، با نام های ثابت نگهداری می شوند. تاریخ ها به قالب واحد تبدیل و سطرهای فاقد متن، تاریخ قابل استفاده یا برچسب مرجع برای تحلیل مربوط علامت گذاری می شوند. شناسه ی یکتا نیز برای کنترل سطرهای تکراری در سطح زوج پیکره و ادعا به کار می رود.


فضای برچسب هنگام استنتاج تا حد امکان همان فضای اصلی هر پیکره است؛ بنابراین مدل تنها میان برچسب هایی انتخاب می کند که برای همان داده معنا دارند. این تصمیم از تبدیل زودهنگام همه ی وظایف به یک مسئله ی دودویی جلوگیری می کند. برای تحلیل های بین پیکره ای، نسخه ای استاندارد با فضای

$$\mathcal{Y}^* = \{\text{Supported, Refuted, Misleading, NEI}\}. \quad (5.3)$$

ساخته می شود. نگاشت Half-True به Misleading فقط در تحلیل هایی اعمال می شود که به تجمیع مشترک نیاز دارند. خروجی اصلی هر مدل، برچسب خام، برچسب نرمال شده و در صورت کاربرد برچسب استاندارد شده را جدا نگه می دارد تا اثر folding قابل ممیزی باشد. تحلیل حساسیت با و بدون این نگاشت انجام می شود و نتیجه ی آن در فصل چهارم گزارش خواهد شد.

تفکیک زمانی مطابق تعریف عملیاتی فصل نخست انجام می شود، اما مرز می تواند به مدل و پیکره وابسته باشد. اگر $\tau_{m,d}$ مرز ثبت شده برای مدل m و پیکره ی d باشد، وضعیت نمونه از رابطه ی (۲.۱) با جایگزینی همین مرز به دست می آید. وابستگی مرز به مدل ضروری است، زیرا زمان انتشار یا به روزرسانی مدل ها یکسان نیست. مقدار دقیق مرز همراه تنظیمات هر اجرا ذخیره می شود و هیچ مرزی از روی عملکرد مشاهده شده تنظیم نمی گردد. این تقسیم یک تقریب از مواجهه ی زمانی است، نه اثبات عضویت یا عدم عضویت ادعا در داده های پیش آموزش. برای مدل های بسته، ترکیب کامل داده ی آموزش در دسترس نیست و تاریخ انتشار یک ادعا نیز غیاب گزاره های معادل یا اطلاعات سازنده ی آن را تضمین نمی کند. بنابراین در سراسر تحلیل، unseen به معنای «پس از مرز عملیاتی» و seen به معنای «پیش از یا برابر با مرز» است.

علاوه بر متغیر دودویی، فاصله ی پیوسته ی هر ادعا از مرز برای تحلیل های تشخیصی محاسبه می شود:



شکل (۳-۲) تفکیک مدل محور seen/unseen و فاصله‌ی هر ادعا از مرز عملیاتی.

$$\Delta t_{i,m,d} = \frac{t_i - \tau_{m,d}}{30/44}, \quad (6.3)$$

که واحد آن ماه است؛ مقادیر منفی پیش از مرز و مقادیر مثبت پس از آن قرار دارند. این کمیت اجازه می دهد بررسی شود آیا تغییر رفتار صرفاً در دو سوی مرز دیده می شود یا با افزایش فاصله ی زمانی روندی پیوسته دارد. تحلیل اصلی همچنان بر تفکیک از پیش تعریف شده استوار است و تحلیل فاصله ماهیت تکمیلی دارد. پیش از ساخت پرامپت، کنترل کیفیت شامل یکتایی شناسه، اعتبار تاریخ، عضویت برچسب در فضای مجاز، تطابق سیگنال سوگیری با شناسه ی ادعا و ثبت منشأ هر سطر انجام می شود. هیچ سطر نامعتبر به صورت خاموش حذف نمی شود؛ تعداد و علت کنارگذاری ها در گزارش ممیزی داده ثبت می گردد. این جداسازی مانع آمیختن خطای آماده سازی داده با خطای حقیقت سنجی مدل می شود.

۳-۵ طراحی سه راهبرد پرامپتی و

مدل های مورد ارزیابی

سه راهبرد پرامپتی برای جداسازی اثر «تعریف وظیفه»، «راهنمای ساختار یافته ی حقیقت سنجی» و «اطلاعات سوگیری» طراحی شده اند. همه ی راهبردها متن ادعا، تاریخ در صورت وجود، فضای برچسب مجاز و قالب خروجی را دریافت می کنند. تفاوت آن ها در میزان راهنمایی افزوده شده است:

$$\begin{aligned} P_N &= [\text{Task, Labels, Claim, Date, Output}], \\ P_S &= P_N + [\text{LabelDefinitions, VerificationRules}], \\ P_B &= P_S + [\text{BiasSignals, BiasDefinitions, CognitiveChecks}]. \end{aligned} \quad (7.3)$$

راهبرد Naive. این حالت حداقل دستور لازم برای انتخاب یک برچسب معتبر را ارائه می کند و نقش خط پایه ی ساده را دارد. مدل باید بدون فهرست کنترل تفصیلی، حکم را از میان برچسب های همان پیکره انتخاب

کند. این راهبرد برای سنجش اثر ساختاردهی عمومی در مقایسه با Strong استفاده می‌شود.

راهبرد Strong. علاوه بر اجزای Naive، تعریف دقیق هر برجسب و قواعد بررسی ادعای مرکزی، موجودیت‌ها، رابطه‌ها، تاریخ، عدد و واحد، مقایسه، کمیت‌نما، نفی و علیت را در اختیار مدل قرار می‌دهد. هدف آن است که خط پایهی مقایسه با مداخله‌ی شناختی خود یک پرامپت ضعیف نباشد. قواعد در همه‌ی نمونه‌های یک پیکره ثابت‌اند و فقط بخش ادعا و تاریخ تغییر می‌کند.

راهبرد Bias-aware. این راهبرد تمام اجزای Strong را بدون حذف نگه می‌دارد و نام، تعریف و نمره‌ی سیگنال‌های عبورکرده از آستانه را به آن می‌افزاید. سپس مدل هدایت می‌شود نشانه‌هایی مانند حذف زمینه، گزینش شواهد، اغراق، قاب‌بندی هیجانی، ادعای علیّ بیش از شواهد، ناسازگاری زمانی و مقایسه‌ی گمراه‌کننده را بررسی کند. پرامپت صریحاً بیان می‌کند که وجود سوگیری نه شاهد کذب است و نه جایگزین بررسی واقعیت؛ حکم نهایی باید بر معنای ادعا و تعریف کلاس‌ها استوار باشد.

مقایسه‌ی اصلی میان P_S و P_B است. در این تضاد، مدل، ادعا، تاریخ، فضای برجسب، قواعد حقیقت‌سنجی و تنظیمات تولید ثابت می‌مانند و تنها بلوک شناختی افزوده می‌شود. برای نمونه‌ی i ، اثر صحت در سطح نمونه $\tau_i = C_i^B - C_i^S$ و عضو مجموعه‌ی $\{-1, 0, +1\}$ است. این تعریف محاسباتی به‌ترتیب تخریب پاسخ صحیح، بی‌تغییری صحت و اصلاح خطا را بازنمایی می‌کند و مبنای تحلیل زوجی بخش ۳-۷ است.

برای بررسی ناهمگنی اثر، خانواده‌هایی با اندازه، آموزش دستوری و ارائه‌دهنده‌ی متفاوت به کار رفته‌اند. جدول ۳-۴ نام‌های ثبت‌شده در اجرا را نشان می‌دهد. هدف جدول رتبه‌بندی تجاری مدل‌ها نیست؛ هر مدل یک سطح از عامل m در طراحی آزمایش است و نتیجه‌ها در سطح نسخه‌ی ثبت‌شده تفسیر می‌شوند.

جدول (۳-۴) مدل‌های زبانی مورد استفاده و نقش آن‌ها در طراحی چندمدلی.

مدل	سازنده	نقش در ارزیابی
GPT-4o-mini	OpenAI	مدل تجاری سبک و مرجع API-محور
Llama-3.1-8B-Instruct	Meta	مدل بازوزن با اندازه‌ی کوچک‌تر
Llama-3.1-70B-Instruct	Meta	مدل بازوزن بزرگ‌تر از همان خانواده
Qwen2.5-72B-Instruct	Alibaba	خانواده‌ی دستوری بزرگ با آموزش متفاوت
DeepSeek-V3/DeepSeek Chat	DeepSeek	بررسی پایداری اثر در خانواده‌ای مستقل
Grok-3/Grok-3-mini	xAI	اجراهای تکمیلی برای سنجش ناهمگنی

ثبت نام دقیق مدل و ارائه‌دهنده ضروری است، زیرا نام خانوادگی به‌تنهایی نسخه‌ی وزن‌ها، تاریخ به‌روزرسانی یا رفتار سرویس را مشخص نمی‌کند. برای هر اجرا شناسه‌ی مدل، زمان اجرا، پیکره، روش پرامپت و مرز زمانی

در فراداده نگهداری می شود. اگر یک سرویس نام یا نسخه را تغییر دهد، خروجی های پیش و پس از تغییر در یک سلول ادغام نمی شوند مگر آنکه هم ارزی آن ها مستند شده باشد.

صدور حکم در این پژوهش بسته است: مدل در مرحله ی نهایی به موتور جست و جوی زنده یا سامانه ی بازیابی متصل نیست. این انتخاب برای سنجش دانش پارامتری و اثر مداخله ی پرامپتی با عوامل مزاحم کمتر انجام شده است. در طراحی مبتنی بر شواهد، کیفیت بازیابی، تازگی سند و استنتاج از شاهد نیز بر خروجی اثر می گذارند و جداسازی منشأ تغییر دشوارتر می شود. بنابراین نتیجه های این فصل و فصل چهارم درباره ی حقیقت سنجی بسته اند و به عنوان عملکرد یک سامانه ی کامل وب محور تعمیم داده نمی شوند.

۳-۶- پروتکل اجرا، اعتبارسنجی خروجی و

بازتولید پذیری

همه ی روش ها تا حد امکان در شرایط استنتاج ثابت اجرا می شوند. دما صفر، top_p برابر ۱ و سقف خروجی ۱۲۸ توکن است. دمای صفر برای کاهش نویز نمونه گیری انتخاب شده تا اختلاف دو پرامپت کمتر با تصادف تولید آمیخته شود؛ با این حال، قطعی بودن کامل سرویس های بسته تضمین نمی شود و شناسه و زمان هر اجرا ثبت می گردد. ترتیب نمونه ها و مقادیر پیکربندی برای همه ی روش های قابل مقایسه ثابت نگه داشته می شوند.

مدل موظف است یک خروجی ساختاریافته با کلید label تولید کند؛ در روش های ساختاریافته امکان ثبت توضیح کوتاه نیز وجود دارد، اما فقط برچسب نهایی وارد معیارهای اصلی می شود. متن توضیح، مطابق محدودیت وفاداری استدلال های تولید شده، مشاهده ی مستقیم فرایند درونی مدل تلقی نمی شود [۲۵]. پارسر ابتدا بلوک JSON را استخراج، نویسه ها و فاصله ها را نرمال و برچسب را با فضای مجاز پیکره تطبیق می دهد. خروجی فقط هنگامی معتبر است که $\hat{y}_i \in \mathcal{V}_{d_i}$ باشد.

اگر پاسخ فاقد JSON قابل استخراج یا دارای برچسب خارج از فضای مجاز باشد، همان درخواست یک بار دیگر با پرامپت ثابت اجرا می شود. پاسخ نامعتبر پس از تلاش مجدد، خطای زیرساختی ثبت می شود و به صورت مصنوعی «پیش بینی غلط» محسوب نمی گردد. تعداد خروجی های معتبر، نامعتبر، ناقص و خطا دار جداگانه گزارش می شوند تا نرخ شکست سرویس با توان حقیقت سنجی مدل مخلوط نشود. مقایسه ی زوجی نیز فقط روی اشتراک نمونه هایی انجام می شود که هر دو روش برای آن ها خروجی معتبر دارند.

حقیقت‌سنجی ادعاهای جدید در مدل‌های زبانی بزرگ با کمک سوگیری‌های شناختی^۳: مدل‌سازی و طراحی چارچوب پژوهش

خطاهای شبکه، پایان مهلت و محدودیت نرخ از خطاهای قالب خروجی جدا می‌شوند. برای خطاهای موقت از عقب‌نشینی نمایی استفاده می‌شود؛ اگر d تأخیر اولیه باشد، فاصله‌ی تلاش k ام برابر $d_k = 2^k d$ است و تا سقف تلاش تعریف‌شده در پیکربندی ادامه می‌یابد. متن کامل خطا، زمان و شناسه‌ی درخواست در فایل گزارش ثبت می‌شود؛ اعتبارسنجی برچسب فقط پس از دریافت موفق پاسخ انجام می‌گیرد. خلاصه‌ی قواعد اجرا در جدول ۳-۵ آمده است. این جدول، مرجع تنظیمات استنتاج و بازتولیدپذیری فاز دوم است.

جدول (۳-۵) پروتکل استنتاج، اعتبارسنجی و ثبت خروجی.

مؤلفه	قاعده‌ی اجرا
پارامترهای تولید	$max_tokens = ۱۲۸$ و $top_p = ۱/۰$ ، $temperature = ۰$
قالب پاسخ	JSON دارای برچسب؛ توضیح کوتاه در صورت درخواست
اعتبار برچسب	فقط برچسب عضو فضای مجاز همان پیکره پذیرفته می‌شود
پاسخ نامعتبر	یک اجرای مجدد با همان پرامپت؛ سپس ثبت مستقل خطا
خطای موقت	تلاش مجدد با عقب‌نشینی نمایی و ثبت گزارش
تصادفی‌بودن	دانه‌ی ۴۲ برای تقسیم، توازن و بوت‌استرپ؛ دمای صفر برای LLM
فراداده‌ی اجرا	مدل، پیکره، روش، رژیم، زمان، مرز زمانی و نسخه‌ی پرامپت
سطح ذخیره	یک رکورد به‌ازای هر ادعا و فایل‌های تجمیعی مشتق‌شده

فاز نخست با Python و ابزارهای PyTorch، transformers، datasets، scikit-learn، pandas، numpy، accelerate و sentencepiece اجرا شده است. فاز دوم با Python و رابط‌های سازگار با قالب OpenAI API پیاده‌سازی شده و در اجراهای مختلف از درگاه‌های Avalai و OpenRouter استفاده شده است. فایل‌های نگاشت داده، پیکربندی مدل و سازنده‌ی پرامپت از یکدیگر جدا هستند تا تغییر یک جزء به بازنویسی کل خط لوله نیاز نداشته باشد.

برای هر ترکیب مدل، پیکره، روش و رژیم زمانی، خروجی در مسیر مستقل ذخیره می‌شود. هر رکورد حداقل شامل شناسه‌ی ادعا، متن و تاریخ، برچسب مرجع، برچسب خام و نرمال‌شده‌ی مدل، سیگنال‌های سوگیری، وضعیت اعتبار و خطای احتمالی است. ذخیره‌ی سطح نمونه اجازه می‌دهد هر عدد تجمیعی به پیش‌بینی‌های سازنده‌ی آن بازگردانده شود. فایل‌های خلاصه فقط محصول مشتق‌شده‌اند و معیارهای نهایی تا حد امکان دوباره از رکوردهای سطح نمونه محاسبه می‌شوند تا تغییر پیش‌پردازش یا نگاشت برچسب، خلاصه‌های قدیمی را معتبر جلوه ندهد.

بازتولیدپذیری با ثابت‌کردن دانه‌ی ۴۲ در تقسیم داده، توازن و بازنمونه‌گیری؛ ثبت نسخه‌ی مدل و پرامپت؛

ذخیره ی مرزهای زمانی؛ نگهداری نگاشت برچسب ها؛ و جداسازی خروجی خام از پردازش شده تقویت می شود. چون سرویس های بیرونی ممکن است در طول زمان تغییر کنند، بازتولید دقیق پاسخ مدل بسته همواره تضمین پذیر نیست؛ در عوض، همه ی ورودی ها، تنظیمات و خروجی های دریافت شده برای بازسازی تحلیل همان اجرا حفظ می شوند.

۳-۷- معیارهای ارزیابی و طرح تحلیل آماری

طرح تحلیل از سطح کیفیت داده آغاز و به ترتیب به عملکرد هر سلول، تعمیم زمانی، اثر زوجی مداخله، ناهمگنی و تحلیل ظرفیت انتخاب می رسد. پیش از هر محاسبه، رکورد باید دارای شناسه، برچسب مرجع و پیش بینی معتبر باشد و خطای حل نشده ی استنتاج نداشته باشد. سطرهای تکراری بر اساس زوج شناسه و پیکره کنترل می شوند و تعداد رکوردهای کنارگذاشته شده برای هر شرط گزارش می گردد. معیارها از فایل های سطح پیش بینی باز محاسبه و با خلاصه های زمان اجرا تطبیق داده می شوند.

عملکرد پایه و تعمیم زمانی. دقت و Macro-F1 مطابق روابط (۱۱.۲) و (۱۲.۲) محاسبه می شوند. دقت تصویر کلی و Macro-F1 عملکرد متوازن کلاس ها را ارائه می کند؛ ماتریس درهم ریختگی و معیارهای هر کلاس برای تشخیص تغییرات پنهان شده در میانگین استفاده می شوند. هر معیار ابتدا برای سلول (m, d, p, z) و سپس، در صورت تجمیع، با گزارش جداگانه ی میانگین بدون وزن و وزن دار محاسبه می شود.


شکاف تعمیم زمانی G_p بر اساس رابطه ی (۱.۱) برای هر راهبرد محاسبه می شود. برای توصیف تغییر قدر مطلق فاصله ی زمانی پس از مداخله، کمیت زیر به کار می رود:

$$TEG = |G_S| - |G_B|. \quad (۸.۳)$$

TEG یک آمار توصیفی این پژوهش است، نه معیار استاندارد تثبیت شده. مقدار مثبت فقط کاهش قدر مطلق شکاف را نشان می دهد و بدون بررسی سطح عملکرد unseen تفسیر نمی شود. برای همین، هر روش در دو بعد صلاحیت و پایداری نمایش داده می شود:

حقیقت‌سنجی ادعاهای جدید در مدل‌های زبانی بزرگ با کمک سوگیری‌های شناختی^۳: مدل‌سازی و طراحی چارچوب پژوهش

$$C_T = \text{Performance}_{\text{unseen}}, \quad S_T = -|G|. \quad (۹.۳)$$



شکل (۳-۳) چارچوب دوبعدی ارزیابی صلاحیت و پایداری زمانی.

مقایسه‌ی زوجی مداخله. مجموعه‌ی تطبیق‌یافته برای هر مدل، پیکره و رژیم زمانی شامل ادعاهایی است

که هر دو روش Strong و Bias-aware برای آن‌ها خروجی معتبر دارند:

$$\mathcal{M}_{m,d,z} = \{i : \hat{y}_i^S \in \mathcal{Y}_d \wedge \hat{y}_i^B \in \mathcal{Y}_d\}. \quad (۱۰.۳)$$

در این مجموعه، Fixed به نمونه‌ای گفته می‌شود که Strong در آن نادرست و Bias-aware درست است و

Broke حالت عکس را نشان می‌دهد. اختلاف دقت از رابطه‌ی زوجی فصل دوم، یعنی $(N_{\text{fixed}} - N_{\text{broke}})/N$ ،

به دست می‌آید. علاوه بر اثر خالص، تعداد و نرخ هر دو نوع تغییر گزارش می‌شود تا دو مداخله با اختلاف دقت

یکسان اما الگوی اصلاح/تخریب متفاوت از یکدیگر متمایز شوند.

برای آزمون فرض برابری احتمال Fixed و Broke از مکنمار استفاده می شود [۱۶]. هنگامی که تعداد زوج های ناهم خوان کم باشد نسخه ی دقیق دو جمله ای و در غیر این صورت نسخه ی مناسب تقریبی به کار می رود. آزمون روی نمونه های تطبیق یافته انجام می شود و سلول هایی که هر دو روش در آن ها وضعیت صحت یکسان دارند، در آماری عدم تقارن نقشی ندارند.

فاصله ی اطمینان و آزمون های متعدد.

عدم قطعیت اختلاف دقت، Macro-F1 و اثرهای زیرگروهی با بوت استرپ زوجی برآورد می شود [۹]. در هر یک از ۲۰۰۰ تکرار، شناسه ی ادعا با جایگزینی نمونه گیری و هر دو پیش بینی همراه همان شناسه نگه داشته می شوند. فاصله ی اطمینان ۹۵ درصد از صدک های ۵/۲ و ۵/۹۷ توزیع بازنمونه گیری به دست می آید. اگر اندازه ی گروه یا تعداد تغییرهای زوجی برای استنباط کافی نباشد، نتیجه فقط توصیفی گزارش می شود.

تحلیل هم زمان چند مدل، پیکره، رژیم و نوع سوگیری تعداد آزمون ها را افزایش می دهد. برای هر خانواده ی از پیش تعریف شده، روش Holm خطای خانواده ای را کنترل می کند؛ بنابراین مقادیر احتمال خام و تصحیح شده از یکدیگر جدا می شوند. حداقل های عملیاتی نیز پیش از تحلیل تعیین شده اند: $n \geq 20$ برای نمایش توصیفی، $n \geq 30$ برای استنباط گروهی، دست کم ۱۰ زوج ناهم خوان برای تفسیر مکنمار و $n \geq 50$ برای ادعاهای قوی تر در سطح نوع سوگیری. گروه های کوچک حذف خاموش نمی شوند و با علامت هشدار یا سطح شواهد پایین تر نمایش داده می شوند.

تحلیل زمانی و کنترل ترکیب. تعامل زمان و مداخله با I_T در رابطه ی (۲.۳) محاسبه می شود. برای جلوگیری از نسبت دادن هر اختلافی به تازگی، توزیع برچسب در دو رژیم مقایسه و فاصله ی تغییرات کل محاسبه می شود:

$$TVD(P_s, P_u) = \frac{1}{2} \sum_k |P_s(k) - P_u(k)|. \quad (11.3)$$

در پیکره های دارای فراداده، شکاف زمانی درون موضوع و برای گویندگان یا موجودیت های پرتکرار نیز محاسبه می شود. این تحلیل ها آزمون مستقیم حفظ کردن اطلاعات نیستند، زیرا میزان مواجهه ی واقعی مدل مشاهده نمی شود؛ آن ها فقط بررسی می کنند آیا ناهمگنی موضوعی یا آشنایی احتمالی با موجودیت با شکاف تجمیعی

هم‌زمان است. تحلیل اصلی روی داده‌ی کامل انجام می‌شود و نسخه‌ی متوازن‌شده صرفاً آزمون حساسیت به غلبه‌ی کلاس یا پیکره‌ی بزرگ‌تر است.

فضای برجسب نیز یک منبع حساسیت است. برای تحلیل‌هایی که Half-True را در Misleading ادغام می‌کنند، همه‌ی معیارهای اصلی در حالت اصلی و ادغام‌شده بازمحاسبه می‌شوند. اگر جهت یا اندازه‌ی اثر به نگاشت وابسته باشد، آن تحلیل به‌عنوان حساس به فضای برجسب گزارش می‌شود. این کنترل مانع آن است که نتیجه‌ای حاصل تصمیم فنی استانداردسازی، به‌عنوان رفتار عمومی مدل تعبیر شود.

تحلیل تغییر سیاست تصمیم. برای هر کلاس k ، اختلاف نرخ پیش‌بینی میان دو راهبرد محاسبه می‌شود:

$$\Delta P_k = P(\hat{Y}_B = k) - P(\hat{Y}_S = k). \quad (۱۲.۳)$$

این کمیت مستقل از صحیح‌بودن پاسخ نشان می‌دهد افزودن بلوک سوگیری احتمال انتخاب کدام کلاس‌ها را افزایش یا کاهش داده است. همراه آن، ماتریس انتقال $\hat{Y}_S \rightarrow \hat{Y}_B$ و برجسب مرجع گزارش می‌شود تا تغییرهای سودمند از تغییرهای صرفاً جهت‌دار جدا شوند. فصل سوم فقط روش این محاسبه را تعریف می‌کند و نام‌گذاری یا تفسیر الگوی مشاهده‌شده به فصل چهارم واگذار می‌شود.

تحلیل نوع و خانواده‌ی سوگیری. برای هر سوگیری b با اندازه‌ی کافی، اثر شرطی برابر است با

$$\Delta_b = \mathbb{E}[C^B - C^S \mid b \in B_i]. \quad (۱۳.۳)$$

Δ_b همراه تعداد نمونه، تعداد Fixed/Broke، فاصله‌ی اطمینان و مقدار احتمال تصحیح‌شده گزارش می‌شود. برای کاهش پراکندگی در کلاس‌های کم‌فراوان، سوگیری‌های مرتبط در خانواده‌های مفهومی از پیش تعریف‌شده تجمیع و اثر خانواده به‌صورت میانگین وزن‌دار برجسب تعداد نمونه محاسبه می‌شود. اگر یک ادعا چند سیگنال داشته باشد، عضویت آن در هر گروه ثبت می‌شود و استقلال گروه‌ها فرض نمی‌گردد؛ از این رو، نتایج سطح سوگیری عمدتاً برای بررسی ناهمگنی و تولید فرضیه استفاده می‌شوند.

رابطه‌ی اطمینان آشکار ساز و اثر مداخله نیز با گروه‌بندی یا مدل‌سازی پیوسته‌ی q_{ik} بررسی می‌شود. هدف،

فصل ۳: مدل سازی و طراحی چارچوب پژوهش سنجی ادعاهای جدید در مدل های زبانی بزرگ با کمک سوگیری های شناختی

سنجش تجربی هم بستگی نمره ی اطمینان با $C^B - C^S$ است. آستانه ی ۳۰٪ در این تحلیل ثابت می ماند و نتیجه برای باز تنظیم پسینی آستانه روی همان داده استفاده نمی شود؛ هر سیاست مبتنی بر اطمینان به عنوان تحلیل اکتشافی مشخص خواهد شد.

ظرفیت انتخاب مداخله. برای تعیین حد بالای محاسباتی انتخاب میان دورا هبرد، پیش بینی اوراکل به صورت زیر تعریف می شود:

$$C_i^O = \max(C_i^S, C_i^B), \quad Acc_O = \frac{1}{N} \sum_i C_i^O. \quad (۱۴.۳)$$

این اوراکل از برچسب مرجع برای انتخاب استفاده می کند و قابل استقرار نیست؛ تنها سقف عملکرد قابل دستیابی با همین دو خروجی موجود را نشان می دهد. در کنار آن، مسئله ی مسیریابی به صورت انتخاب $r(x) \in \{S, B\}$ با هدف بیشینه کردن $\mathbb{E}[C^{r(x)} | x]$ تعریف می شود. متغیر هدف مناسب برای یک مسیریاب، سود شرطی $\mathbb{E}[C^B - C^S | x]$ است، نه صرفاً احتمال وجود یک سوگیری. در این پایان نامه، اوراکل و سیاست های ساده برای سنجش ظرفیت و محدودیت داده تحلیل می شوند؛ آموزش یک مسیریاب جدید به عنوان نتیجه ی انجام شده گزارش نمی شود.

تحلیل های تأییدی، اکتشافی و اعتبار. مقایسه ی seen/unseen، تضاد Strong/Bias-aware، شکاف زمانی و آزمون زوجی تحلیل های اصلی اند. تحلیل نوع سوگیری، موضوع، گوینده، فاصله از مرز، پاسخ به اطمینان آشکار ساز و مسیریابی اکتشافی اند. در همه ی آن ها اندازه ی اثر، فاصله ی اطمینان و اندازه ی نمونه در کنار معنی داری آماری گزارش می شود تا انتخاب یک مقدار احتمال کوچک جایگزین سنجش اهمیت عملی نشود.

تهدیدهای اعتبار شامل عملیاتی بودن مرز seen/unseen، تفاوت دامنه و ترکیب پیکره ها، انتقال آشکار ساز از MindScope به ادعاهای واقعی، نبود برچسب انسانی معیار برای سوگیری، تغییر هم زمان طول و معنای پرامپت، وابستگی احتمالی ادعاهای یک گوینده و ماهیت بسته ی حقیقت سنجی است. کنترل های متناظر شامل تحلیل پیکره ای و سطح کلاس، مقایسه ی زوجی، ثبت خطای بالادستی، ثابت بودن هسته ی Strong، تحلیل حساسیت نگاشت برچسب، تصحیح آزمون های متعدد و جداسازی خروجی نامعتبر از خطای حقیقت سنجی هستند. این کنترل ها دامنه ی استنتاج را مشخص می کنند، اما محدودیت ها را حذف کامل نمی کنند.

۳-۸- جمع‌بندی

در این فصل روش پژوهش در هشت بخش یکپارچه شد. معماری دو فازي ابتدا با MindScope و DeBERTa-v3-base سیگنال‌های سوگیری را تولید می‌کند و سپس آن‌ها را در کنار تاریخ و فضای برجسب پیکره‌ها به آزمایش سه راهبرد پرامپتی وارد می‌سازد. استانداردسازی داده، تفکیک زمانی مدل‌محور، طراحی بسته‌ی حقیقت‌سنجی و اجرای چندمدلی به‌گونه‌ای تعریف شدند که تضاد Strong و Bias-aware در سطح همان ادعا قابل محاسبه باشد.

پروتکل اجرا، خروجی ساختاریافته، مدیریت خطا، ذخیره‌ی سطح نمونه و قواعد بازتولیدپذیری امکان‌میزی هر مقدار تجمیعی را فراهم می‌کنند. طرح تحلیل نیز از معیارهای فصل دوم استفاده می‌کند و آن‌ها را با شکاف زمانی، مقایسه‌ی زوجی، بوت‌استرپ، مکنمار، تصحیح Holm، تحلیل سطح سوگیری و برجسب، کنترل ترکیب و ارزیابی ظرفیت انتخاب تکمیل می‌سازد. هیچ‌یک از این تعریف‌ها در باره‌ی جهت یا اندازه‌ی نتیجه پیش‌داوری نمی‌کنند؛ فصل چهارم همین پروتکل را بر خروجی‌های واقعی اعمال و نتایج را گزارش خواهد کرد.

فصل ۴

پیاده‌سازی، تحلیل اکتشافی و تحلیل عمیق نتایج

در فصل سوم، طراحی دو فاز، تفکیک زمانی، سه راهبرد پرامپتی و پروتکل آماری تعریف شد. این فصل نتایج را در سه سطح مکمل گزارش می‌کند: نخست کیفیت داده و سیگنال آشکارساز؛ سپس تعمیم زمانی در سطح مطالعه؛ و در نهایت اثر زوجی مداخله‌ی شناختی در سطح همان ادعا. هدف فقط رتبه‌بندی روش‌ها نیست، بلکه تفکیک «سطح عملکرد» از «پایداری زمانی» و شناسایی تغییری است که مداخله در سیاست تصمیم مدل ایجاد می‌کند.

۴-۱- داده، ممیزی و ساختار زمانی

در تحلیل اکتشافی ۴۴۴۰۳۳۰ ردیف پیش‌بینی خوانده شد: ۷۳۶۰۲۷۳ ردیف اجرای اصلی و ۷۰۸۰۵۶ ردیف نسخه‌های متوازن‌شده‌ی پس‌پردازشی. تعداد ۶۶۷۰۴ ردیف دارای prediction_error بود و کنار گذاشته شد تا خطای زیرساخت یا پاسخ غیرقابل‌پارس به‌عنوان خطای حقیقت‌سنجی شمرده نشود. پنج پیکره در مجموع ۱۰۸۰۲۴ ادعای یکتا دارند. جدول ۴-۱ اندازه، فضای برچسب، طول ادعا و پوشش سیگنال شناختی را یک‌جا نشان می‌دهد.

اختلاف چند مرتبه‌ای اندازه‌ی پیکره‌ها [۵، ۲۳، ۲۱، ۱۳، ۳] و ناهمسانی فضای برچسب نشان می‌دهد تجمیع ساده‌ی همه‌ی نمونه‌ها می‌تواند نتیجه را به دو پیکره‌ی بزرگ متمایل کند. ازاین‌رو، تحلیل کلان بر ۱۱ مطالعه‌ی کامل مدل-پیکره استوار است که هر سه روش و هر دو رژیم زمانی را دارند؛ پس از حذف یک ترکیب

حقیقت‌سنجی ادعاهای جدید در مدل‌های زبانی بزرگ با کمک سوگیر فضایی، تحلیل اکتشافی و تحلیل عمیق نتایج

جدول (۱-۴) ممیزی فشرده‌ی پیکرها و پوشش سیگنال شناختی

پیکره	ادعا	کلاس	طول میانگین	پوشش سیگنال	Cramér's V
Matter-of-Fact	۳۶۰،۸	۲	۵۳.۲۹	%۴۷.۵۰	۰.۳۱.۰
TRACeR	۹۹۴،۱۴	۳	۷۷.۱۸	%۹۸.۴۴	۰.۳۰.۰
TSVeR	۳۰۴	۴	۷۴.۱۵	%۷۵.۴۳	۱۷۵.۰
ClaimReview Plus	۳۰۰	۴	۹۴.۱۵	%۳۳.۵۵	۰.۷۹.۰
FACT5	۱۵۰	۴	۴۹.۲۴	%۳۳.۵۱	۱۹۱.۰

با فقط یک نمونه‌ی seen، این هسته ۳۳ سلول روش و ۶۶ مقدار seen/unseen دارد. تحلیل مداخله نیز روی هسته‌ای مستقل و سخت‌گیرانه انجام می‌شود: ۴۲۰'۱۰ زوج unseen در ۱۳ ترکیب مدل-پیکره که در آن Strong Bias-aware برای همان claim_id خروجی معتبر دارند. این دو مخرج به ترتیب برای تعمیم مطالعه‌محور و استنباط زوجی به کار می‌روند و نباید با یکدیگر خلط شوند.

ممیزی لایه‌ی شناختی نشان داد از ۷۲ کلاس قابل پیش‌بینی، ۴۴ نوع سوگیری دست‌کم یک بار در پیکره‌های مقصد فعال شده‌اند و در مجموع ۶۴۲'۱۱ سیگنال ثبت شده است. پنج دسته‌ی پرتکرار عبارت‌اند از:


- Just-world Hypothesis و Hindsight Bias، Curse of Knowledge؛

- Bias Blind Spot و Time-saving Bias.

این پنج دسته حدود ۶۵ درصد سیگنال‌ها را تشکیل می‌دهند. بنابراین فضای نظری ۷۲ کلاسه در کاربرد واقعی به توزیعی دنباله‌سنگین فرو می‌ریزد؛ نتیجه‌های دسته‌های کم‌تکرار را نباید هم‌وزن دسته‌های پرتکرار تفسیر کرد.

ترکیب هسته‌ی زوجی نیز کاملاً یکنواخت نیست: ۷۶ درصد از ۴۲۰'۱۰ زوج unseen به Matter-of-Fact تعلق دارند. نتیجه‌ی تجمیعی Strong در برابر Bias-aware رفتار همین مخزن زوجی را به‌درستی توصیف می‌کند؛ اما نباید بدون تحلیل لایه‌ای به «اثر متوسط روی همه‌ی دامنه‌ها» تعبیر شود. نمودارهای مطالعه‌محور و تک‌سوگیری این وابستگی را آشکار می‌کنند.

شکل ۱-۴ عدم‌تقارن حجم دو سوی برش را در ۱۱ مطالعه‌ی کامل نشان می‌دهد. در هر مطالعه، کمینه‌ی تعداد معتبر سه روش به‌عنوان حجم مشترک نمایشی گرفته شده است. نامتوازن بودن split سبب می‌شود عدم قطعیت و وزن ضمنی مطالعات متفاوت باشد؛ به همین دلیل میانگین بدون وزن مطالعه‌ها، تحلیل زوجی و فاصله‌ی اطمینان در کنار یکدیگر گزارش می‌شوند.



شکل (۱-۴) حجم نمونه‌ی قابل مقایسه‌ی seen و unseen در ۱۱ مطالعه‌ی کامل مدل-پیکره

برش زمانی فقط مواجهه‌ی احتمالی مدل با اطلاعات را تغییر نمی‌دهد؛ توزیع کلاس، موضوع، موجودیت، طول و دشواری نیز ممکن است همراه زمان جابه‌جا شوند [۶، ۱، ۲۰]. بنابراین شکاف مشاهده‌شده را باید یک برآیند دانست، نه برآورد علی خالص حضور یا نبود ادعا در پیش‌آموزش:

$$G_{obs} = G_{exposure} + G_{composition} + G_{topic} + G_{difficulty} + G_{model} + \epsilon. \quad (۱.۴)$$

ممیزی فراداده‌ی اجرا یک محدودیت مهم دیگر را آشکار کرد. مرز ثبت‌شده برای GPT-4o-mini و دو نسخه‌ی Llama-3.1 بیش از ۴۵ روز با cutoff مستند در EDA فاصله داشت. مرز Llama-3.1-70B نیز میان پیکره‌ها یکسان نبود.

این پرچم برای DeepSeek-V3 هم ثبت شد، اما برای Qwen2.5-72B و دو نسخه‌ی Grok-3 دیده نشد. از این‌رو، اصطلاح seen/unseen در تمام نتیجه‌ها صرفاً به دو سوی مرز عملیاتی ذخیره‌شده در همان اجرا اشاره

حقیقت‌سنجی ادعاهای جدید در مدل‌های زبانی بزرگ با کمک سوگیر فضایی^۴، تحلیل اکتشافی و تحلیل عمیق نتایج

دارد و نباید به مشاهده‌ی مستقیم داده‌های پیش‌آموزش تعبیر شود.

تغییر ترکیب برچسب طلایی در دو سوی همین مرز نیز قابل چشم‌پوشی نیست. در ۱۸ ترکیب مدل-پیکره که هر دو سوی زمانی را داشتند، میانه‌ی فاصله‌ی تغییر کل^۱ توزیع برچسب برابر ۱۷/۰ بود. بیشینه‌ی ۷۰/۰ به سلولی با فقط سه نمونه‌ی seen تعلق داشت و بنابراین برای استنباط استفاده نشد؛ با این حال، مقادیر بزرگ بعدی نیز نشان می‌دهند بخشی از شکاف خام می‌تواند از تغییر نرخ پایه‌ی کلاس‌ها ناشی شود. این مشاهده ضرورت تجزیه‌ی ترکیب و تحلیل شرطی را تقویت می‌کند.

۲-۴ - تحلیل اکتشافی و ارزیابی آشکارساز

مدل DeBERTa-v3-base در فاز نخست روی مسئله‌ی ۷۲ کلاسه‌ی MindScope تنظیم دقیق شد [۳۱]، [۱۱]. نتایج آزمون در جدول ۲-۴ آمده است.

جدول (۲-۴) عملکرد آشکارساز ۷۲ کلاسه‌ی سوگیری شناختی روی آزمون MindScope


مقدار	معیار
۰.۹۳۰.۰	Test Loss
%۲۰.۹۸	Accuracy
%۱۵.۹۸	Macro-F1
%۲۰.۹۸	Weighted-F1

نزدیکی سه معیار جدول نشان می‌دهد امتیاز بالا فقط محصول کلاس‌های غالب نیست. با این حال، ۲۰/۹۸ درصد عملکرد درون دامنه‌ی MindScope است و دقت برچسب‌های منتقل شده به ادعاهای سیاسی، خبری و علمی را اثبات نمی‌کند. سنجش مستقیم این انتقال به برچسب انسانی مستقل در پیکره‌های مقصد نیاز دارد. از سوی دیگر، حتی تشخیص درست یک نشانه تضمین نمی‌کند افزودن آن به پرامپت، تصمیم حقیقت‌سنج را بهتر کند:

$$A_{\text{detector}} \neq U_{\text{downstream}} \quad (۲.۴)$$

^۱Total Variation Distance

آشکارساز برای حدود نیمی از ادعاها حداقل یک سیگنال فعال کرده است. شکل ۴-۲ پوشش و confidence میانگین را در پنج پیکره مقایسه می‌کند؛ confidence در اینجا اطمینان از وجود cue است، نه احتمال سودمندی مداخله. مقادیر $\text{Cramér's } V$ در جدول ۴-۱ نیز عمدتاً کوچک‌اند، پس حضور سیگنال را نمی‌توان میان‌بری ساده برای برچسب حقیقت دانست. در عین حال، وابستگی ضعیف سیگنال به حقیقت مانع از آن نیست که ارائه‌ی سیگنال توزیع خروجی مدل را تغییر دهد؛ بخش ۴-۶ این اثر را مستقیماً می‌آزماید.



شکل (۴-۲) پوشش و میانگین confidence آشکارساز سوگیری در پنج پیکره‌ی حقیقت‌سنجی

۴-۳- نتایج اصلی تعمیم زمانی

جدول ۴-۳ میانگین بدون وزن عملکرد ۱۱ مطالعه‌ی کامل را گزارش می‌کند و شکل ۴-۳ همان مقایسه را تصویری می‌سازد.

با تعریف $G^{(m)} = \text{Acc}_{\text{seen}}^{(m)} - \text{Acc}_{\text{unseen}}^{(m)}$ ، شکاف‌ها برابرند با


(۳.۴)

$$G_{\text{Naive}} = -۳/۰۸ \text{ pp}, \quad G_{\text{Strong}} = -۴/۶۱ \text{ pp}, \quad G_{\text{BiasAware}} = -۰/۴۳ \text{ pp}.$$

حقیقت‌سنجی ادعاهای جدید در مدل‌های زبانی بزرگ با کمک سوگیرفصلی گنجانده‌شده، تحلیل اکتشافی و تحلیل عمیق نتایج

جدول (۳-۴) میانگین عملکرد ۱۱ مطالعه‌ی کامل در دو رژیم زمانی

Macro-F1	Accuracy	بخش	روش
%۸۶.۳۹	%۴۰.۴۸	Seen	Naive
%۱۹.۴۰	%۴۸.۵۱	Unseen	Naive
%۰۰.۴۰	%۲۸.۵۰	Seen	Strong
%۴۲.۴۱	%۸۹.۵۴	Unseen	Strong
%۶۷.۳۸	%۳۱.۴۹	Seen	Bias-aware
%۰۹.۳۸	%۷۴.۴۹	Unseen	Bias-aware



شکل (۳-۴) میانگین Accuracy سه راهبرد پرامپتی در seen و unseen در ۱۱ مطالعه‌ی کامل


در هیچ روش، میانگین unseen پایین‌تر از seen نیست. این نتیجه به معنای «دانستن آینده» نیست؛ بلکه نشان می‌دهد تاریخ انتشار هم‌زمان چند مؤلفه را جابه‌جا می‌کند و به‌تنهایی شاخص دشواری ذاتی نیست:

$$\boxed{\text{Novelty Temporal} \neq \text{Difficulty Intrinsic}}. \quad (۴.۴)$$

برای روشن‌شدن نقش ترکیب کلاس، اگر $\pi_{k,z}$ سهم کلاس k و $a_{k,z}$ دقت شرطی آن در رژیم z باشد، آنگاه تجزیه‌ی دقیق شکاف عبارت است از

$$G = \underbrace{\sum_k (\pi_{k,s} - \pi_{k,u}) a_{k,s}}_{\text{تغییر ترکیب کلاس}} + \underbrace{\sum_k \pi_{k,u} (a_{k,s} - a_{k,u})}_{\text{تغییر عملکرد شرطی}}. \quad (۵.۴)$$

پس حتی با ثبات عملکرد درون کلاس‌ها، تغییر سهم کلاس‌ها می‌تواند علامت G را عوض کند. شکل ۴-۴ نیز نشان می‌دهد جهت و اندازه‌ی اثر زمان میان مدل‌ها، پیکره‌ها و روش‌ها یکنواخت نیست؛ بنابراین میانگین کلی باید همراه ناهمگنی مطالعه‌به‌مطالعه خوانده شود.



شکل (۴-۴) شکاف تعمیم زمانی به تفکیک مدل-پیکره و روش؛ مقدار منفی یعنی Accuracy بخش unseen بیشتر است

برای آنکه نتیجه فقط بر میانگین ۱۱ مطالعه متکی نباشد، اختلاف seen-unseen در همه‌ی سلول‌هایی که حداقل ۳۰ نمونه در هر سو داشتند با فاصله‌ی اطمینان بوت‌استرپ آزمون شد. از ۴۶ سلول دارای هر دو سمت، ۳۷ سلول قابل استنباط بودند؛ پس از تصحیح Holm، ۱۲ اختلاف معنادار باقی ماند و جهت هر ۱۲ مورد مثبت

حقیقت‌سنجی ادعاهای جدید در مدل‌های زبانی بزرگ با کمک سوگیرفصلی گنایطی‌سازی، تحلیل اکتشافی و تحلیل عمیق نتایج

بود. میانه‌ی اختلاف در ۳۷ سلول قابل‌آزمون نیز ۰.۳۱+ بود. شکل ۴-۵ برآورد و فاصله‌ی اطمینان همه‌ی سلول‌ها را نشان می‌دهد؛ نقاط کم‌رنگ به دلیل حجم ناکافی صرفاً توصیفی‌اند. یک آزمون حساسیت مکمل، شکاف نسخه‌ی اصلی را با نسخه‌ی متوازن‌شده‌ی پس‌پردازشی مقایسه کرد. هم‌بستگی رتبه‌ای Spearman میان دو برآورد در ۴۵ سلول برابر ۰.۷۷ بود. بنابراین تغییر ترکیب نمونه‌ها اندازه‌ی برخی اثرها را جابه‌جا می‌کند، اما ترتیب کلی سلول‌ها تا حد زیادی پایدار است. این نتیجه همراه ممیزی TVD نشان می‌دهد ترکیب داده مهم است، ولی به‌تنهایی همه‌ی الگوی زمانی را توضیح نمی‌دهد.

۴-۴- مقایسه‌ی Naive، Strong و Bias-aware

خط‌پایه‌ی Strong نسبت به Naive در seen به اندازه‌ی ۸۸/۱ و در unseen به اندازه‌ی ۴۱/۳ واحد درصد Accuracy بالاتر دارد. این تفاوت سهم تعریف روشن برچسب‌ها و قواعد کنترل تاریخ، عدد، نفی و علیت را جدا می‌کند؛ در نتیجه اثر افزوده‌ی cue شناختی با یک خط‌پایه‌ی واقعی‌تر سنجیده می‌شود. حساسیت مدل‌های زبانی به صورت پرامپت نیز در مطالعات پیشین گزارش شده است [۴، ۱۸، ۳۰].

باین حال، بهترین سطح عملکرد و کوچک‌ترین شکاف به یک روش تعلق ندارند: Strong بیشترین Accuracy را دارد، ولی Bias-aware شکاف را از قدر مطلق ۶۱/۴ به ۴۳/۰ واحد درصد می‌رساند؛ بنابراین Temporal Equalization Gain برابر ۱۸/۴ واحد درصد است. شکل ۴-۶ این موازنه را نشان می‌دهد.


این مشاهده یک محدودیت تفسیری اساسی ایجاد می‌کند:

$$\boxed{\text{Invariance Temporal} \neq \text{Competence Temporal}}. \quad (۶.۴)$$

یک روش می‌تواند در دو رژیم تقریباً برابر ولی ضعیف عمل کند؛ از این رو کاهش شکاف فقط هنگامی شاهد robustness بهتر است که سطح عملکرد unseen نیز حفظ یا افزایش یابد.


اثر مستقیم مداخله نسبت به Strong برابر اختلاف دقت دو روش است. شکل ۴-۷ نشان می‌دهد این اثر در برخی ترکیب‌ها مثبت، در برخی نزدیک صفر و در تعدادی منفی است. پس نشانه‌ی شناختی نه یک ویژگی همواره مفید و نه همواره مضر، بلکه مداخله‌ای وابسته به مدل، پیکره، زمان و نوع سیگنال است.

فصل ۴: پیاده‌سازی، تحلیل اکتشافی و تحلیل تعمیم‌یافته نتایج ادعاهای جدید در مدل‌های زبانی بزرگ با کمک سوگیری‌های شناختی



شکل (۴-۵) اثر مرز زمانی عملیاتی بر دقت در سطح سلول؛ مقدار مثبت به معنای دقت بیشتر در unseen است و خطوط، فاصله‌ی اطمینان ۹۵ درصد بوت‌استرپ را نشان می‌دهند

حقیقت‌سنجی ادعاهای جدید در مدل‌های زبانی بزرگ با کمک سوگیر فضایی، تحلیل اکتشافی و تحلیل عمیق نتایج




شکل (۴-۶) موازنه‌ی Accuracy و پایداری زمانی؛ شکاف کوچک‌تر الزاماً به معنای competence بالاتر نیست

برای آزمون مستقیم اینکه آیا مداخله دقیقاً در ادعاهای جدیدتر مفیدتر می‌شود، برای هر سلول تضاد برهم‌کنش زیر محاسبه شد:

$$I_{m,d} = \Delta Acc_{unseen}^{B-S} - \Delta Acc_{seen}^{B-S}. \quad (۷.۴)$$

میانگین این تضاد در ۹ سلول دارای داده‌ی کامل، برای همه‌ی ادعاها ۰/۳۰- و در ۷ سلول دارای نمونه‌ی کافی bias-present برابر ۰/۲۷- بود. شکل ۴-۸ ناهمگنی شدید سلول‌ها را نشان می‌دهد: چند ترکیب اثر مثبت دارند، اما برآیند نمونه‌ی محدود حاضر از فرض «سود بیشتر Bias-aware در «unseen حمایت نمی‌کند. این تحلیل ماهیت اکتشافی دارد و به دلیل تعداد کم سلول‌ها جایگزین آزمون زوجی ادعاها نیست.




شکل (۴-۷) اثر Bias-aware نسبت به Strong در هر مطالعه و رژیم زمانی؛ مقدار مثبت به نفع مداخله است

۴-۵- تحلیل آماری زوجی

برای حذف اثر تفاوت نمونه‌ها، دو روش روی همان ۴۲۰۱۰ ادعای unseen جفت شدند. اگر C_i^B و C_i^S شاخص درستی Strong و Bias-aware باشند، Fixed گذار (۰, ۱) و Broke گذار (۱, ۰) است. Strong دقت ۶۰۸/۰ و Bias-aware دقت ۵۸۱/۰ دارد؛ مداخله ۴۰۹ خطا را اصلاح، اما ۶۸۴ پاسخ درست را خراب می‌کند؛ در نتیجه اثر خالص $-۲۷۵ = ۶۸۴ - ۴۰۹$ است. آزمون دقیق McNemar این عدم تقارن را معنادار نشان می‌دهد ($p < ۰/۰۰۱$) [۱۶]. بنابراین نبود بهبود میانگین به معنای بی‌اثر بودن مداخله نیست؛ مداخله فعال است، اما جهت خالص آن منفی است.

جدول ۴-۴ شواهد اصلی زوجی را فشرده می‌کند. فاصله‌های اطمینان اثرهای تک‌سوگیری با paired bootstrap محاسبه و آزمون‌ها با روش Holm تصحیح شده‌اند [۹]. اعداد کامل همه‌ی دسته‌ها در Forest Plot شکل ۴-۹ باقی مانده‌اند.

حقیقت‌سنجی ادعاهای جدید در مدل‌های زبانی بزرگ با کمک سوگیری‌های متناهی‌سازی، تحلیل اکتشافی و تحلیل عمیق نتایج



شکل (۴-۸) تضاد برهم‌کنش اثر Bias-aware نسبت به Strong میان unseen و seen؛ مقدار مثبت یعنی سود نسبی بیشتر مداخله در ادعاهای جدیدتر

جدول (۴-۴) شواهد آماری اصلی در هسته‌ی زوجی unseen

p/q_{Holm}	B	F	CI 95%	ΔAcc	n	تحلیل
$p < 0.001$	۶۸۴	۴۰۹	—	-۰/۰۲۶	۴۲۰,۱۰	کل هسته
$p = 0.001, q = 0.012$	۵۴	۲۴	$[-0.061, -0.016]$	-۰/۰۴۰	۷۵۴	Bias Blind Spot
$p < 0.001, q = 0.006$	۶۸	۳۲	$[-0.060, -0.017]$	-۰/۰۳۹	۹۲۴	Curse of Knowledge

این نتیجه‌ی تجمیعی تنها شاهد زوجی موجود نیست.


در ممیزی همه‌ی مقایسه‌های روشی و لایه‌های زمانی/حضور سوگیری، ۳۰۶ آزمون مکنمار ساخته شد. از این تعداد، ۱۸۴ مورد حداقل ۱۰ زوج ناهم‌خوان و در نتیجه توان عملیاتی لازم را داشتند. در خانواده‌ی ازپیش‌تعریف‌شده‌ی مقایسه‌های روی کل نمونه‌ها، ۲۰ اختلاف پس از تصحیح Holm معنادار باقی ماند. جهت و اندازه‌ی این اختلاف‌ها میان مدل و پیکره ثابت نبود؛ بنابراین شواهد گسترده‌تر نیز به‌جای یک اثر عمومی، بر ناهمگنی مداخله تأکید می‌کنند.

۴-۶- تحلیل تک‌سوگیری و تغییر جهت تصمیم

اثر هر سوگیری با $\Delta_b = Acc_{BiasAware,b} - Acc_{Strong,b}$ محاسبه شد. به علت تفاوت فراوانی دسته‌ها، اندازه‌ی اثر فقط همراه n ، فاصله‌ی اطمینان و تصحیح چندآزمونی تفسیر می‌شود. پس از معیار حجم نمونه و تصحیح Holm فقط دو اثر معنادار می‌مانند: Bias Blind Spot و Curse of Knowledge؛ هر دو نیز منفی‌اند. هیچ اثر مثبت پس از تصحیح معنادار نیست. نقطه‌برآوردهای مثبت در دسته‌های دیگر، به دلیل عدم قطعیت، مبنای

کافی برای یک فهرست سفید عمومی نیستند.

تجمع دسته‌ها در پنج خانواده‌ی مفهومی نیز نتیجه را معکوس نکرد. اثر وزن‌دار خانواده‌ی «خطر و زیان» $0.52-$ ، «برجستگی و دسترس‌پذیری» $0.35-$ ، «دانش و بیش‌اطمینانی» $0.35-$ ، «اجتماعی و انگیزشی» $0.21-$ و «قاب‌بندی و شناخت آماری» $0.02-$ بود. این اعداد استنباط جداگانه‌ی معناداری برای خانواده‌ها نیستند، اما نشان می‌دهند سود مثبت پایداری با ادغام دسته‌های هم‌خانواده ظاهر نمی‌شود.




شکل (۹-۴) اثر زوجی Bias-aware نسبت به Strong به تفکیک سوگیری در ادعاهای unseen هم‌تاشده؛ خطوط افقی فاصله‌ی اطمینان bootstrap را نشان می‌دهند

تحلیل توزیع برچسب سازوکار رفتاری مهم‌تری را آشکار می‌کند. برای کلاس k ، تغییر فراوانی پیش‌بینی با $\Delta P_k = P(\hat{Y}_B = k) - P(\hat{Y}_S = k)$ سنجیده شد. شکل ۴-۱۰ برای ۱۵ سوگیری پرتکرار، الگوی مشترک نشان می‌دهد: میانگین تغییر $P(\text{Supported})$ در این ۱۵ ردیف $0.96+$ و میانگین تغییر $P(\text{Refuted})$ برابر $0.74-$ است. در کل هسته نیز نرخ Supported از حدود $0.32/5$ به $0.37/2$ درصد افزایش و نرخ Refuted از حدود $0.32/4$ به $0.28/8$ درصد کاهش می‌یابد. ماتریس‌های درهم‌ریختگی همین ساختار را از زاویه‌ی عملکرد کلاسی تأیید می‌کنند: Bias-aware بیشترین بازخوانی Supported و کمترین بازخوانی Refuted را دارد.

این الگوی جهت‌دار که در این پایان‌نامه **Shift Decision Permissive** نامیده می‌شود، نشان می‌دهد مداخله فقط تعداد خطاها را تغییر نمی‌دهد، بلکه prior تصمیم را به سوی پذیرش بیشتر ادعا جابه‌جا می‌کند.

حقیقت‌سنجی ادعاهای جدید در مدل‌های زبانی بزرگ با کمک سوگیری‌های شناختی‌سازی، تحلیل اکتشافی و تحلیل عمیق نتایج



شکل (۴-۱۰) تغییر توزیع برچسب به تفکیک سوگیری در ادعاهای unseen هم‌تا شده؛ مقدار مثبت یعنی انتخاب بیشتر آن برچسب توسط Bias-aware

چون دسترسی یکنواخت به logit و state hidden مدل‌های محور API وجود ندارد، این نتیجه رفتاری است، نه اندازه‌گیری مستقیم سازوکار درونی. به صورت مفهومی می‌توان نوشت

$$\Delta z(x, B) = \Delta z_{\text{claim}}(x, B) + \Delta z_{\text{prompt-prior}}(B), \quad (۸.۴)$$

که مؤلفه‌ی نخست cue وابسته به ادعا و مؤلفه‌ی دوم جهت‌گیری عمومی ناشی از قالب پرامپت است. الگوی مشترک چند سوگیری با وجود مؤلفه‌ی دوم سازگار است، اما آن را به طور علیّی اثبات نمی‌کند [۲۵، ۱۲]. ترکیب این تغییر جهت با کاهش شکاف زمانی، پارادوکس شناختی رفع سوگیری^۲ را شکل می‌دهد. این پارادوکس یکی از دستاوردهای مفهومی اصلی پژوهش است: مداخله‌ای که برای کاهش اثر میان‌برهای شناختی طراحی شده، می‌تواند خود یک سوگیری تصمیم تازه ایجاد کند. در داده‌های حاضر، نمود رفتاری این سوگیری همان Permissive Decision Shift، یعنی حرکت نظام‌مند خروجی به سوی پذیرش بیشتر ادعاها، است.

^۲Cognitive Debiasing Paradox

در این داده‌ها، Bias-aware فاصله‌ی زمانی را کم می‌کند، اما دقت کل را بالا نمی‌برد و مدل را به سمت Supported می‌برد. بنابراین کوچک‌شدن شکاف ممکن است تا حدی حاصل فشرده‌شدن سیاست تصمیم باشد، نه افزایش توانمندی:

$$\boxed{\begin{aligned} \text{Intervention Cognitive} &\rightarrow \text{Gap Temporal Smaller} \\ &\not\Rightarrow \text{Fact-Checking Better} \end{aligned}} \quad (۹.۴)$$

۴-۷- مسیر یابی و Oracle

برای کاهش زیان مداخله، سیاست آستانه‌ای $\pi_\gamma(x)$ فقط در صورت عبور confidence آشکارساز از γ ، مسیر Bias-aware را فعال می‌کند. جدول ۴-۵ نشان می‌دهد افزایش آستانه نرخ مداخله و زیان را کاهش می‌دهد، اما برتری پایدار نسبت به Strong-only ایجاد نمی‌کند.

جدول (۴-۵) سیاست‌های انتخاب روش روی هسته‌ی زوجی unseen

سیاست	Accuracy	Macro-F1	نرخ ارجاع	Fixed	Broke
Strong only	۶۰۸.۰	۳۹۷.۰	%۰.۰	۰	۰
Bias-aware only	۵۸۱.۰	۳۸۳.۰	%۱۰۰	۴۰۹	۶۸۴
confidence ≥ ۰.۳	۵۹۷.۰	۳۸۷.۰	%۶.۴۹	۲۰۷	۳۱۷
confidence ≥ ۰.۵	۶۰۵.۰	۳۹۸.۰	%۴.۲۱	۱۰۱	۱۲۶
confidence ≥ ۰.۷	۶۰۷.۰	۳۹۷.۰	%۱.۹	۴۷	۵۳
Helpful-bias whitelist	۶۰۹.۰	۳۹۷.۰	%۳.۱۴	۸۸	۷۰

علت بنیادی این شکست، تفاوت هدف آشکارسازی و مسیر یابی است. confidence تقریب $q(x)$ است، حال آنکه router باید سود مداخله را تخمین بزند: $P(\text{Bias Present} \mid x)$

$$g(x) = \mathbb{E}[C_B - C_S \mid x]. \quad (۱۰.۴)$$

از این رو، تمایز Detector Accuracy و utility که در بخش ۴-۲ دیده شد، در اینجا به پیام عملی می‌رسد:

وجود یا confidence بالایی cue به‌تنهایی معیار انتخاب مداخله نیست.

برای سنجش ظرفیت واقعی انتخاب، Oracle غیرقابل استقرار بهترین پاسخ دوروش را برای هر ادعا برمی‌گزیند. دقت آن ۶۴۷/۰ است؛ یعنی حدود ۹/۳ واحد درصد بالاتر از Strong-only. پس دو سیاست کاملاً زائد نیستند و برخی ادعاها واقعاً از مداخله سود می‌برند. با این حال، بهترین انتخاب‌گر ساده، یعنی فهرست سفید سوگیری‌های ظاهراً مفید، فقط به ۶۰۹/۰ می‌رسد و بهبودش با McNemar معنادار نیست ($p = ۰/۱۷۶$). مسئله‌ی مهندسی اصلی، تشخیص نشانه نیست، بلکه پیش‌بینی نمونه‌به‌نمونه‌ی سود مداخله با ویژگی‌های ادعا، مدل، دامنه، فاصله از برش زمانی و عدم قطعیت است.

۴-۸- بحث: ناهمگنی و حدود تفسیر

نتایج یک برنده‌ی مطلق معرفی نمی‌کنند. Strong بهترین خط‌پایه‌ی عمومی از نظر دقت است؛ Bias-aware کمترین شکاف زمانی را دارد، اما در هسته‌ی زوجی زیان خالص ایجاد می‌کند؛ و Oracle نشان می‌دهد سود بالقوه فقط با انتخاب زمینه‌مند قابل دستیابی است. این الگو با تفاوت instruction، alignment tuning و حساسیت مدل‌ها به context و نیز با تفاوت فضای برچسب و ماهیت ادعاها در TRACeR، Matter-of-Fact و TSVer سازگار است. بنابراین یک میانگین pooled نه به‌تنهایی شکست قطعی مداخله را اثبات می‌کند و نه مجوز استفاده‌ی همگانی از آن را می‌دهد.

فاصله‌ی میان Accuracy و Macro-F1 نیز بخشی از همین ناهمگنی است. برای مثال در unseen، Strong به‌ترتیب ۸۹/۵۴ و ۴۲/۴۱ درصد و Bias-aware به ۷۴/۴۹ و ۰۹/۳۸ درصد می‌رسند. این فاصله نشان می‌دهد عملکرد میان کلاس‌ها متوازن نیست و برتری روی کلاس‌های پرتکرار می‌تواند دقت کلی را بالا ببرد. از این‌رو ارزیابی کاربردی باید سطح دقت، توازن کلاس و پایداری زمانی را هم‌زمان بسنجد.

دو محدودیت مرز ادعاهای فصل را تعیین می‌کنند. نخست، seen/unseen جانشین عملیاتی exposure است، نه مشاهده‌ی corpus پیش‌آموزش؛ نمونه‌ی پس از cutoff لزوماً از همه‌ی اطلاعات پیشین مستقل نیست و نمونه‌ی پیش از cutoff نیز memorization را اثبات نمی‌کند. بنابراین نتایج درباره‌ی رفتار در دو توزیع زمانی‌اند، نه اثر علی خالص مواجهه. دوم، برچسب‌های سوگیری نموده‌های متنی را تقریب می‌زنند، نه حالت روان‌شناختی نویسندگان یا سازوکار درونی Transformer را [۲۶، ۲۷، ۳۱]. ادعای قابل دفاع این است که ارائه‌ی های cue

فصل ۴: پیاده‌سازی، تحلیل اکتشافی و تحلیل تعمیم‌یافته ادعاهای جدید در مدل‌های زبانی بزرگ با کمک سوگیری‌های شناختی

شناختی رفتار خروجی را تغییر می‌دهد؛ منشأ دقیق این تغییر به آزمایش‌های کنترلی مانند برچسب طلایی، cue تصادفی یا جابه‌جاشده و دسترسی به logit نیاز دارد.

برای سنجش شکنندگی این تفسیر، چند تحلیل تشخیصی که در EDA انجام شده بود در جدول ۴-۶ خلاصه می‌شود. این ردیف‌ها آزمون فرضیه‌ی اصلی جدید نیستند و نقش آن‌ها تعیین حدود تفسیر نتایج است.

جدول (۴-۶) تحلیل‌های حساسیت و تشخیصی مکمل

تحلیل	نتیجه‌ی عددی	حد تفسیر
توازن پس‌پردازشی	Spearman برابر ۷۷٪ در ۴۵ سلول	رتبه‌ی شکاف‌ها نسبتاً پایدار است، اما اندازه‌ی اثر به ترکیب حساس می‌ماند.
پنجره‌ی سه‌ماهه‌ی برش	دقت تجمیعی ۵۵۶٪ پیش از مرز و ۵۶۲٪ پس از آن	جهش افت فوری پس از مرز مشاهده نمی‌شود؛ این مقایسه توصیفی و تجمیعی است.
رفتار امتناع/حکم نرم	میان‌ه‌ی تغییر NEI برابر ۰۰۰٪ و حکم نرم ۰۰۷٪	برتری unseen صرفاً از افزایش امتناع حاصل نشده است.
توافق بین مدلی	کاپای زوجی تجمیعی از ۳۷٪ در seen به ۲۵٪ در unseen رسید	در این نمونه، توافق خروجی مدل‌ها در unseen کمتر است؛ این شاهد اکتشافی است و تفسیر علی ندارد.
نگاشت Half-True	میانگین و بیشینه‌ی تغییر دقت ۰۰۰٪؛ صفر سلول از ۴۴ سلول بیش از ۲ واحد درصد تغییر کرد	نتیجه‌ی اصلی محصول انتخاب نگاشت Half-True به Misleading نیست.
وابستگی سیگنال و حقیقت	هم‌بستگی سود با Cramér's V: $\rho = ۰/۲۲, p = ۰/۴۲۱$	شواهدی برای توضیح سود مداخله صرفاً با leakage برچسب دیده نشد.

در نتیجه، مداخله‌ی شناختی در شکل فعلی یک افزونه‌ی عمومی نیست. مسیر قابل دفاع، نگه‌داشتن Strong به‌عنوان پیش‌فرض و آموزش router برای برآورد مستقیم $g(x)$ است؛ confidence detector فقط یکی از ویژگی‌های چنین مدلی خواهد بود. این استنتاج از وجود هم‌زمان ۴۰۹ مورد Fixed، ۶۸۴ مورد Broke و ۹/۳ واحد درصد headroom در Oracle حاصل می‌شود، نه از تکرار صرف میانگین‌ها.

۴-۹ - خلاصه

ممیزی ۱۱ مطالعه‌ی کامل نشان داد ادعاهای unseen در میانگین الزاماً دشوارتر نیستند؛ شکاف Naive، Strong و Bias-aware به‌ترتیب ۰۸/۳-، ۶۱/۴- و ۴۳/۰- واحد درصد بود. این نتیجه در تحلیل سلولی نیز تقویت شد، اما اختلاف بعضی مرزهای عملیاتی با cutoff مستند و میان‌ه‌ی TVD برابر ۱۷٪، تفسیر علی آن را محدود می‌کنند. Strong بالاترین دقت را داشت، در حالی که کوچک‌شدن شکاف Bias-aware بدون افزایش سطح عملکرد رخ داد و تضاد برهم‌کنش نیز سود بیشتر مداخله در unseen را نشان نداد. تحلیل زوجی

حقیقت‌سنجی ادعاهای جدید در مدل‌های زبانی بزرگ با کمک سوگیری فصلی: چالش‌های ساختاری، تحلیل اکتشافی و تحلیل عمیق نتایج

اثر جهت‌دار مداخله را آشکار کرد: ۴۰۹ اصلاح در برابر ۶۸۴ تخریب، دو اثر تک‌سوگیری منفی و معنادار پس از Holm، و انتقال پیش‌بینی از Refuted به Supported. در نهایت، confidence و whitelist ساده نتوانستند headroom حدود ۹/۳ واحد درصدی Oracle را بازیابی کنند. برآیند فصل در چهار دستاورد مفهومی خلاصه می‌شود:

$$\begin{array}{l} \textit{Novelty} \neq \textit{Difficulty}, \quad \textit{Invariance} \neq \textit{Competence} \\ \textit{Debiasing} \rightarrow \textit{New Decision Bias} \\ \textit{Bias Detection} \neq \textit{Intervention Utility} \end{array} \quad (۱۱.۴)$$

فصل پنجم پیامدها، محدودیت‌ها و مسیرهای توسعه را با ارجاع به شواهد این فصل جمع‌بندی می‌کند.

فصل ۵

جمع‌بندی، نتیجه‌گیری و پیشنهادها

این پایان‌نامه حقیقت‌سنجی ادعاهای جدید را در تقاطع سه مسئله بررسی کرد: انتقال از ادعاهای seen به unseen، اثر صورت‌بندی پرامپت، و سود یا زیان افزودن نشانه‌های سوگیری شناختی. برای این منظور، یک آشکارساز ۷۲ کلاسه‌ی DeBERTa-v3 بر MindScope تنظیم دقیق شد و خروجی آن در کنار دو راهبرد Naive و Strong، راهبرد Bias-aware را ساخت [۳۱، ۱۱]. فصل چهارم نتایج عددی، شواهد زوجی و تفسیر رفتاری این آزمایش‌ها را به تفصیل ارائه کرد؛ فصل حاضر فقط پاسخ نهایی پرسش‌ها، دستاوردها، محدودیت‌ها و مسیر ادامه‌ی پژوهش را جمع‌بندی می‌کند.

۵-۱- جمع‌بندی و پاسخ نهایی به پرسش‌ها

پرسش محوری این بود که آیا عملکرد مناسب مدل‌های زبانی روی ادعاهای قدیمی‌تر به حقیقت‌سنجی ادعاهای جدیدتر تعمیم می‌یابد و آیا آگاه‌سازی مدل از نشانه‌های سوگیری این انتقال را بهبود می‌دهد. تفکیک زمانی پژوهش یک تعریف عملیاتی از تازگی است، نه اثبات عضویت یا عدم عضویت ادعا در پیکره‌ی پیش‌آموزش؛ زیرا همراه زمان، موضوع، کلاس، موجودیت و دشواری نیز ممکن است تغییر کنند [۶، ۱، ۲۰، ۲۲]. پاسخ شش پرسش فصل اول، با ارجاع به تحلیل کامل فصل ۴، چنین است:

۱. تفاوت عملکرد seen و unseen: در میانگین ۱۱ مطالعه‌ی کامل، unseen برای هیچ‌یک از سه راهبرد

دقت پایین‌تری نداشت. بنابراین نتیجه‌ی قابل دفاع، بهتر دانستن آینده توسط مدل نیست؛ بلکه کافی نبودن تازگی زمانی به‌عنوان شاخص دشواری است.

۲. نقش خط‌پایه‌ی **Strong**: این راهبرد از نظر میانگین دقت در هر دو رژیم از Naive بهتر بود، اما شکاف زمانی کوچک‌تری نداشت. پس تعریف دقیق فضای برچسب و قواعد بررسی ادعا سطح عملکرد را بهبود می‌دهد، ولی به‌تنهایی مسئله‌ی انتقال زمانی را حل نمی‌کند؛ همین امر ضرورت مقایسه با یک خط‌پایه‌ی قوی را تأیید می‌کند [۳۰، ۴، ۱۸].

۳. اثر افزودن اطلاعات سوگیری: Bias-aware بهبود عمومی نسبت به Strong ایجاد نکرد. در هسته‌ی زوجی unseen تعداد پاسخ‌های صحیحی که خراب شدند از خط‌هایی که اصلاح شدند بیشتر بود و اثر مداخله میان مدل، پیکره و نوع سوگیری ناهمگن باقی ماند.

۴. پایداری در برابر صلاحیت.

کوچک شدن محسوس شکاف seen/unseen در Bias-aware با حفظ یا افزایش عملکرد unseen همراه نبود. بنابراین برابری دو رژیم زمانی، بدون توجه به سطح مطلق دقت، شاهد کافی برای تعمیم زمانی بهتر نیست.

۵. پارادوکس شناختی رفع سوگیری: مداخله علاوه بر صحت، توزیع برچسب‌ها را نیز به‌صورت جهت‌دار تغییر داد؛ پیش‌بینی Supported بیشتر و Refuted کمتر شد. بنابراین رفع سوگیری پرامپتی، بدون بهبود دقت کلی، خود یک سوگیری تصمیم تازه ایجاد کرد. این نمود رفتاری در فصل چهارم با عنوان Permis-Shiftive Decision تحلیل شد.

۶. لزوم مداخله‌ی انتخابی.

آستانه‌گذاری اطمینان آشکارساز و فهرست ساده‌ی سوگیری‌ها نتوانستند بهبود پایداری نسبت به Strong ایجاد کنند، در حالی که Oracle ظرفیت مکمل بودن دو روش را نشان داد. پس شواهد از انتخاب نمونه‌به‌نمونه‌ی مداخله حمایت می‌کنند، نه افزودن همیشگی اطلاعات شناختی.

جدول ۵-۱ قضاوت نهایی درباره‌ی فرضیه‌ها را در قالب فشرده ارائه می‌کند.

فصل ۵: جمع‌بندی، نتیجه‌گیری و پیشنهادها حقیقت‌سنجی ادعاهای جدید در مدل‌های زبانی بزرگ با کمک سوگیری‌های شناختی

جدول (۱-۵) جمع‌بندی فرضیه‌های اصلی پژوهش

فرضیه	نتیجه	تفسیر نهایی
Unseen از seen ضعیف‌تر است	حمایت نمی‌شود	میانگین شکاف هر سه روش منفی است و unseen دقت پایین‌تری ندارد.
Strong نسبت به Naive انتقال زمانی بهتری دارد	حمایت نسبی	دقت Strong بیشتر است، اما شکاف زمانی آن کوچک‌تر نیست.
Bias-aware تعمیم زمانی را بهبود می‌دهد	فقط از نظر برابری	شکاف کوچک‌تر شد، ولی سطح عملکرد عمومی افزایش نیافت.
اثر مداخله به شرایط وابسته است	حمایت می‌شود	اثر میان مدل، پیکره، زمان و نوع سوگیری ناهمگن است.
confidence بالاتر، مداخله‌ی مفیدتری می‌سازد	حمایت نمی‌شود	دروازه‌گذاری زیان را کم کرد، اما پایدار از Strong عبور نکرد.
مداخله‌ی انتخابی ظرفیت بهبود دارد	در سطح Oracle حمایت می‌شود	ظرفیت وجود دارد، ولی انتخاب‌گرهای ساده آن را استخراج نمی‌کنند.

۵-۲- دستاوردها و نوآوری‌ها

دستآورد اصلی پایان‌نامه صرفاً افزودن نام یک سوگیری به پرامپت نیست؛ ارزش کار در طراحی کنترل‌شده و تمایزهایی است که از نتایج حاصل شدند. چهار دستآورد مفهومی نهایی عبارت‌اند از:

• Novelty $\neq$ Difficulty

قرارگرفتن ادعا پس از برش زمانی، به‌تنهایی نه دشواری بیشتر را اثبات می‌کند و نه نبود اطلاعات مرتبط در دانش پارامتری مدل را. ارزیابی زمانی باید اثر ترکیب داده و عملکرد شرطی را نیز در نظر بگیرد.

• Temporal Invariance $\neq$ Temporal Competence

شباهت عملکرد در دو رژیم زمانی فقط پایداری را توصیف می‌کند. این شباهت زمانی نشانه‌ی تاب‌آوری است که سطح عملکرد روی ادعاهای جدید نیز حفظ یا بهتر شده باشد.

• پارادوکس شناختی رفع سوگیری (Cognitive Debiasing Paradox)

رفع سوگیری پرامپتی می‌تواند خود یک سوگیری تصمیم تازه ایجاد کند. در این پژوهش، مداخله بدون بهبود دقت کلی، خروجی مدل‌ها را به‌طور نظام‌مند به سوی پذیرش بیشتر ادعاها سوق داد؛ Permissive Decision Shift نام الگوی رفتاری مشاهده‌شده‌ای است که این دستآورد را پشتیبانی می‌کند.

• Bias Detection $\neq$ Intervention Utility

دقت بالای آشکارساز در وظیفه‌ی بالادستی، بهبود تصمیم پایین‌دستی را تضمین نمی‌کند. معیار نهایی باید سود مداخله برای همان ادعا و همان مدل باشد.

از نظر روش‌شناختی، پژوهش یک خط لوله‌ی دو فاز برای اتصال آشکارساز سوگیری به حقیقت‌سنج زبانی ساخت و سه راهبرد پرامپتی را در پنج پیکره و دورژیم زمانی مقایسه کرد. استفاده از Strong اثر مهندسی دستور را از ارزش افزوده‌ی سیگنال شناختی جدا کرد؛ ممیزی سلول‌های کامل نیز از نتیجه‌گیری بر شبکه‌ی نامتوازن مدل-پیکره جلوگیری کرد. افزون بر میانگین دقت و Macro-F1، جفت‌سازی پیش‌بینی‌ها، تحلیل Fixed/Broke، آزمون McNemar، فاصله‌ی اطمینان، تحلیل تک‌سوگیری و تغییر توزیع برچسب به کار رفتند؛ این طراحی نشان داد ارزیابی مداخله‌ی پرامپتی باید بر همان نمونه‌ها و فراتر از یک میانگین کلی انجام شود [۱۶].

از نظر تجربی، Permissive Decision Shift به افزایش جهت‌دار پذیرش ادعا اشاره دارد و شاهد عملی Cognitive Debiasing Paradox است: مداخله، پیش‌فرض تصمیم را جابه‌جا و شکاف زمانی را بدون افزایش دقت فشرده کرد. این دستاورد یک یافته‌ی رفتاری است، نه ادعای دسترسی به سازوکار روان‌شناختی یا درونی مدل [۲۵، ۱۲، ۲۸].

از نظر مهندسی، نتیجه‌ی Oracle و مداخله‌ی انتخابی مکمل یکدیگرند. دقت Oracle نشان داد دو سیاست روی دقیقاً یک مجموعه از ادعاها موفق نمی‌شوند، اما شکست دروازه‌گذاری براساس اطمینان ثابت کرد وجود نشانه معیار مناسبی برای فعال‌سازی نیست. در نتیجه، مسئله از تشخیص سوگیری به انتخاب مداخله تبدیل می‌شود: Strong مسیر پیش‌فرض می‌ماند و مسیر یاب فقط هنگام سود مورد انتظار مثبت، مسیر شناختی را فعال می‌کند.

۵-۳- محدودیت‌ها

۱. تعریف زمانی و تغییر ترکیب.

مرز seen/unseen یک جانشین عملیاتی برای مواجهه است و محتوای واقعی داده‌ی پیش‌آموزش همه‌ی مدل‌ها مشاهده نشده است. افزون بر زمان، توزیع برچسب، موضوع، موجودیت، طول و دشواری نیز تغییر می‌کنند؛ بنابراین نتایج، مقایسه‌ی دو توزیع زمانی‌اند و نه اثر علی خالص مواجهه.

۲. انتقال آشکار ساز.

عملکرد ۹۸/۲۰ درصدی DeBERTa-v3 درون دامنه‌ی MindScope به دست آمده است. پیکره‌های مقصد برچسب طلایی سوگیری ندارند؛ از این رو سهم خطای آشکار سازی و خطای خود مداخله در نتیجه‌ی انتها به انتها کاملاً جدا نمی‌شود.

۳. دامنه‌ی مداخله و حقیقت‌سنجی: نتیجه‌ی منفی به قالب مشخص Bias-aware مربوط است و شکست همه‌ی روش‌های رفع سوگیری را اثبات نمی‌کند. همچنین ارزیابی اصلی closed-book است؛ سامانه‌ی عملی باید شواهد باز یابی شده، منبع و زمان انتشار را وارد تصمیم کند [۲۴، ۱۹، ۳].

۴. ناهمگنی و توان آماری.

تفاوت API، تنظیم دستوری و هم‌ترازی، تعمیم نتیجه‌ی یک مدل به مدل دیگر را محدود می‌کند. بعضی زیرگروه‌ها نیز کوچک‌اند؛ بنابراین اثرهای تک‌سوگیری فقط همراه حجم نمونه، فاصله‌ی اطمینان و تصحیح چند آزمونی قابل تفسیرند.

۵. محدودیت مکانیزمی.

برای همه‌ی مدل‌های بسته به لاجیت و حالت‌های پنهان دسترسی یکسان وجود ندارد. نسبت دادن تغییر رفتاری به پیش فرض ناشی از پرامپت، یک تبیین سازگار با خروجی هاست، نه مشاهده‌ی مستقیم سازوکار درونی.

۶. معیار و مسئولیت‌پذیری: Accuracy هزینه‌ی خطاها را یکسان فرض می‌کند، در حالی که پذیرش یک ادعای نادرست می‌تواند پرهزینه‌تر باشد. برچسب سوگیری نیز فقط cue متنی است و نباید به عنوان تشخیص حالت روان‌شناختی، صدور حکم درباره‌ی گوینده یا ابزار برچسب‌گذاری ایدئولوژیک استفاده شود.

۴-۵ - پیشنهادها برای ادامه‌ی پژوهش

یازده پیشنهاد نسخه‌ی اولیه در پنج برنامه‌ی پژوهشی ادغام می‌شوند. جدول ۵-۲ برای هر محور مسئله‌ی باز، آزمایش تعیین‌کننده و ارزش علمی آن را مشخص می‌کند؛ این پیشنهادها نتیجه‌ی انجام‌شده‌ی پایان‌نامه نیستند.

جدول (۵-۲) پنج محور اولویت‌دار برای ادامه‌ی پژوهش

محور	مسئله	آزمایش پیشنهادی	ارزش علمی
اعتبارسنجی علی مداخله	معلوم نیست اثر از معنای درست نشانه می‌آید یا از طول پرامپت، برانگیختگی و خطای آشکارساز.	Strong، سوگیری پیش‌بینی‌شده، برچسب طلایی انسانی و shuffled-bias روی همان ادعاها مقایسه شوند.	فاصله‌ی میان ارزش معنایی سیگنال، اثر قالب پرامپت و خطای بالادستی تفکیک می‌شود.
مداخله‌ی انتخابی	اطمینان، وجود سوگیری را می‌سنجد نه سود استفاده از آن؛ هزینه‌ی خطاها نیز برابر نیست.	یک مسیر یاب با برچسب‌های Broke، Fixed و بدون تغییر و ویژگی‌های ادعا، مدل، فاصله از برش و عدم قطعیت آموزش داده شود.	بخشی از فاصله‌ی Strong تا Oracle به سیاستی قابل استقرار تبدیل و پذیرش کاذب پرهزینه کنترل می‌شود.
حقیقت‌سنجی مبتنی بر شواهد	طراحی closed-book اثر دانش به‌روز و قابلیت استناد را نمی‌سنجد.	چهار حالت ادعا، ادعا+سوگیری، ادعا+شاهد و ادعا+شاهد+سوگیری با منبع و زمان انتشار مقایسه شوند.	روشن می‌شود نشانه‌ی شناختی در حضور شواهد بیرونی مکمل شاهد است یا همچنان پیش‌فرض نامطلوب ایجاد می‌کند.
معیار زمانی کنترل‌شده	زمان با موضوع، کلاس، محبوبیت موجودیت و دشواری درهم تنیده است.	زوج‌های زمانی هم‌تاشده و نمونه‌های پادواقعی ساخته شوند که فقط تاریخ، موجودیت یا مقدار وابسته به زمان را تغییر می‌دهند.	اثر تازگی از ترکیب داده و دشواری موضوع بهتر جدا و معیار دقیق‌تری برای دانش زمانی ساخته می‌شود.
قابلیت اعتماد و سازوکار	کالیراسیون، ناهمگنی سلسله‌مراتبی و منشأ مکانیزمی تغییر تصمیم هنوز ناشناخته‌اند.	روی مدل‌های وزن‌باز، کالیراسیون و امتناع، مدل چندسطحی مدل-داده-سوگیری، لاجیت و فعال‌سازی و پرامپت‌های خنثی مقایسه شوند [۱۰].	مشخص می‌شود تغییر به سمت پذیرش با چه عدم قطعیت و سازوکاری رخ می‌دهد و آیا می‌توان آن را بدون حذف سودهای موردی کاهش داد.

۵-۵ - نتیجه‌گیری نهایی

این پژوهش نشان داد ارزیابی حقیقت‌سنجی ادعاهای جدید را نمی‌توان به یک برش زمانی یا یک امتیاز دقت فروکاست. ادعاهای unseen در میانگین الزاماً دشوارتر نبودند، Strong مطمئن‌ترین راهبرد عمومی باقی ماند و Bias-aware با وجود کاهش شکاف زمانی، بهبود عمومی ایجاد نکرد و سیاست برچسب‌گذاری را به سمت پذیرش بیشتر تغییر داد. در نتیجه، رفع سوگیری پرامپتی می‌تواند خود یک سوگیری تصمیم تازه ایجاد کند. در عین حال، برتری Oracle نشان داد مداخله برای بخشی از ادعاها ارزش دارد. آخرین حرف پایان‌نامه بنابراین این است: زمان، پایداری و تشخیص یک سیگنال به‌ترتیب معادل دشواری، صلاحیت و سود مداخله نیستند. مسیر مناسب برای سامانه‌های آینده، ترکیب شواهد به‌روز با یک خط‌پایه‌ی قوی و فعال‌سازی انتخابی مداخله بر اساس سود واقعی همان ادعاست.

کتاب نامه

- [1] Agarwal, Oshin and Nenkova, Ani. Temporal effects on pre-trained models for language processing tasks. *Transactions of the Association for Computational Linguistics*, 10:904–921, 2022.
- [2] Allein, Laura, Saelens, Maarten, Cartuyvels, Ruben, and Moens, Marie-Francine. Implicit temporal reasoning for evidence-based fact-checking. In *Findings of the Association for Computational Linguistics: EACL 2023*, 2023.
- [3] Braun, Tobias, Rothermel, Mark, Rohrbach, Marcus, and Rohrbach, Anna. DEFAME: Dynamic evidence-based FAct-checking with multimodal experts. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pages 5383–5417. PMLR, 2025.
- [4] Chatterjee, Anwoy, Renduchintala, H S V N S Kowndinya, Bhatia, Sumit, and Chakraborty, Tanmoy. POSIX: A prompt sensitivity index for large language models. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages 14550–14565, 2024.
- [5] Chowdhury, Shayan, Fang, Sunny, and Muresan, Smaranda. FACT5: A novel benchmark and pipeline for nuanced fact-checking of complex statements. In *Proceedings of the Eighth Fact Extraction and VERification Workshop (FEVER)*, pages 101–117, Vienna, Austria, 2025. Association for Computational Linguistics.
- [6] Dhingra, Bhuwan, Cole, Jeremy R., Eisenschlos, Julian Martin, Gillick, Daniel, Eisenstein, Jacob, and Cohen, William W. Time-aware language models as temporal knowledge bases. *Transactions of the Association for Computational Linguistics*, 10:257–273, 2022.
- [7] Dhuliawala, Shehzaad, Komeili, Mojtaba, Xu, Jing, Raileanu, Roberta, Li, Xian, Celikyilmaz, Asli, and Weston, Jason. Chain-of-verification reduces hallucination in large language models. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 3563–3578, 2024.

- [8] Ecker, Ullrich K. H., Lewandowsky, Stephan, Cook, John, Schmid, Philipp, Fazio, Lisa K., Brashier, Nadia, Kendeou, Panayiota, Vraga, Emily K., and Amazeen, Michelle A. The psychological drivers of misinformation belief and its resistance to correction. *Nature Reviews Psychology*, 1:13–29, 2022.
- [9] Efron, Bradley and Tibshirani, Robert J. *An Introduction to the Bootstrap*. Chapman and Hall/CRC, 1993.
- [10] Guo, Chuan, Pleiss, Geoff, Sun, Yu, and Weinberger, Kilian Q. On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning*, pages 1321–1330, 2017.
- [11] He, Pengcheng, Gao, Jianfeng, and Chen, Weizhu. DeBERTaV3: Improving DeBERTa using ELECTRA-style pre-training with gradient-disentangled embedding sharing. In *International Conference on Learning Representations*, 2023.
- [12] Jain, Sarthak and Wallace, Byron C. Attention is not explanation. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 3543–3556, 2019.
- [13] Jansen, Peter, Hassan, Samiah, and Wang, Ruoyao. Matter-of-fact: A benchmark for verifying the feasibility of literature-supported claims in materials science. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, pages 4090–4102, Suzhou, China, 2025. Association for Computational Linguistics.
- [14] Kojima, Takeshi, Gu, Shixiang Shane, Reid, Machel, Matsuo, Yutaka, and Iwasawa, Yusuke. Large language models are zero-shot reasoners. In *Advances in Neural Information Processing Systems*, volume 35, 2022.
- [15] Manakul, Potsawee, Liusie, Adian, and Gales, Mark J. F. SelfCheckGPT: Zero-resource black-box hallucination detection for generative large language models. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 9004–9017, 2023.
- [16] McNemar, Quinn. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2):153–157, 1947.
- [17] Pennycook, Gordon and Rand, David G. Lazy, not biased: Susceptibility to partisan fake news is better explained by lack of reasoning than by motivated reasoning. *Cognition*, 188:39–50, 2019.

- [18] Pezeshkpour, Pouya and Hruschka, Estevam. Large language models sensitivity to the order of options in multiple-choice questions. In *Findings of the Association for Computational Linguistics: NAACL 2024*, pages 2006–2017, 2024.
- [19] Schlichtkrull, Michael, Chen, Yulong, Whitehouse, Chenxi, Deng, Zhenyun, Akhtar, Mubashara, Aly, Rami, Guo, Zhijiang, Christodoulopoulos, Christos, Cocarascu, Oana, Mittal, Arpit, Thorne, James, and Vlachos, Andreas. The automated verification of textual claims (AVeriTeC) shared task. In *Proceedings of the Seventh Fact Extraction and VERification Workshop (FEVER)*, pages 1–26, 2024.
- [20] Søgaard, Anders, Ebert, Sebastian, Bastings, Joost, and Filippova, Katja. We need to talk about random splits. In *Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics*, 2021.
- [21] Strong, Marek and Vlachos, Andreas. TSVer: A benchmark for fact verification against time-series evidence. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, pages 29906–29926, Suzhou, China, 2025. Association for Computational Linguistics.
- [22] Su, Zhaochen, Tang, Zecheng, Guan, Xinyan, Wu, Lijun, Zhang, Min, and Li, Juntao. Improving temporal generalization of pre-trained language models with lexical semantic change. In *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 6380–6393, 2022.
- [23] Tang, Yixuan, Wang, Jincheng, and Tung, Anthony Kum Hoe. The missing parts: Augmenting fact verification with half truth detection. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, pages 33979–33996, Suzhou, China, 2025. Association for Computational Linguistics.
- [24] Thorne, James, Vlachos, Andreas, Christodoulopoulos, Christos, and Mittal, Arpit. FEVER: a large-scale dataset for fact extraction and VERification. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 809–819, 2018.
- [25] Turpin, Miles, Michael, Julian, Perez, Ethan, and Bowman, Samuel R. Language models don’t always say what they think: Unfaithful explanations in chain-of-thought prompting. In *Advances in Neural Information Processing Systems*, volume 36, 2023.
- [26] Tversky, Amos and Kahneman, Daniel. Judgment under uncertainty: Heuristics and biases. *Science*, 185(4157):1124–1131, 1974.


- [27] Tversky, Amos and Kahneman, Daniel. The framing of decisions and the psychology of choice. *Science*, 211(4481):453–458, 1981.
- [28] Vaswani, Ashish, Shazeer, Noam, Parmar, Niki, Uszkoreit, Jakob, Jones, Llion, Gomez, Aidan N., Kaiser, Lukasz, and Polosukhin, Illia. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [29] Wang, William Yang. “liar, liar pants on fire”: A new benchmark dataset for fake news detection. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 422–426, 2017.
- [30] Wei, Jason, Wang, Xuezhi, Schuurmans, Dale, Bosma, Maarten, Ichter, Brian, Xia, Fei, Chi, Ed, Le, Quoc V., and Zhou, Denny. Chain-of-thought prompting elicits reasoning in large language models. In *Advances in Neural Information Processing Systems*, volume 35, 2022.
- [31] Xie, Zhentao, Zhao, Jiabao, Wang, Yilei, Shi, Jinxin, Bai, Yanhong, Wu, Xingjiao, and He, Liang. MindScope: Exploring cognitive biases in large language models through multi-agent systems. *Frontiers in Artificial Intelligence and Applications*, 2024.
- [32] Zhang, Michael J. Q. and Choi, Eunsol. Mitigating temporal misalignment by discarding outdated facts. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 14213–14226, 2023.
- [33] Zhang, Xuan and Gao, Wei. Towards LLM-based fact verification on news claims with a hierarchical step-by-step prompting method. In *Proceedings of the 13th International Joint Conference on Natural Language Processing and the 3rd Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics*, pages 996–1011, 2023.

Abstract

Large language models produce fluent and persuasive responses, but this capability does not necessarily imply reliable factual judgment, particularly for new claims. This thesis studies closed-book fact-checking through the lens of temporal generalization by comparing model behavior in operationally defined seen and unseen regimes. These terms refer only to the two sides of the temporal boundary recorded for each run; they do not establish whether a claim was present in pretraining data. A second research axis evaluates the effect of adding textual cognitive-bias cues to the fact-checking prompt. A 72-class DeBERTa-v3-base detector was fine-tuned on MindScope and achieved 98.20% accuracy and 98.15% Macro-F1 on its in-domain test set. Three prompting strategies—Naive, Strong, and Bias-aware—were then evaluated across five datasets and multiple model families. The temporal analysis used 11 complete model–dataset studies, while the direct intervention analysis used 10,420 matched unseen claim pairs. Accuracy, Macro-F1, temporal gaps, paired bootstrap intervals, McNemar tests, Holm correction, Fixed/Broke transitions, per-bias effects, and changes in verdict distributions were jointly examined. Across the 11 studies, Strong obtained mean seen/unseen accuracies of 50.28% and 54.89%, respectively, and provided the highest overall performance. Bias-aware obtained 49.31% and 49.74%, reducing the absolute temporal gap from 4.61 percentage points under Strong to 0.43 points, but without improving competence on unseen claims. In the matched pool, Strong and Bias-aware achieved accuracies of 0.608 and 0.581. The intervention fixed 409 errors but broke 684 correct predictions, a significant asymmetry under McNemar’s test $p < 0.001$. After multiple-testing correction, only Bias Blind Spot and Curse of Knowledge had significant per-bias effects, both negative. **The central finding is that prompt-based debiasing can itself introduce a new decision bias: the intervention systematically shifted models toward accepting more claims without improving overall accuracy.** This behavioral pattern is termed the Permissive Decision Shift and, more broadly, the Cognitive Debiasing Paradox. Nevertheless, a non-deployable Oracle reached 0.647 accuracy, indicating approximately 3.9 percentage points of complementary headroom. Together, the findings establish four conceptual contributions: temporal novelty is not equivalent to difficulty; temporal invariance is not equivalent to temporal competence; prompt-based debiasing can introduce a new decision bias; and bias-detection accuracy does not guarantee intervention utility. Strong is therefore the safer default, while cognitive information should be activated selectively according to the expected utility for each claim. These conclusions are behavioral rather than mechanistic: discrepancies between some operational boundaries and documented cutoffs, temporal composition shift, and

the lack of uniform access to logits and hidden states limit direct causal or mechanistic interpretation.

Keywords Automated Fact-Checking, Large Language Models, Temporal Generalization, New Claims, Cognitive Biases, Prompt Intervention



University of Tehran
College of Engineering
School of Electrical and
Computer Engineering
Department of Computer
Engineering



Fact-Checking New Claims in Large Language Models Using Cognitive Biases

Bachelor of Science Thesis in Computer Engineering

By:

Mohammad Amanlou

Supervisor:

Mohammadreza Abolghasemi Dehaqani

September 2026